Université de Lille

Devoir Maison – Macroéconométrie 2

ARCH, GARCH et rendements de l'indice S&P 500

Auteurs : François PICHON & Julien POT

24 novembre 2025

Devoir maison de Macroéconométrie 2 (Master Économie appliquée – Université de Lille).

Table des matières

Exercice 1 **2**
Données, construction des séries et premières observations . . . 2
Stationnarité des rendements . . . 4
Rendements non autocorrélés (en moyenne) . . . 4
Rendements au carré autocorrélés . . . 6
Rendements absolus autocorrélés . . . 7
Synthèse . . . 9

Exercice 2 **9**
Moyenne des rendements logarithmiques . . . 9
Transformation du modèle . . . 10
Vraisemblance et log-vraisemblance . . . 10
Moments non conditionnels . . . 12

Exercice 3 **16**
0.1 Vraisemblance conditionnelle . . . 16
Vraisemblance conditionnelle . . . 16
Log-vraisemblance et conditions de premier ordre . . . 17
Simulation du modèle avec `fGarch` . . . 17
Loi des espérences itérées . . . 18
Variance non conditionnelle . . . 19
Estimation sur la série S&P 500 . . . 20
Résidus standardisés . . . 20
Tests de bruit blanc . . . 21

Annexe – Code R complet **23**

Exercice 1

Données, construction des séries et premières observations

On utilise les cours de clôture ajustés P_t (variable `Adj.Close`) de l'indice S&P 500 à fréquence hebdomadaire de janvier 1987 à octobre 2020, soit

$$\boxed{T = 1761}$$

observations hebdomadaires.

On note, pour chaque date $t = 1, \dots, T$,

$$P_t = \text{cours de clôture ajusté à la date } t.$$

On construit d'abord le log-prix

$$\log P_t = \ln(P_t),$$

puis le rendement logarithmique défini par

$$r_t = \log P_t - \log P_{t-1} = \ln(P_t) - \ln(P_{t-1}), \qquad t = 2, \dots, T.$$

Autrement dit, si l'on pose $p_t = \log P_t$, on a simplement

$$r_t = \Delta p_t = p_t - p_{t-1}.$$

Ces deux transformations sont classiques en finance : on travaille d'abord sur le log-prix pour neutraliser la taille des prix, puis sur les différences de log pour obtenir une série de rendements potentiellement stationnaire qui seront liés aux modèles ARCH/GARCH.

La Figure 1 représente la trajectoire du log-prix $\log P_t$, tandis que la Figure 2 illustre la série des rendements r_t.

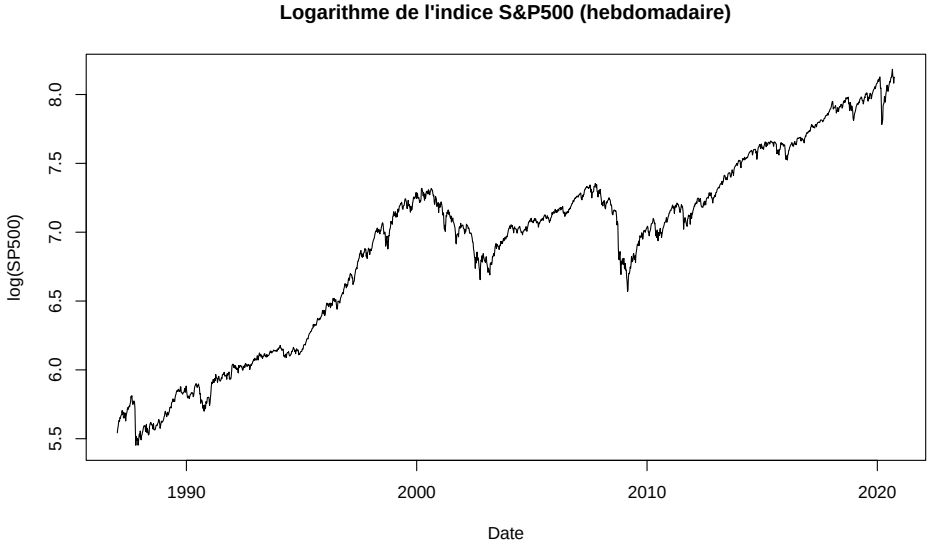


FIGURE 1 – Logarithme hebdomadaire de l'indice S&P 500 ($\log P_t$).

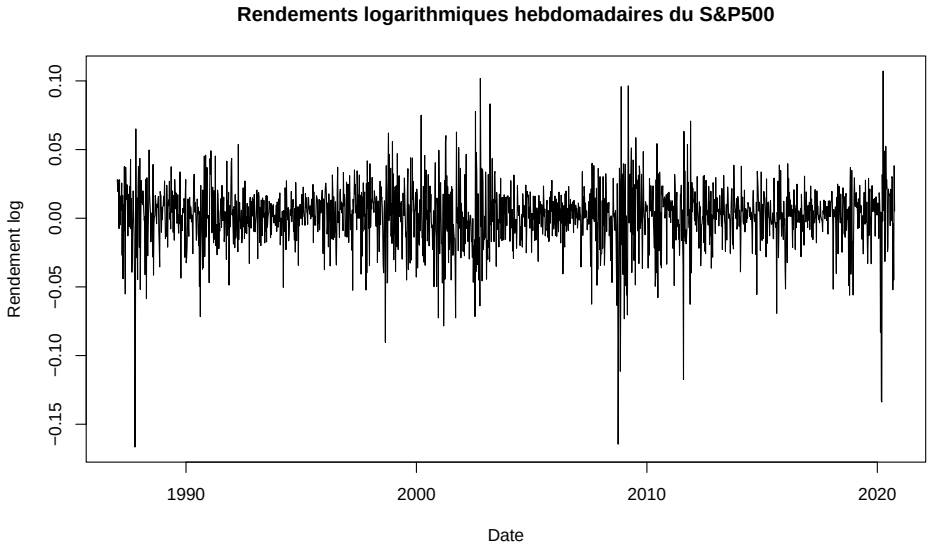


FIGURE 2 – Rendements logarithmiques hebdomadaires du S&P 500 (r_t).

Le graphique du log-prix $\log P_t$ (Figure 1) montre une tendance de long terme, ce qui est cohérent avec une non-stationnarité des prix (espérance qui dépend du temps).

En revanche, la trajectoire des rendements r_t (Figure 2) oscille autour d'une moyenne faible et quasi constante dans le temps, indiquant visuellement une stationnarité au niveau de la moyenne. On observe aussi de l'hétéroscédasticité : les périodes calmes (variations faibles) alternent avec des périodes de forte amplitude. Cela suggère une variance conditionnelle non constante (*volatility clustering*).

Ces premiers graphiques nous montrent donc que : les niveaux de prix sont non stationnaires, tandis que les rendements semblent plus réguliers en moyenne mais présentent une volatilité

très variable dans le temps. On va maintenant confirmer ces impressions visuelles par des tests statistiques.

Stationnarité des rendements

On va appliquer ici un test ADF sur la série $\{r_t\}$ pour tester l'hypothèse nulle de racine unitaire.

Rappel sur le test ADF. Une version simplifiée de la régression ADF s'écrit

$$\Delta r_t = \alpha + \varphi r_{t-1} + \sum_{i=1}^{p-1} \psi_i \, \Delta r_{t-i} + u_t, \qquad t = p+1, \dots, T,$$

où $\Delta r_t = r_t - r_{t-1}$.

L'hypothèse testée est

$$H_0 : \varphi = 0 \quad \text{(racine unitaire, non-stationnarité)}, \qquad H_1 : \varphi < 0 \quad \text{(stationnarité)}.$$

En notant $\hat{\varphi}$ l'estimateur MCO de φ et $\widehat{\text{se}}(\hat{\varphi})$ son erreur standard, la statistique de test ADF est

$$\text{ADF} = \frac{\hat{\varphi}}{\widehat{\text{se}}(\hat{\varphi})}.$$

Résultat sur les données. Sur la période considérée, on obtient

$$\boxed{\text{ADF} = -16{,}557} \qquad \text{avec une p-value} \qquad \boxed{p = 1{,}92 \times 10^{-29}}.$$

La p-value est très faible, on rejette donc très nettement l'hypothèse nulle de racine unitaire : la série des rendements $\{r_t\}$ est stationnaire.

Cela signifie que l'on peut appliquer sans problème des modèles de type ARCH/GARCH directement aux rendements : on ne risque pas de confondre une tendance de long terme avec de la volatilité.

Rendements non autocorrélés (en moyenne)

On évalue ensuite l'absence d'autocorrélation au niveau des rendements via l'ACF de r_t et le test de Ljung–Box avec $h = 12$.

Rappel : autocorrélation empirique. Si l'on note $\bar{r} = \frac{1}{T}\sum_{t=1}^{T} r_t$ la moyenne empirique, l'autocorrélation empirique au retard k est

$$\hat{\rho}_k = \frac{\displaystyle\sum_{t=k+1}^{T} (r_t - \bar{r})(r_{t-k} - \bar{r})}{\displaystyle\sum_{t=1}^{T} (r_t - \bar{r})^2}, \qquad k = 1, 2, \dots$$

et l'on teste globalement

$$H_0 : \rho_1 = \cdots = \rho_h = 0.$$

Test de Ljung–Box. La statistique de Ljung–Box est

$$Q(h) = T(T+2) \sum_{k=1}^{h} \frac{\hat{\rho}_k^2}{T-k},$$

qui, sous H_0 et pour T grand, suit approximativement une loi χ^2_h. On rejette H_0 si $Q(h)$ est trop grand (p-value $<$ seuil).

Le correlogramme empirique des rendements (Figure 3) présente des pics très proches de zéro pour les premiers retards, contenus dans les bandes de confiance asymptotiques $\left[-\frac{1{,}96}{\sqrt{T}}, \frac{1{,}96}{\sqrt{T}}\right]$.

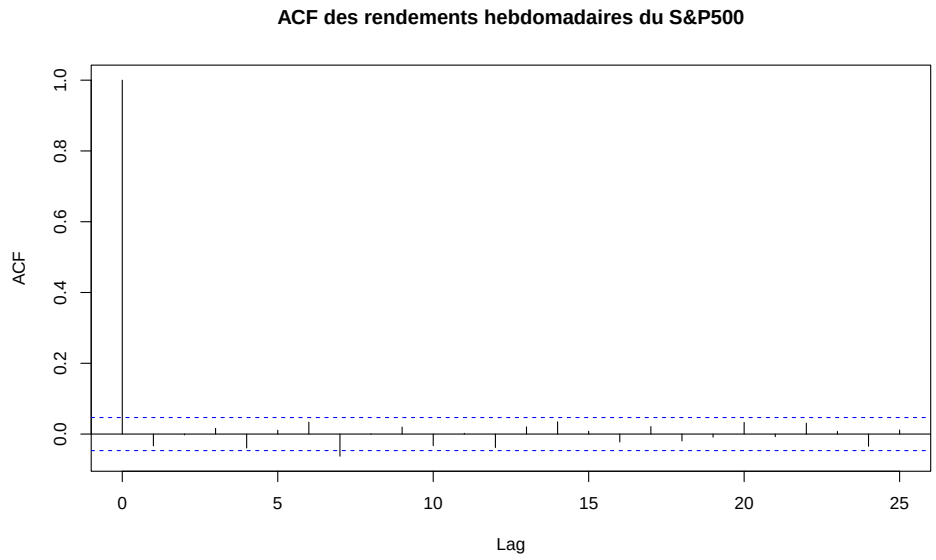


FIGURE 3 – ACF des rendements logarithmiques hebdomadaires du S&P 500.

Le test de Ljung–Box nous donne :

$$\boxed{p = 0{,}0788 \quad \text{pour } h = 12.}$$

Au seuil de 5% qu'on utilisera comme référence, on ne rejette pas l'hypothèse d'absence d'autocorrélation : les rendements se comportent comme un bruit blanc en moyenne. Le correlogramme de r_t confirme ce résultat : la plupart des pics restent dans les bandes de confiance.

La p-value est supérieure à 5 %, ce qui signifie qu'on ne trouve pas de structure linéaire dans les rendements. Cela correspond bien au fait stylisé selon lequel les rendements sont difficiles à prédire à partir de leurs propres valeurs passées.

Rendements au carré autocorrélés

Pour analyser comment la volatilité évolue, on va regarder ensuite la dépendance des puissances des rendements, en particulier les **carrés** r_t^2.

On considère la série $\{r_t^2\}$, représentée sur la Figure 4.

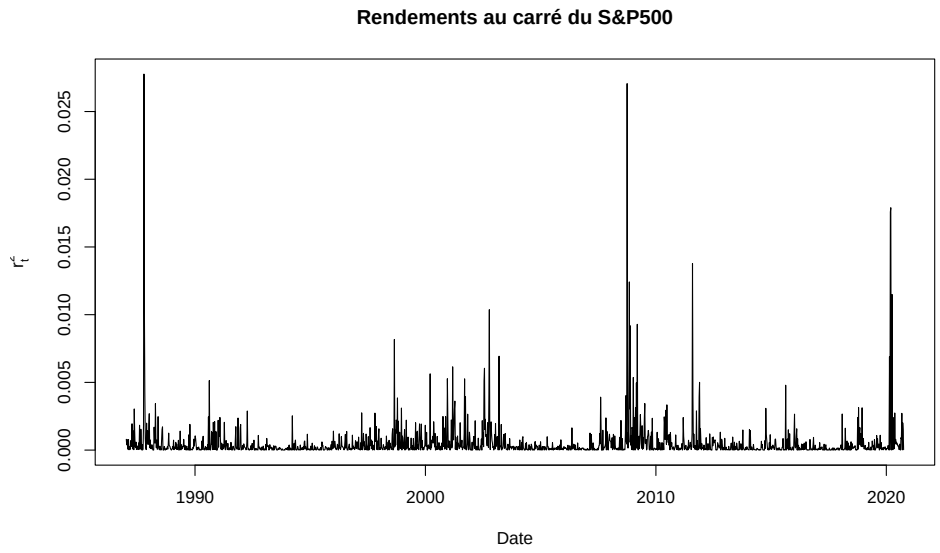


FIGURE 4 – Rendements au carré r_t^2 de l'indice S&P 500.

On observe des périodes de forte volatilité (pics de r_t^2) assez regroupées, alternant avec des périodes calmes, ce qui suggère une dépendance de la variance dans le temps.

On applique le test de Ljung–Box à la série $\{r_t^2\}$. Si l'on note $\hat{\rho}_k(r^2)$ l'autocorrélation empirique de r_t^2 au lag k, la statistique associée est de la même forme :

$$Q_{r^2}(h) = T(T+2)\sum_{k=1}^{h}\frac{\hat{\rho}_k(r^2)^2}{T-k} \approx \chi^2_h \quad \text{sous } H_0.$$

Le correlogramme de r_t^2 (Figure 5) montre des autocorrélations positives et significatives qui décroissent lentement avec le retard, ce qui représnte bien l'idée d'un clustering de volatilité.

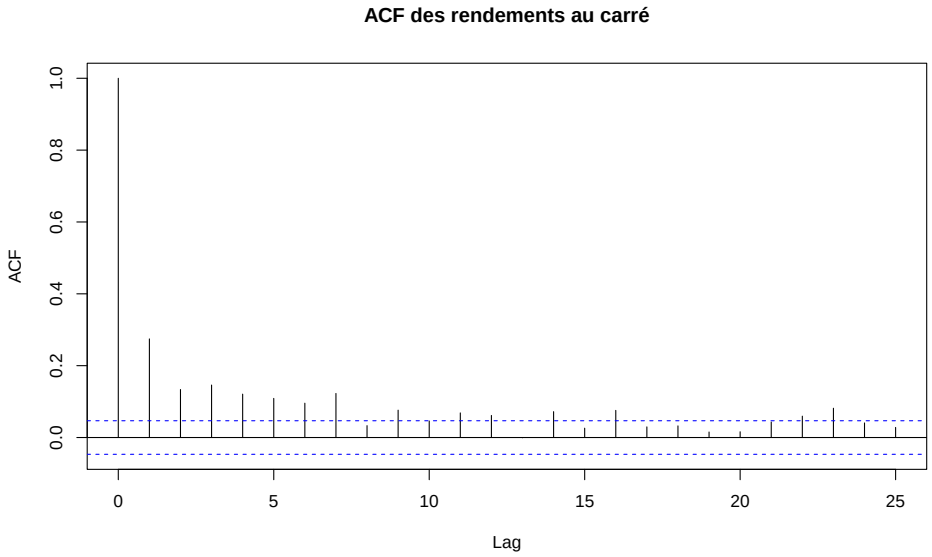


FIGURE 5 – ACF des rendements au carré r_t^2 de l'indice S&P 500.

Le test de Ljung–Box sur r_t^2 à $h = 12$ donne une p-value

$$\boxed{p < 2{,}2 \times 10^{-16}},$$

ce qui indique des autocorrélations très significatives des carrés des rendements. Le correlogramme de r_t^2 décroît lentement : phénomène de clustering : les chocs de volatilité ont tendance à persister (périodes de forte variance suivies d'autres périodes de forte variance, et inversement pour les périodes calmes).

Ces résultats montrent bien que même si les rendements sont peu autocorrélés, on constate une évolution lente de la variance, ce que des modèles à variance conditionnelle (ARCH/GARCH) sont précisément conçus pour représenter.

Rendements absolus autocorrélés

Le même constat vaut pour les valeurs absolues des rendements. En posant $|r_t|$ comme autre proxy de la volatilité, on considère la série $\{|r_t|\}$, illustrée par la Figure 6.

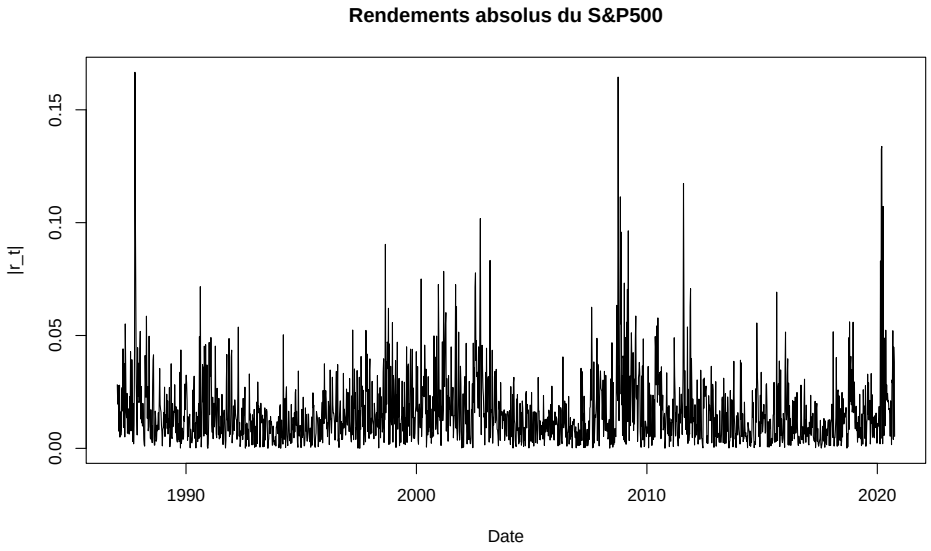


FIGURE 6 – Rendements absolus $|r_t|$ de l'indice S&P 500.

On applique de nouveau le test de Ljung–Box (toujours $h = 12$) à cette série. Le correlogramme (Figure 7) présente des autocorrélations très fortes, décroissant plus lentement encore que pour r_t^2.

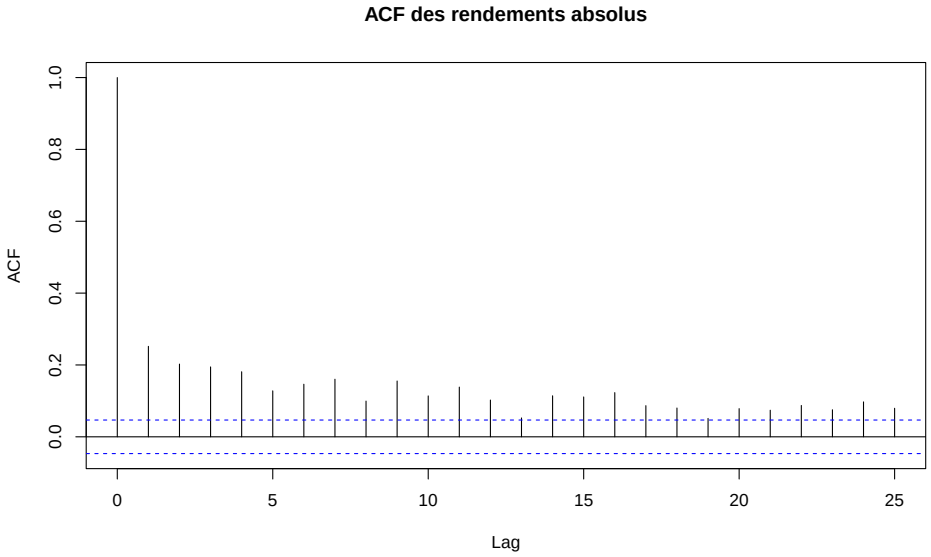


FIGURE 7 – ACF des rendements absolus $|r_t|$ de l'indice S&P 500.

On obtient alors la p-value

$$\boxed{p < 2{,}2 \times 10^{-16}},$$

extrêmement faible. L'autocorrélation de $|r_t|$ est donc **fortement significative**, et l'ACF de $|r_t|$ montre une décroissance encore plus lente que celle de r_t^2, renforçant l'idée d'une **mémoire dans la volatilité**.

On voit donc que, selon la transformation appliquée aux rendements (niveau, carré, valeur absolue), on a des propriétés très différentes : bruit blanc en moyenne pour r_t, mais forte dépendance dans les mesures de volatilité.

Synthèse

Les quatre faits stylisés demandés sont observés sur les données S&P 500 hebdomadaires (1987–2020) :

1. **Stationnarité des rendements** (ADF significatif) :

$$\boxed{\text{ADF} = -16{,}557, \quad p = 1{,}92 \times 10^{-29}}.$$

2. **Absence d'autocorrélation linéaire en moyenne** (Ljung–Box sur r_t non significatif au seuil 5 %) :

$$\boxed{p_{\text{LB}}(r_t, h = 12) = 0{,}0788}.$$

3. **Autocorrélations des carrés des rendements** :

$$\boxed{p_{\text{LB}}(r_t^2, h = 12) < 2{,}2 \times 10^{-16}}.$$

4. **Autocorrélations des valeurs absolues** :

$$\boxed{p_{\text{LB}}(|r_t|, h = 12) < 2{,}2 \times 10^{-16}}.$$

On a donc une série qui admet un bruit blanc en moyenne (pas d'autocorrélation linéaire) mais hétéroscédastique en variance.

Exercice 2

On considère le modèle ARCH(1)

$$x_t = \sqrt{\omega_t}\,\varepsilon_t, \qquad \omega_t = \alpha_0 + \alpha_1 x_{t-1}^2, \qquad \varepsilon_t \sim \mathcal{N}(0, 1).$$

Dans tout cet exercice, on travaille sur la série des rendements de l'exercice 1.

Moyenne des rendements logarithmiques

On note P_t le cours ajusté (`Adj.Close`) et

$$r_t = \log P_t - \log P_{t-1}.$$

La moyenne empirique sur la période vaut

$$\bar{r} = \frac{1}{T}\sum_{t=1}^{T} r_t = \boxed{0{,}001466957} \approx 0{,}1467\% \text{ par semaine.}$$

Cette moyenne positive reste faible par rapport à la volatilité hebdomadaire, mais elle n'est pas nulle et doit donc être prise en compte lors de la spécification du modèle.

Transformation du modèle

Le modèle ARCH(1) ci-dessus impose une **moyenne conditionnelle nulle**. En effet,

$$x_t = \sqrt{\omega_t}\,\varepsilon_t, \qquad \varepsilon_t \sim \mathcal{N}(0,1), \quad \mathbb{E}(\varepsilon_t) = 0.$$

Comme ω_t est $\mathcal{I}_{t-1}$-mesurable, on a

$$\begin{aligned}\mathbb{E}(x_t \mid \mathcal{I}_{t-1}) &= \mathbb{E}(\sqrt{\omega_t}\,\varepsilon_t \mid \mathcal{I}_{t-1}) \\ &= \sqrt{\omega_t}\,\mathbb{E}(\varepsilon_t \mid \mathcal{I}_{t-1}) \\ &= \sqrt{\omega_t}\,\mathbb{E}(\varepsilon_t) \\ &= \sqrt{\omega_t} \times 0 = 0.\end{aligned}$$

Donc

$$\mathbb{E}(x_t) = \mathbb{E}\big[\mathbb{E}(x_t \mid \mathcal{I}_{t-1})\big] = 0.$$

Or la série de rendements $\{r_t\}$ a une moyenne non nulle $\bar{r}$. Pour rendre le modèle compatible avec les données, on recentre :

$$\boxed{x_t \equiv r_t - \bar{r}},$$

de sorte que

$$\mathbb{E}(x_t \mid \mathcal{I}_{t-1}) = \mathbb{E}(r_t - \bar{r} \mid \mathcal{I}_{t-1}) = \mathbb{E}(r_t \mid \mathcal{I}_{t-1}) - \bar{r} = 0,$$

et que la dynamique de variance conditionnelle reste

$$\omega_t = \alpha_0 + \alpha_1 x_{t-1}^2.$$

Équivalent :

$$r_t = \mu + \sqrt{\omega_t}\,\varepsilon_t, \quad \mu = \bar{r}, \quad \omega_t = \alpha_0 + \alpha_1 (r_{t-1} - \mu)^2.$$

Autrement dit, on retire simplement la moyenne empirique de la série avant d'appliquer le modèle ARCH.

Vraisemblance et log-vraisemblance

Sous la normalité conditionnelle,

$$x_t \mid \mathcal{I}_{t-1} \sim \mathcal{N}(0, \omega_t), \qquad \omega_t = \alpha_0 + \alpha_1 x_{t-1}^2.$$

La densité d'une loi normale $\mathcal{N}(m, \sigma^2)$ en x est

$$\phi(x; m, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-m)^2}{2\sigma^2}\right).$$

Ici $m = 0$ et $\sigma^2 = \omega_t$, donc la densité conditionnelle est

$$f(x_t \mid \mathcal{I}_{t-1}; \alpha_0, \alpha_1) = \frac{1}{\sqrt{2\pi\,\omega_t}} \exp\left(-\frac{x_t^2}{2\,\omega_t}\right).$$

En conditionnant sur $\tilde{x}_1$, la **vraisemblance conditionnelle** est le produit des densités pour $t = 2, \dots, T$:

$$\begin{aligned} L(\alpha_0, \alpha_1 \mid x_2, \dots, x_T; \tilde{x}_1) &= \prod_{t=2}^{T} f(x_t \mid \mathcal{I}_{t-1}; \alpha_0, \alpha_1) \\ &= \prod_{t=2}^{T} \left[\frac{1}{\sqrt{2\pi\,\omega_t}} \exp\left(-\frac{x_t^2}{2\,\omega_t} \right) \right]. \end{aligned}$$

On peut séparer le produit en deux parties (terme de normalisation et terme exponentiel) :

$$L(\alpha_0, \alpha_1 \mid x_2, \dots, x_T; \tilde{x}_1) = \left(\prod_{t=2}^{T} \frac{1}{\sqrt{2\pi\,\omega_t}} \right) \times \left(\prod_{t=2}^{T} \exp\left(-\frac{x_t^2}{2\,\omega_t} \right) \right),$$

avec

$$\omega_t = \alpha_0 + \alpha_1 x_{t-1}^2.$$

On obtient ainsi la forme compacte :

$$\boxed{L(\alpha_0, \alpha_1 \mid x_2, \dots, x_T; \tilde{x}_1) = \prod_{t=2}^{T} \frac{1}{\sqrt{2\pi\,\omega_t}} \exp\left(-\frac{x_t^2}{2\,\omega_t} \right), \quad \omega_t = \alpha_0 + \alpha_1 x_{t-1}^2.}$$

La **log-vraisemblance** associée est

$$\ell(\alpha_0, \alpha_1) = \log L(\alpha_0, \alpha_1 \mid x_2, \dots, x_T; \tilde{x}_1) = \sum_{t=2}^{T} \log f(x_t \mid \mathcal{I}_{t-1}; \alpha_0, \alpha_1).$$

On développe :

$$\begin{aligned} \log f(x_t \mid \mathcal{I}_{t-1}; \alpha_0, \alpha_1) &= \log\left(\frac{1}{\sqrt{2\pi\,\omega_t}} \exp\left(-\frac{x_t^2}{2\,\omega_t} \right) \right) \\ &= \log\left(\frac{1}{\sqrt{2\pi\,\omega_t}} \right) + \log\left(\exp\left(-\frac{x_t^2}{2\,\omega_t} \right) \right) \\ &= -\frac{1}{2} \log(2\pi\,\omega_t) - \frac{x_t^2}{2\,\omega_t} \\ &= -\frac{1}{2} \log(2\pi) - \frac{1}{2} \log(\omega_t) - \frac{x_t^2}{2\,\omega_t}. \end{aligned}$$

En sommant sur t,

$$\begin{aligned} \ell(\alpha_0, \alpha_1) &= \sum_{t=2}^{T} \left[-\frac{1}{2} \log(2\pi) - \frac{1}{2} \log(\omega_t) - \frac{x_t^2}{2\,\omega_t} \right] \\ &= -\frac{1}{2} \sum_{t=2}^{T} \log(2\pi) - \frac{1}{2} \sum_{t=2}^{T} \log(\omega_t) - \frac{1}{2} \sum_{t=2}^{T} \frac{x_t^2}{\omega_t} \\ &= -\frac{T-1}{2} \log(2\pi) - \frac{1}{2} \sum_{t=2}^{T} \log(\omega_t) - \frac{1}{2} \sum_{t=2}^{T} \frac{x_t^2}{\omega_t}. \end{aligned}$$

On obtient ainsi :

$$\boxed{\ell(\alpha_0, \alpha_1) = \log L = -\frac{1}{2}\sum_{t=2}^{T}\left[\log(2\pi) + \log\omega_t + \frac{x_t^2}{\omega_t}\right], \quad \omega_t = \alpha_0 + \alpha_1 x_{t-1}^2.}$$

Avec : $\alpha_0 > 0$, $0 \leq \alpha_1 < 1$.

Cette log-vraisemblance est la base de l'estimation par maximum de vraisemblance dans les fonctions d'estimation de type `garchFit`. Les logiciels statistiques, nous permettent d'éviter ce calcul de cette vraisembance grâce à des packages.

Moments non conditionnels

Estimation des paramètres. On maximise $\ell(\alpha_0, \alpha_1)$ sur la série centrée $x_t = r_t - \bar{r}$ à l'aide de `garchFit` . L'estimation donne :

$$\boxed{\widehat{\alpha}_0 = 3{,}789 \times 10^{-4}}, \qquad \boxed{\widehat{\alpha}_1 = 0{,}288233}.$$

Ces valeurs estimées vérifient bien les contraintes du modèle ($\widehat{\alpha}_0 > 0$, $0 \leq \widehat{\alpha}_1 < 1$), ce qui permet de définir des moments finis d'ordre au moins 2.

Formules générales. On note, pour tout entier $r \geq 1$,

$$m_{2r} = \mathbb{E}(x_t^{2r}).$$

Moment d'ordre 2.
On a

$$x_t = \sqrt{\omega_t}\,\varepsilon_t \quad \Longrightarrow \quad x_t^2 = \omega_t\,\varepsilon_t^2.$$

Conditionnellement à $\mathcal{I}_{t-1}$,

$$\mathbb{E}(x_t^2 \mid \mathcal{I}_{t-1}) = \mathbb{E}(\omega_t\varepsilon_t^2 \mid \mathcal{I}_{t-1}) = \omega_t\,\mathbb{E}(\varepsilon_t^2) = \omega_t \times 1 = \omega_t,$$

car $\varepsilon_t \sim \mathcal{N}(0,1)$ implique $\mathbb{E}(\varepsilon_t^2) = 1$.

En prenant l'espérance non conditionnelle,

$$\begin{aligned} m_2 = \mathbb{E}(x_t^2) &= \mathbb{E}\big[\mathbb{E}(x_t^2 \mid \mathcal{I}_{t-1})\big] \\ &= \mathbb{E}(\omega_t) \\ &= \mathbb{E}(\alpha_0 + \alpha_1 x_{t-1}^2) \\ &= \alpha_0 + \alpha_1\mathbb{E}(x_{t-1}^2). \end{aligned}$$

Sous stationnarité, $\mathbb{E}(x_{t-1}^2) = \mathbb{E}(x_t^2)$, donc

$$\mathbb{E}(x_t^2) = \alpha_0 + \alpha_1\mathbb{E}(x_t^2) \quad \Longleftrightarrow \quad \mathbb{E}(x_t^2)(1-\alpha_1) = \alpha_0 \quad \Longleftrightarrow \quad \mathbb{E}(x_t^2) = \frac{\alpha_0}{1-\alpha_1}.$$

On retrouve ainsi :

$$\boxed{\mathbb{E}(x_t^2) = \frac{\alpha_0}{1-\alpha_1} \quad \text{(existe si } \alpha_1 < 1).}$$

Condition générale d'existence du moment d'ordre $2r$.
De façon générale,

$$\begin{aligned}\mathbb{E}(x_t^{2r} \mid \mathcal{I}_{t-1}) &= \mathbb{E}(\omega_t^r \varepsilon_t^{2r} \mid \mathcal{I}_{t-1}) \\ &= \omega_t^r \, \mathbb{E}(\varepsilon_t^{2r} \mid \mathcal{I}_{t-1}) \quad \text{car } \omega_t \in \mathcal{I}_{t-1} \\ &= \omega_t^r \, \mathbb{E}(\varepsilon_t^{2r}) \quad \text{car } (\varepsilon_t) \text{ est i.i.d.}\end{aligned}$$

$$\mathbb{E}(\varepsilon_t^{2r}) = \prod_{j=1}^{r}(2j-1), \qquad \text{avec } \sigma^2 = 1 \text{ et } \varepsilon_t \sim \mathcal{N}(0,1).$$

On remplace ω_t^r et ε_t^{2r} :

$$\mathbb{E}(x_t^{2r} \mid \mathcal{I}_{t-1}) = (\alpha_0 + \alpha_1 x_{t-1}^2)^r \prod_{j=1}^{r}(2j-1).$$

Le moment d'ordre 2r du processus ARCH(1) existe si et seuelement si

$$\boxed{\alpha_1^r \prod_{j=1}^{r}(2j-1) < 1.}$$

Moment d'ordre 4.

Pour r = 2 :

$$\begin{aligned}\mathbb{E}(x_t^4 \mid \mathcal{I}_{t-1}) &= (\alpha_0 + \alpha_1 x_{t-1}^2)^2 \, (2 \times 2 - 1) \\ &= 3(\alpha_0 + \alpha_1 x_{t-1}^2)^2.\end{aligned}$$

$$\begin{aligned}\mathbb{E}(x_t^4 \mid \mathcal{I}_{t-1}) &= 3(\alpha_0^2 + 2\alpha_0\alpha_1 x_{t-1}^2 + \alpha_1^2 x_{t-1}^4) \\ &= 3\alpha_0^2 + 6\alpha_0\alpha_1 x_{t-1}^2 + 3\alpha_1^2 x_{t-1}^4.\end{aligned}$$

Remplacons par les espérances dans notre expression :

$$\mathbb{E}(x_t^4) = 3\alpha_0^2 + 6\alpha_0\alpha_1 \mathbb{E}(x_t^2) + 3\alpha_1^2 \mathbb{E}(x_t^4).$$

$$\mathbb{E}(x_t^4) - 3\alpha_1^2 \mathbb{E}(x_t^4) = 3\alpha_0^2 + 6\alpha_0\alpha_1 \mathbb{E}(x_t^2).$$

$$\mathbb{E}(x_t^4)(1 - 3\alpha_1^2) = 3\alpha_0^2 + 6\alpha_0\alpha_1 \mathbb{E}(x_t^2).$$

$$\mathbb{E}(x_t^4) = \frac{3\alpha_0^2 + 6\alpha_0\alpha_1\,\mathbb{E}(x_t^2)}{1 - 3\alpha_1^2}.$$

On sait que :

$$\mathbb{E}(x_t^2) = \frac{\alpha_0}{1 - \alpha_1}.$$

Donc :

$$\mathbb{E}(x_t^4) = \frac{3\alpha_0^2 + (6\alpha_0^2\alpha_1/(1 - \alpha_1))}{1 - 3\alpha_1^2}.$$

Pour le numérateur :

$$3\alpha_0^2 + (6\alpha_0^2\alpha_1/(1 - \alpha_1)) <=> \frac{3\alpha_0^2(1 - \alpha_1) + 6\alpha_0^2\alpha_1}{1 - \alpha_1}.$$

Ainsi :

$$\mathbb{E}(x_t^4) = \frac{3\alpha_0^2(1 - \alpha_1) + 6\alpha_0^2\alpha_1}{(1 - \alpha_1)(1 - 3\alpha_1^2)}.$$

$$3\alpha_0^2\big[(1 - \alpha_1) + 2\alpha_1\big] = 3\alpha_0^2(1 + \alpha_1).$$

Finalement :

$$\mathbb{E}(x_t^4) = \frac{3\alpha_0^2(1 + \alpha_1)}{(1 - \alpha_1)(1 - 3\alpha_1^2)}.$$

Pour coller à l'expression dans le devoir ;

$$1 + \lambda_1 \;=\; \frac{1 - \lambda_1^2}{1 - \lambda_1}.$$

On a donc :

$$\boxed{\mathbb{E}(x_t^4) = \frac{3\,\alpha_0^2\,(1 - \alpha_1^2)}{(1 - \alpha_1)^2\,(1 - 3\alpha_1^2)} \quad \text{(existe si } 3\alpha_1^2 < 1\text{).}}$$

Valeurs numériques. Avec $\widehat{\alpha}_0, \widehat{\alpha}_1$, on obtient pour le second moment :

$$\mathbb{E}(x_t^2) = \frac{\widehat{\alpha}_0}{1 - \widehat{\alpha}_1} = \frac{3{,}789 \times 10^{-4}}{1 - 0{,}288233} \approx 5{,}323 \times 10^{-4},$$

soit un résultat théorique :

$$\boxed{\mathbb{E}(x_t^2) \approx 5{,}323 \times 10^{-4}}.$$

Pour le moment d'ordre 2, on a $r = 1$ et

$$(2r - 1)!! = (2 \times 1 - 1)!! = 1.$$

La condition d'existence du moment d'ordre $2r$ dans un ARCH(1) est

$$(2r - 1)!!\,\alpha_1^r < 1.$$

Pour $r = 1$, elle devient simplement

$$1 \times \widehat{\alpha}_1 = 0{,}288233 < 1,$$

donc le moment d'ordre 2 existe bien sous le modèle estimé.

Par la suite, nous utiliserons les résultats de notre logiciel pour indiquer le résultat de l'espérance, qui sera assez proche de la théorie malgré quelques fluctuations. Notre logiciel pour le résultat précédent nous donne :

$$\boxed{\mathbb{E}(x_t^2) \approx 5{,}239 \times 10^{-4}}.$$

C'est normal que ce ne soit pas pareil car on se base ici sur des données réelles.

Pour le moment d'ordre 4, on utilise la formule explicite

$$\mathbb{E}(x_t^4) = \frac{3\,\alpha_0^2\,(1-\alpha_1^2)}{(1-\alpha_1)^2\,(1-3\alpha_1^2)}.$$

En remplaçant α_0, α_1 par leurs estimateurs, on obtient :

$$\boxed{\mathbb{E}(x_t^4) \approx 2{,}592 \times 10^{-6}}.$$

Pour l'existence du moment d'ordre 4, on prend $r = 2$, donc

$$(2r-1)!! = (2 \times 2 - 1)!! = 3,$$

et la condition devient

$$3\,\widehat{\alpha}_1^2 \approx 3 \times 0{,}0831 \approx 0{,}2492 < 1,$$

ce qui garantit que le moment d'ordre 4 existe.

Les moments d'ordres 6 et 8 se calculent de la même façon. On obtient :

$$\boxed{\begin{aligned}&\mathbb{E}(x_t^6) \approx 4{,}026 \times 10^{-8},\\ &\mathbb{E}(x_t^8) \approx 8{,}950 \times 10^{-10}.\end{aligned}}$$

Pour $r = 3$ (moment d'ordre 6), on a

$$(2r-1)!! = (2 \times 3 - 1)!! = 5 \times 3 \times 1 = 15,$$

et

$$15\,\widehat{\alpha}_1^3 \approx 15 \times 0{,}0239 \approx 0{,}3592 < 1,$$

ce qui assure l'existence du moment d'ordre 6.

Pour $r = 4$ (moment d'ordre 8), on a

$$(2r-1)!! = (2 \times 4 - 1)!! = 7 \times 5 \times 3 \times 1 = 105,$$

et

$$105\,\widehat{\alpha}_1^4 \approx 105 \times 0{,}0069 \approx 0{,}7247 < 1,$$

donc le moment d'ordre 8 existe également.

Pour l'ordre 10, on regarde d'abord la condition :

$$(2r-1)!! = (2\times 5-1)!! = 9\times 7\times 5\times 3\times 1 = 945,$$

et donc

$$945\,\widehat{\alpha}_1^5 \approx 1{,}880 > 1.$$

La condition

$$(2r-1)!!\,\alpha_1^r < 1$$

n'est donc plus vérifiée pour $r=5$, d'où

$$\boxed{\mathbb{E}(x_t^{10}) \text{ n'existe pas.}}$$

Ces résultats montrent que plus α_1 est élevé, plus les moments d'ordre élevé risquent d'être supérieur à 1 : ici, les moments jusqu'à l'ordre 8 existent, mais le moment d'ordre 10 n'est plus défini sous le modèle.

Exercice 3

On considère le modèle :

$$\begin{cases} x_t = a_0 + a_1 x_{t-1} + \eta_t, \\ \eta_t = \sqrt{\omega_t}\,\varepsilon_t, \\ \omega_t = \alpha_0 + \alpha_1 \eta_{t-1}^2 + \alpha_2 \omega_{t-1}, \\ \varepsilon_t \sim \mathcal{N}(0,1), \end{cases}$$

avec $\theta = (a_0, a_1, \alpha_0, \alpha_1, \alpha_2)'$ et contraintes $\alpha_0 > 0$, $\alpha_1 \geq 0$, $\alpha_2 \geq 0$, $\alpha_1 + \alpha_2 < 1$.

Ce modèle mélange d'une part un AR(1) pour la moyenne et un GARCH(1,1) pour la variance. Ce modèle va prendre en compte une dépendance dans les rendements et une forte persistance dans la volatilité, c'est ce qu'on observe souvent en finance.

0.1 Vraisemblance conditionnelle

On définit $\mathcal{I}_{t-1} = \{x_1, \ldots, x_{t-1}\}$. Par construction,

$$x_t \mid \mathcal{I}_{t-1} = a_0 + a_1 x_{t-1} + \eta_t, \qquad \eta_t \mid \mathcal{I}_{t-1} \sim \mathcal{N}(0, \omega_t),$$

On pose

$$m_t \equiv a_0 + a_1 x_{t-1}, \qquad \eta_t = x_t - m_t.$$

Alors

$$x_t \mid \mathcal{I}_{t-1} \sim \mathcal{N}(m_t, \omega_t).$$

La densité conditionnelle est

$$f(x_t \mid x_{t-1}; \theta) = \frac{1}{\sqrt{2\pi\,\omega_t}} \exp\left(-\frac{(x_t - m_t)^2}{2\,\omega_t}\right) = \frac{1}{\sqrt{2\pi\,\omega_t}} \exp\left(-\frac{\eta_t^2}{2\,\omega_t}\right),$$

avec

$$\omega_t = \alpha_0 + \alpha_1 \eta_{t-1}^2 + \alpha_2 \omega_{t-1}.$$

En conditionnant sur x_1, la **vraisemblance conditionnelle** est

$$\boxed{L(\theta \mid x_2, \ldots, x_T) = \prod_{t=2}^{T} f(x_t \mid x_{t-1}; \theta) = \prod_{t=2}^{T} \frac{1}{\sqrt{2\pi\,\omega_t}} \exp\left(-\frac{\eta_t^2}{2\,\omega_t}\right).}$$

Log-vraisemblance et conditions de premier ordre

La log-vraisemblance est

$$\boxed{\ell(\theta) = \log L(\theta \mid x_2, \ldots, x_T) = -\frac{1}{2} \sum_{t=2}^{T} \left[\log(2\pi) + \log \omega_t + \frac{\eta_t^2}{\omega_t}\right],}$$

avec

$$\eta_t = x_t - a_0 - a_1 x_{t-1}, \qquad \omega_t = \alpha_0 + \alpha_1 \eta_{t-1}^2 + \alpha_2 \omega_{t-1}.$$

Pour un paramètre $\varphi \in \theta$, on a

$$\frac{\partial \ell_t}{\partial \varphi} = -\frac{1}{2}\left[\frac{1}{\omega_t}\frac{\partial \omega_t}{\partial \varphi} + \frac{\partial}{\partial \varphi}\left(\frac{\eta_t^2}{\omega_t}\right)\right].$$

Les conditions de premier ordre s'écrivent ainsi :

$$\boxed{\frac{\partial \ell(\theta)}{\partial \varphi} = \sum_{t=2}^{T} \frac{\partial \ell_t(\theta)}{\partial \varphi} = 0.}$$

En pratique, ces équations sont résolues par le logiciel. On ne cherche donc pas à obtenir une solution analytique pour les estimateurs, mais plutôt à évaluer le vecteur θ qui annule le score (ou maximise la log-vraisemblance).

Simulation du modèle avec `fGarch`

On souhaite simuler une série (x_t) de taille $T = 2520$ avec :

$$a_0 = 0{,}002, \quad a_1 = -0{,}12, \quad \alpha_0 = 0{,}000015, \quad \alpha_1 = 0{,}0414, \quad \alpha_2 = 0{,}921.$$

Sous R, on utilise le package `fGarch` pour spécifier un modèle AR(1)–GARCH(1,1) :

```
1 library(fGarch)
2
3 a0_true      <- 0.002
```

```r
a1_true     <- -0.12
alpha0_true <- 0.000015
alpha1_true <- 0.0414
alpha2_true <- 0.921

spec_sim <- garchSpec(
  model = list(
    mu     = a0_true,
    ar     = a1_true,
    omega  = alpha0_true,
    alpha1 = alpha1_true,
    beta1  = alpha2_true
  ),
  cond.dist = "norm"
)

set.seed(123)
x_sim <- garchSim(spec = spec_sim, n = 2520)
```

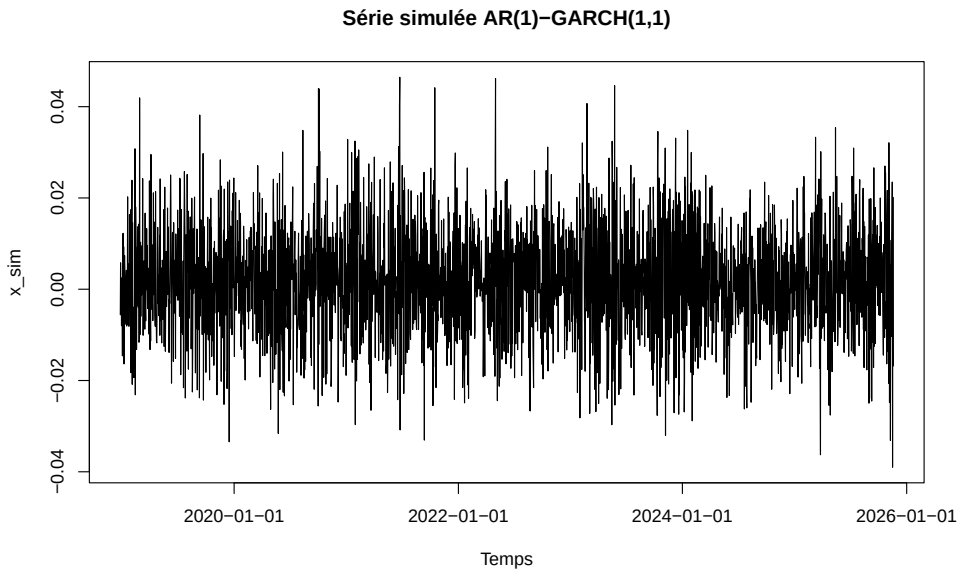


FIGURE 8 – Série simulée du modèle AR(1)–GARCH(1,1) (taille $T = 2520$).

La série simulée reproduit les mêmes caractéristiques que les rendements observés : on a des fluctuations autour d'une moyenne proche de zéro, alternance de périodes calmes et de périodes plus fortes, ce qui donne une bonne validation du modèle.

Loi des espérences itérées

On note $\mathcal{I}_{t-1}$ l'information jusqu'à $t-1$.

$$\mathbb{E}(\eta_t \mid \mathcal{I}_{t-1}) = \mathbb{E}(\sqrt{\omega_t}\varepsilon_t \mid \mathcal{I}_{t-1}) = \sqrt{\omega_t}\,\mathbb{E}(\varepsilon_t) = 0.$$

Par la loi des espérances itérées,

$$\mathbb{E}(\eta_t x_{t-k}) = \mathbb{E}\big[\mathbb{E}(\eta_t x_{t-k} \mid \mathcal{I}_{t-1})\big] = \mathbb{E}\big[x_{t-k}\,\mathbb{E}(\eta_t \mid \mathcal{I}_{t-1})\big] = \mathbb{E}(x_{t-k} \cdot 0) = 0.$$

Donc

$$\boxed{\forall k \geq 1, \quad \mathbb{E}(\eta_t x_{t-k}) = 0.}$$

Le choc η_t est non corrélé avec les valeurs passées de la série.

Variance non conditionnelle

On cherche $\mathbb{V}(x_t)$ en stationnarité.

Pour la partie GARCH(1,1), on a

$$\eta_t = \sqrt{\omega_t}\varepsilon_t, \qquad \mathbb{E}(\eta_t^2) = \mathbb{E}(\omega_t) \equiv \sigma_\eta^2.$$

En prenant l'espérance dans $\omega_t = \alpha_0 + \alpha_1 \eta_{t-1}^2 + \alpha_2 \omega_{t-1}$, on obtient

$$\mathbb{E}(\omega_t) = \alpha_0 + (\alpha_1 + \alpha_2)\mathbb{E}(\omega_{t-1}).$$

À stationnarité, $\mathbb{E}(\omega_t) = \mathbb{E}(\omega_{t-1}) = \sigma_\eta^2$, donc

$$\sigma_\eta^2 = \alpha_0 + (\alpha_1 + \alpha_2)\sigma_\eta^2 \quad \Rightarrow \quad \sigma_\eta^2(1 - \alpha_1 - \alpha_2) = \alpha_0.$$

Si $\alpha_1 + \alpha_2 < 1$,

$$\boxed{\mathbb{V}(\eta_t) = \sigma_\eta^2 = \frac{\alpha_0}{1 - \alpha_1 - \alpha_2}.}$$

Pour l'équation de moyenne AR(1),

$$x_t = a_0 + a_1 x_{t-1} + \eta_t.$$

En stationnarité,

$$\mathbb{V}(x_t) = a_1^2 \mathbb{V}(x_{t-1}) + \mathbb{V}(\eta_t) \quad \Rightarrow \quad \sigma_x^2 = a_1^2 \sigma_x^2 + \sigma_\eta^2,$$

d'où

$$\boxed{\mathbb{V}(x_t) = \frac{\mathbb{V}(\eta_t)}{1 - a_1^2} = \frac{\alpha_0}{(1 - \alpha_1 - \alpha_2)(1 - a_1^2)}.}$$

On voit donc que la variance non conditionnelle de x_t dépend de la partie volatilité $(\alpha_1 + \alpha_2)$ et de la partie moyenne $(|a_1|)$. Si ces valeurs sont proches de 1, la variance de long terme devient très grande.

Estimation sur la série S&P 500

On estime le modèle AR(1)–GARCH(1,1) sur la série de rendements hebdomadaires r_t de l'exercice 1, avec vraisemblance (pseudo-)gaussienne non conditionnelle (choix par défaut de `garchFit`) :

$$r_t = a_0 + a_1 r_{t-1} + \eta_t, \qquad \eta_t = \sqrt{\omega_t}\varepsilon_t, \qquad \omega_t = \alpha_0 + \alpha_1 \eta_{t-1}^2 + \alpha_2 \omega_{t-1}.$$

Résultat (sortie `garchFit`) :

$$\boxed{\hat{a}_0 = 0{,}0024688, \quad \hat{a}_1 = -0{,}09457, \quad \hat{\alpha}_0 = 3{,}387 \times 10^{-5}, \quad \hat{\alpha}_1 = 0{,}18921, \quad \hat{\alpha}_2 = 0{,}75695.}$$

Tous les coefficients sont significatifs (t-statistiques absolues > 3). On a

$$\hat{\alpha}_1 + \hat{\alpha}_2 \approx 0{,}946 < 1,$$

ce qui assure l'existence d'une variance non conditionnelle finie.

À partir de la formule précédente :

$$\widehat{\mathbb{V}}(\eta_t) = \frac{\hat{\alpha}_0}{1 - \hat{\alpha}_1 - \hat{\alpha}_2} \approx \boxed{6{,}29 \times 10^{-4}},$$

$$\widehat{\mathbb{V}}(r_t) = \frac{\widehat{\mathbb{V}}(\eta_t)}{1 - \hat{a}_1^2} \approx \boxed{6{,}35 \times 10^{-4}}.$$

Ces estimations montrent que la volatilité varie beaucoup dans le temps, car $\hat{\alpha}_1 + \hat{\alpha}_2$ est presque égal à 1, tandis que la moyenne bouge assez peu (coefficient $\hat{a}_1$ modéré et négatif). Le modèle correspond donc bien aux faits stylisés observés dans l'exercice 1.

Résidus standardisés

Les résidus standardisés sont définis par

$$\hat{\varepsilon}_t = \frac{\hat{\eta}_t}{\sqrt{\hat{\omega}_t}} = \frac{r_t - \hat{a}_0 - \hat{a}_1 r_{t-1}}{\sqrt{\hat{\omega}_t}},$$

Graphiquement, la série $\{\hat{\varepsilon}_t\}$ oscille autour de 0 avec une amplitude à peu près constante, ce qui correspond à un bruit blanc.

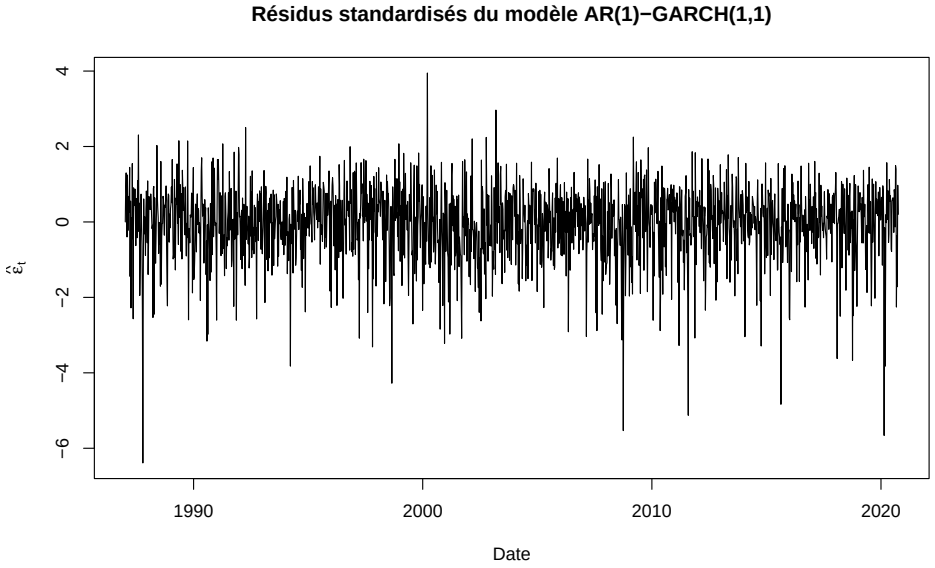


FIGURE 9 – Résidus standardisés $\hat{\varepsilon}_t$ du modèle AR(1)–GARCH(1,1) estimé.

Si le modèle décrit bien la volatilité, alors les résidus standardisés ne doivent plus montrer de périodes où la variance change fortement, contrairement aux rendements bruts.

Tests de bruit blanc

On applique la fonction d'autocorrélation et le test de Ljung–Box aux résidus standardisés et à leurs carrés. Les sorties R (pour $h = 12$) donnent :

$$\text{Ljung–Box sur } \hat{\varepsilon}_t : \quad p = \boxed{0{,}8232},$$

$$\text{Ljung–Box sur } \hat{\varepsilon}_t^2 : \quad p = \boxed{0{,}9667}.$$

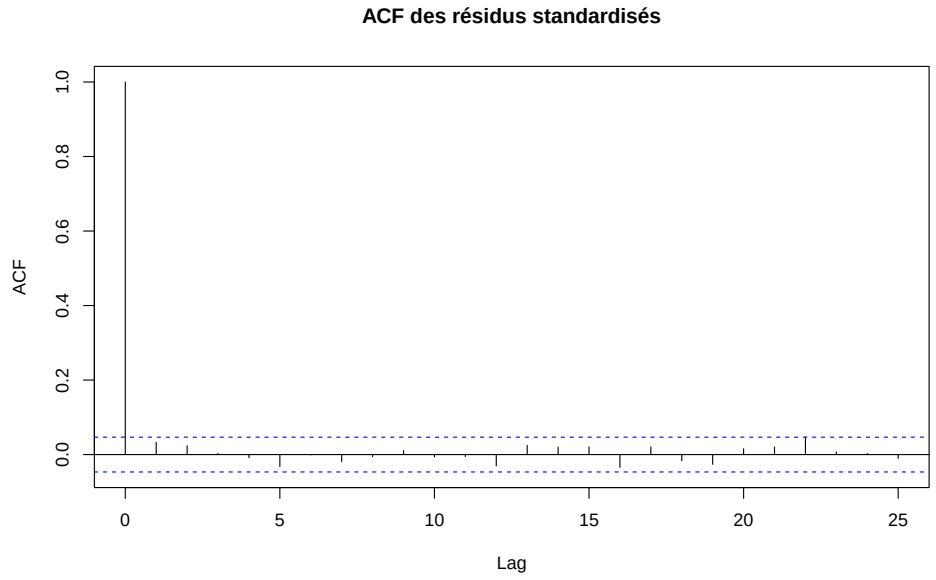


FIGURE 10 – ACF des résidus standardisés $\hat{\varepsilon}_t$.

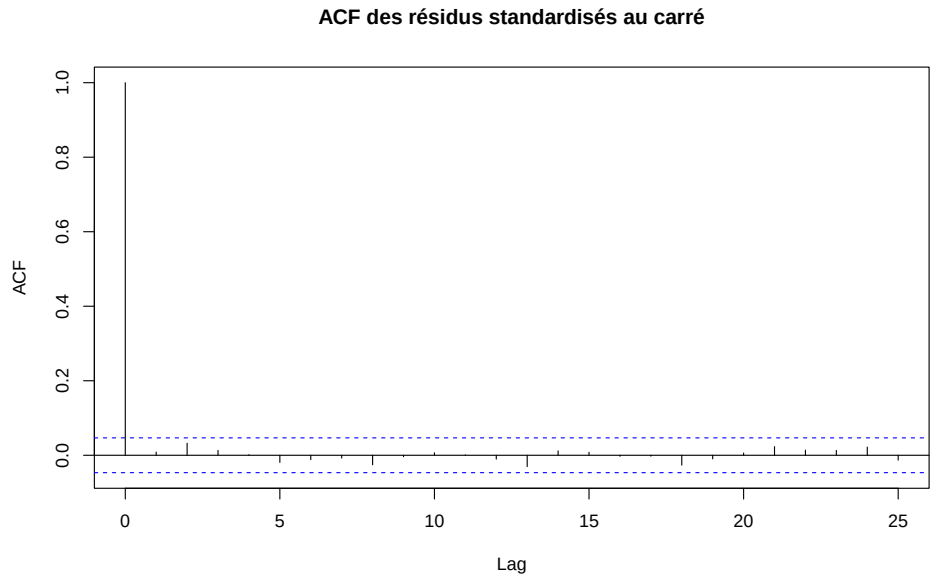


FIGURE 11 – ACF des carrés des résidus standardisés $\hat{\varepsilon}_t^2$.

On utilisera encore une fois dans nos analyses, un seuil de 5%, alors on ne rejette pas l'hypothèse d'absence d'autocorrélation, ni sur $\hat{\varepsilon}_t$, ni sur $\hat{\varepsilon}_t^2$. Le correlogramme confirme que les pics d'ACF restent dans les bandes $\pm 1{,}96/\sqrt{T}$.

Conclusion : les résidus standardisés $\hat{\varepsilon}_t$ se comportent comme un bruit blanc en moyenne *et* en variance.

Cela veut dire qu'après avoir ajusté le modèle, il ne reste plus rien de prévisible dans les données. La moyenne et la volatilité sont bien expliquées. Le modèle AR(1)–GARCH(1,1) décrit donc

correctement les rendements du S&P 500.

Annexe – Code R complet

Listing 1 – Code R complet pour les Exercices 1 à 3

```r
############################################################
## Devoir Maison - Macro conom trie 2
## Exercice 1 : faits stylis s des rendements du S&P500
## Exercice 2 : Mod le ARCH(1) et moments
## Exercice 3 : Mod le AR(1)-GARCH(1,1)
############################################################

library(tseries)

sp <- read.csv("C:/MASTER 2/Macro conom trie/SP500.csv",
               header = TRUE)
sp$Date <- as.Date(sp$Date)

############################################################
# EXERCICE 1 : faits stylis s des rendements du S&P500
############################################################

P   <- sp$Adj.Close
lsp <- log(P)
ret <- diff(lsp)          # rendements log hebdomadaires

ret2  <- ret^2            # rendements au carr
abret <- abs(ret)         # rendements absolus

# S rie du log de l'indice
plot(sp$Date, lsp, type = "l",
     xlab = "Date", ylab = "log(SP500)",
     main = "Logarithme de l'indice S&P500 (hebdomadaire)")

# S rie des rendements
plot(sp$Date[-1], ret, type = "l",
     xlab = "Date", ylab = "Rendement log",
     main = "Rendements logarithmiques hebdomadaires du S&P500")

# Test ADF sur le log de l'indice
adf.test(lsp, k = 12)

# Test ADF sur les rendements
adf.test(ret, k = 12)

# ACF + Ljung-Box des rendements
acf(ret, lag.max = 25,
    main = "ACF des rendements hebdomadaires du S&P500")
Box.test(ret, lag = 25, type = "Ljung-Box")

# Rendements au carr
plot(sp$Date[-1], ret2, type = "l",
     xlab = "Date", ylab = expression(r[t]^2),
     main = "Rendements au carr  du S&P500")
acf(ret2, lag.max = 25,
```

```r
    main = "ACF des rendements au carr ")
Box.test(ret2, lag = 25, type = "Ljung-Box")

# Rendements absolus
plot(sp$Date[-1], abret, type = "l",
     xlab = "Date", ylab = "|r_t|",
     main = "Rendements absolus du S&P500")
acf(abret, lag.max = 25,
    main = "ACF des rendements absolus")
Box.test(abret, lag = 25, type = "Ljung-Box")


############################################################
# EXERCICE 2 : Mod le ARCH(1) et moments
############################################################

# Moyenne des rendements log
mean_ret <- mean(ret)
mean_ret

# Dans la th orie ARCH() -> xt = wtet, moy = nulle
# Ici c'est tr s proche de 0, il faut quand m me centrer les rendements avant
    estimation
ret_c <- ret - mean_ret

#On peut maximiser la log-vraisemblance nous m mes, mais comme indiqu  dans le
     cours,
#cette solution est co teuse. On va utiliser ici le package tseries
arch <- garch(ret_c, order = c(0, 1))
summary(arch)

# Param tres
alpha0_hat <- coef(arch)["a0"]
alpha1_hat <- coef(arch)["a1"]
alpha0_hat
alpha1_hat

# Estimation des moments
E_x2  <- mean(ret_c^2)
E_x4  <- mean(ret_c^4)
E_x6  <- mean(ret_c^6)
E_x8  <- mean(ret_c^8)
E_x10 <- mean(ret_c^10)

c(E_x2, E_x4, E_x6, E_x8, E_x10)

# ordre 2  : alpha1 < 1
# ordre 4  : 3 alpha1^2  < 1
# ordre 6  : 15 alpha1^3 < 1
# ordre 8  : 105 alpha1^4 < 1
# ordre 10 : 945 alpha1^5 < 1

c(
  m2  = alpha1_hat,
  m4  = 3   * alpha1_hat^2,
  m6  = 15  * alpha1_hat^3,
  m8  = 105 * alpha1_hat^4,
```

```
  m10 = 945 * alpha1_hat^5
)
alpha1_hat^2
alpha1_hat^3
alpha1_hat^4
alpha1_hat^5

############################################################
# EXERCICE 3 : Mod le AR(1)-GARCH(1,1)
############################################################

library(fGarch)

# Simulation du mod le AR(1)-GARCH(1,1)

a0_true     <- 0.002
a1_true     <- -0.12
alpha0_true <- 0.000015
alpha1_true <- 0.0414
alpha2_true <- 0.921

# Sp cification
spec_sim <- garchSpec(
  model = list(
    mu     = a0_true,
    ar     = a1_true,
    omega  = alpha0_true,
    alpha1 = alpha1_true,
    beta1  = alpha2_true
  ),
  cond.dist = "norm"
)

set.seed(123)
x_sim <- garchSim(spec = spec_sim, n = 2520)

plot(x_sim, type = "l",
     main = "S rie simul e AR(1)-GARCH(1,1)",
     ylab = "x_sim", xlab = "Temps")


# Estimation AR(1)-GARCH(1,1) sur les rendements S&P500

mod_garch <- garchFit(
  formula   = ~ arma(1, 0) + garch(1, 1),
  data      = ret,
  cond.dist = "norm",
  trace     = FALSE
)

summary(mod_garch)

# Coefficients
coef(mod_garch)

coefs        <- coef(mod_garch)
a0_hat_g     <- coefs["mu"]
```

```r
a1_hat_g     <- coefs["ar1"]
alpha0_hat_g <- coefs["omega"]
alpha1_hat_g <- coefs["alpha1"]
alpha2_hat_g <- coefs["beta1"]

a0_hat_g
a1_hat_g
alpha0_hat_g
alpha1_hat_g
alpha2_hat_g

phi_hat <- alpha1_hat_g + alpha2_hat_g
phi_hat

# Variance non conditionnelle

var_eta_hat <- alpha0_hat_g / (1 - alpha1_hat_g - alpha2_hat_g)
var_r_hat <- var_eta_hat / (1 - a1_hat_g^2)

var_eta_hat
var_r_hat

# R sidus standardis s et graphiques
eps_hat  <- residuals(mod_garch, standardize = TRUE)
eps_hat2 <- eps_hat^2

plot(sp$Date[-1], eps_hat, type = "l",
     main = "R sidus standardis s du mod le AR(1)-GARCH(1,1)",
     xlab = "Date", ylab = expression(hat(epsilon)[t]))

# ACF des r sidus standardis s
acf(eps_hat, lag.max = 25,
    main = "ACF des r sidus standardis s")

# ACF des r sidus standardis s au carr
acf(eps_hat2, lag.max = 25,
    main = "ACF des r sidus standardis s au carr ")


# Tests de Ljung-Box
Box.test(eps_hat, lag = 12, type = "Ljung-Box")
Box.test(eps_hat2, lag = 12, type = "Ljung-Box")
```