Devoir Microéconométrie

Pichon François

Pot Julien

Question 1 :

Nous avons à notre disposition une base de données d'enquête sur les ménages français. Elle se compose de 21 variables représentant des informations sociodémographiques, sur les revenus ou encore sur le travail. L'échantillon compte 19461 observations et on ne retrouve que des femmes en âge de travailler (l'âge minimal est de 16 ans et l'âge maximal est de 65 ans).

Certaines variables manquent d'observations sur certaines sous-population. Nous ne sommes pas ici sur un réel problème de données manquantes mais ces non-observations sont en fait non pertinentes. Prenons l'exemple donc de *nsexe* (sexe de l'individu) qui n'est disponible que pour les femmes (codés 2 dans notre échantillon). Pour *mdiploc* on a une observation seulement pour les femmes vivant en couple. On sait aussi que dans *part_time,* le temps de travail n'est observé que pour les femmes ayant un emploi et non observé pour les sans-emploi ou auto-entrepreneuses

On a donc une structure pour la décision de participation et une autre structure qui vient ensuite, pour l'observation du salaire, les caractéristiques liés à l'emploi.

Le salaire va être défini par :

$$wage_i^* = X_i\beta + \varepsilon_i,$$

qui n'est observée que si la femme est sur le marché du travail. Le salaire observé sera alors :

$$wage_i = \begin{cases} wage_i^* & \text{si } employed_i = 1, \\ \text{non observé} & \text{si } employed_i = 0. \end{cases}$$

Les absences d'observations ne peuvent donc pas être remplacées par des zéros dans notre échantillon. Cela introduirait un biais. On est sur un mécanisme de sélection.

Rentrons donc dans l'analyse des variables :

Avant de présenter les statistiques descriptives et les graphiques, il est nécessaire de préciser quelles variables sont retenues dans l'analyse et pour quelles raisons. Le but est vraiment d'identifier, selon la théorie, les variables qui semblent fort pertinentes pour l'analyse de la participation au marché du travail et du salaire.

Les variables retenues sont l'âge (*nag*), la situation familiale avec des variables dichotomiques (*couple* et *child*), le niveau de diplôme de la femme (*ndiplo*) et le type de zone géographique (*tu99*). Ces variables sont bien définies pour l'ensemble de l'échantillon.

Certaines variables présentes dans la base sont beaucoup plus complexes à utiliser. C'est le cas des variables présentant un nombre important de valeurs non observées, comme *nrtns*, qui comporte 18 605 valeurs non observées, ce qui signifie qu'elle n'est renseignée que pour une très faible partie de l'échantillon. Certaines variables ont une interprétation économique moins directe concernant la

participation au travail ou encore le salaire, comme *qex*. D'autres variables vont être assez redondantes, comme *mtyad*, qui combine des informations déjà données par les variables *couple* et *child* qui sont des dichotomiques que l'on a créer pour faciliter les interprétations.

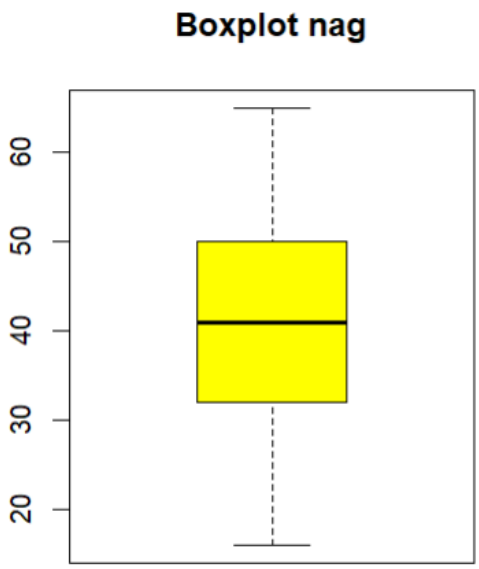
L'objectif ici n'est pas d'obtenir le meilleur modèle mais d'avoir des résultats fiables et interprétables.

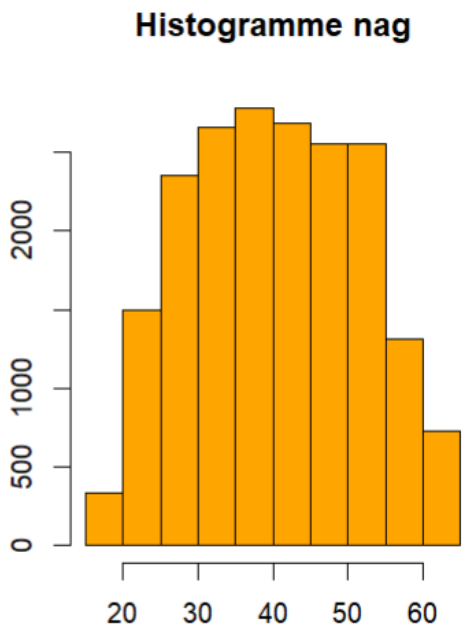
Passons donc aux analyses univariées :

La fonction *describe* de R peut déjà nous donner un aperçu des statistiques de base pour chaque variable. On peut donc observer leur nombre d'observations disponibles, nombre de valeurs non observées, valeurs prises par les variables, dispersion et présence éventuelle de valeurs extrêmes.

On complétera les descriptions par quelques graphiques.

La variable *nag* est observée pour l'ensemble des individus, sans valeurs manquantes. L'âge varie entre 16 et 65 ans, avec une moyenne d'environ 41 ans. La distribution est relativement régulière, ce qui en fait une variable pertinente pour les analyses.



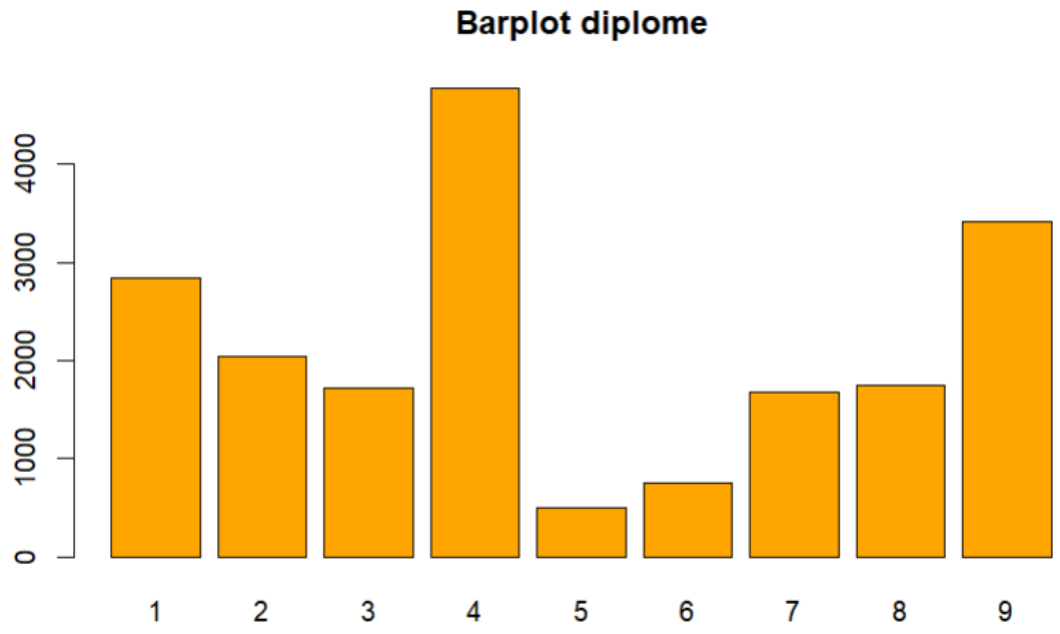


Les variables décrivant la situation familiale (*mmatri*, *nmatri*, *ncohab*, *married*) ne présentent pas de valeurs manquantes. Elles montrent que la majorité des femmes vivent en couple, ce qui justifie la création d'une variable dichotomique, indiquant tout simplement la vie en couple, plus facile à interpréter dans les analyses bivariées et dans nos différentes régressions par la suite (*couple*).

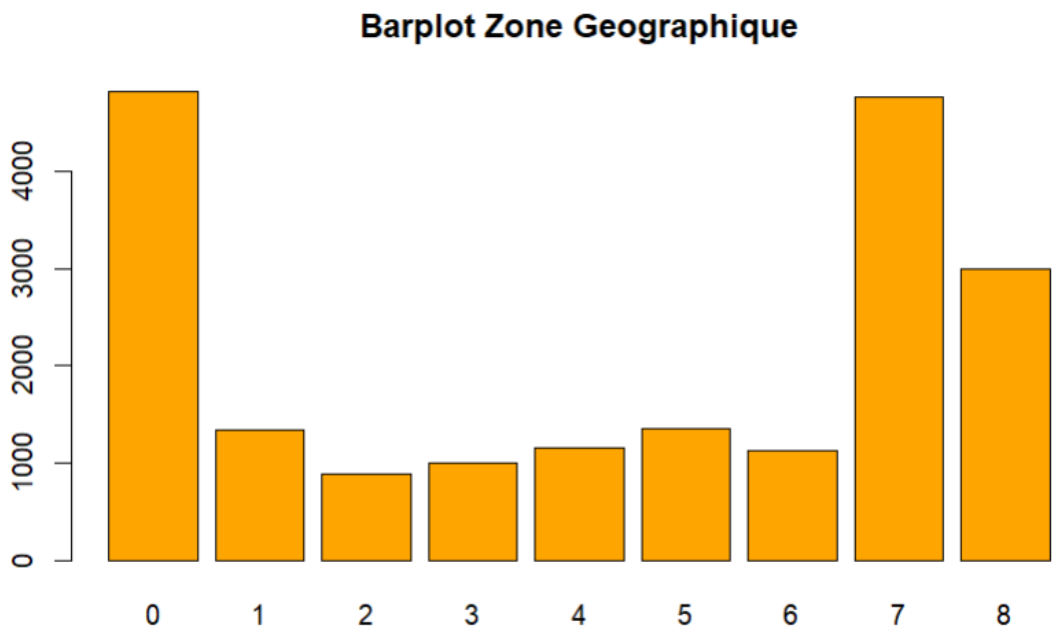
La variable *mne*, qui indique le nombre d'enfants, est également observée pour toutes les femmes. On a une forte concentration des observations autour de 0, 1 ou 2 enfants. Les familles avec un nombre d'enfants élevées sont très rares. Pour simplifier l'analyse, on va résumer cela par une variable dichotomique indiquant la présence d'au moins un enfant (*child*).

Le niveau de diplôme de la femme (*ndiplo*) est observé pour l'ensemble de l'échantillon et présente une répartition relativement équilibrée entre les différentes catégories. Cette variable constitue un indicateur central du capital humain et sera utilisée dans les analyses.

Si on veut rentrer dans les détails, on peut voir directement que d'après le graphique, que la catégorie 4 (CAP,BEP) est beaucoup plus représenté dans notre échantillon que la catégorie 5 destiné actuellement dans notre Société à un parcours orienté plus pour les hommes (BAC Professionnel)



La variable *tu99*, qui décrit le type de zone géographique, est observée pour l'ensemble de l'échantillon. Les observations sont réparties sur l'ensemble des catégories, ce qui permet d'étudier l'influence du contexte géographique sur la participation et le salaire.

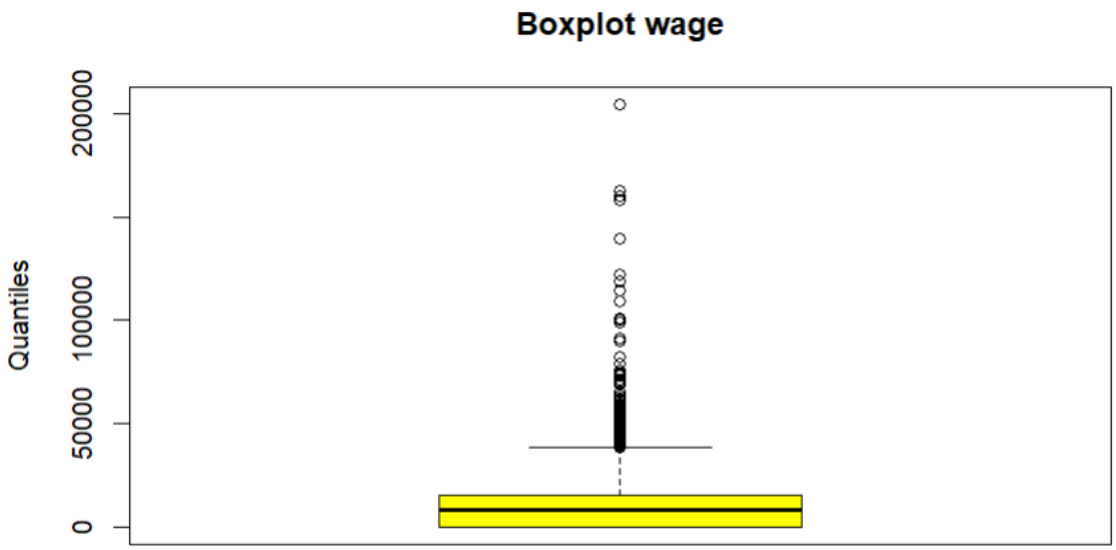


Une grande partie des femmes se situent tout de même dans la catégorie 0, représenté par les villages ruraux. Les autres catégories représentent les zones urbaines du moins peuplés au plus peuplés et on voit que la concentration est beaucoup plus élevé dans la catégorie 7, avec des zones entre 200000 et 2000000 d'habitants ainsi que dans la catégorie 8 avec des femmes vivant sur Paris.

Cas du salaire et de l'emploi

La variable *work* indique si la femme est employée. Environ 64 % des femmes de l'échantillon travaillent. Cette variable est centrale pour l'analyse de la décision de participation au marché du travail.

La variable *wage* correspond au salaire mensuel du travail. Elle est décrite dans la base comme étant égale à zéro lorsque la femme ne travaille pas. On observe 6 952 salaires nuls, correspondant exactement aux femmes non employées. Ces zéros ne doivent pas être interprétés comme des salaires effectifs, mais comme l'absence d'observation du salaire lorsque la femme ne travaille pas.



Les salaires présentent une très forte dispersion, une distribution asymétrique, avec quelques valeurs très élevées.

La variable *part_time* indique le type de temps de travail. Bien qu'elle ne contienne pas de valeurs manquantes dans la base, elle n'est définie que pour les femmes employées. Pour les femmes sans emploi, cette information n'a pas de sens.

Passons maintenant aux analyses bivariées :

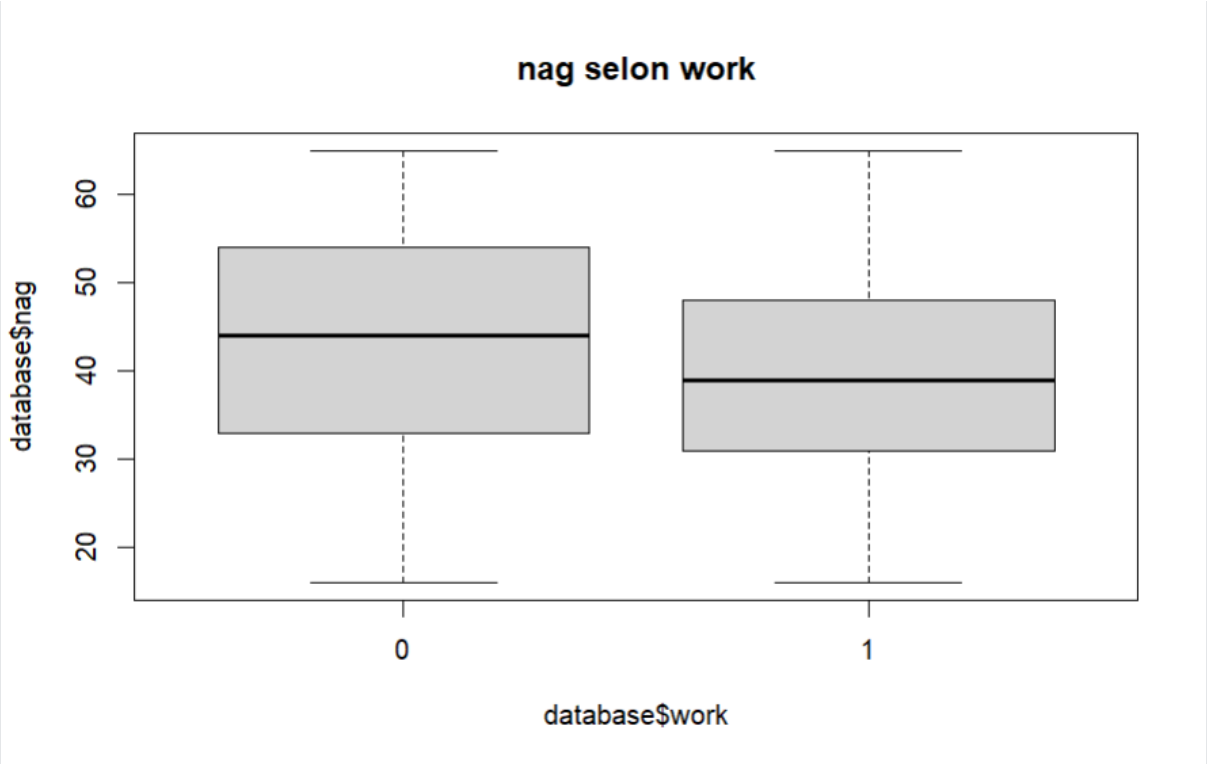
Nous analyserons les relations qui semblent les plus cohérentes théoriquement dans ce rapport.

Participation au marché du travail :

Nous commençons par analyser la relation entre la participation au marché du travail et certaines caractéristiques familiales. Entre work et la variable couple, on peut observer que les femmes qui vivent en couple travaillent moins souvent que celles ne vivant pas en couple. Parmi les femmes qui ne travaillent pas, environ 79 % vivent en couple, contre 73 % parmi celles qui travaillent. Le test du khi-deux confirme que c'est statistiquement significatif. La vie en couple est liée à une probabilité plus faible de participation au marché du travail.

En ce qui concerne les enfants, nous avons les mêmes résultats. On observe que 66,6 % des femmes sans emploi ont au moins un enfant, contre 64,7 % des femmes employées. L'écart entre les 2 classes est très faible et il est statistiquement significatif. La présence d'enfants semble donc également réduire la probabilité de travailler, même si l'effet est moins marqué que celui du couple.

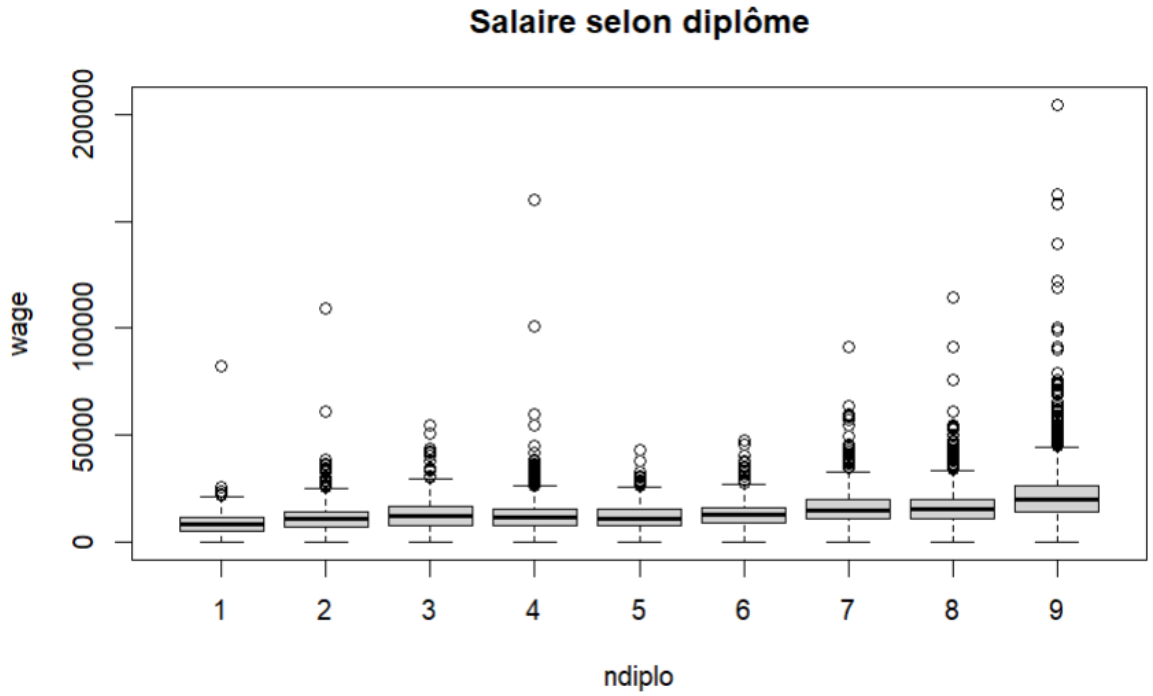
Regardons désormais la variable âge sur la participation au travail.



Ce graphique montre que les femmes employées sont en moyenne plus jeunes que celles qui ne travaillent pas. La médiane de l'âge est plus élevée pour les femmes sans emploi, la participation au marché du travail augmenterait avec l'âge.

Salaire (femmes employées uniquement)

L'analyse bivariée du salaire est réalisée uniquement sur les femmes employées, puisque le salaire n'est observé que pour elles. La Figure 2 présente la distribution du salaire selon le niveau de diplôme.



Le salaire médian augmente avec le niveau de diplôme, et la dispersion des salaires est également plus élevée pour les diplômes les plus élevés. Ce résultat est cohérent avec la théorie du capital humain : un niveau de diplôme plus élevé est associé à des salaires plus importants.

On peut également regarder les corrélations : La corrélation entre le salaire et l'âge est positive et significative (corrélation ≈ 0.17, p-value < 2.2e-16), ce qui indique que le salaire tend à augmenter avec l'âge, cela peut s'expliquer par l'expérience professionnelle.

La corrélation entre le salaire et le revenu total du ménage par exemple est également forte (corrélation ≈ 0.50, p-value < 2.2e-16), ce qui suggère que les ménages à revenu élevé sont aussi ceux où les femmes perçoivent des salaires plus élevés.

Question 2 :

Pour analyser la décision de participation au marché du travail, nous avons estimé plusieurs modèles Probit, la variable latente est donc *work*, indiquant si la femme travaille ou non. Le salaire n'est pas inclus dans cette analyse, car il est endogène à la décision de participation et n'est observé que pour les femmes employées.

On va partir d'un modèle très simple, puis on va enrichir progressivement la spécification en ajoutant des variables explicatives qui semblent théoriquement pertinentes. On s'appuiera donc sur des critères statistiques tels que l'AIC et de tests du rapport de vraisemblance.

Nous commençons par un modèle vide ne contenant qu'une constante, puis nous introduisons successivement l'âge (nag) et son carré (nag2) afin de capter un effet non linéaire du cycle de vie. L'ajout de ces variables améliore l'ajustement du modèle ce qui est normal vu qu'on était sur un modèle vide, cette variable est théoriquement pertinente de toute manière.

Nous introduisons ensuite les variables de situation familiale, à savoir la variable couple, indiquant si la femme vit en couple, et la variable child, indiquant la présence d'au moins un enfant. L'ajout de ces variables améliore encore l'ajustement du modèle, on pourrait en conclure que les contraintes familiales influencent la participation au marché du travail.

	df	AIC
vide	1	25371,60
+nag	2	24731.20
+nag^2	3	23972,12
+couple	4	23843,32
+child	5	23431,92

Dans un second temps, nous ajoutons la variable tu99. Là encore, l'AIC diminue, indiquant une amélioration du modèle.

Enfin, nous introduisons le niveau de diplôme de la femme (ndiplo). L'ajout de cette variable conduit à une baisse supplémentaire de l'AIC.

	df	AIC
Modele complet	21	22103.24

D'autres modèles ont pu également être testés avec l'ajout de nnatior par exemple ou encore nmatri. Quand on ajoutait certaines variables, l'AIC pouvait avoir des scores beaucoup plus forts ou alors les variables ajoutées au sens plutôt théorique étaient redondantes, d'un point de vue théorique. Les tests du rapport de vraisemblance nous faisaient cependant rejeter l'hypothèse nulle et il faudrait donc opter pour le modèle plus complexe. Nous avons pris la décision d'opter pour un modèle plus parcimonieux et facile à interpréter.

Le modèle Probit final retenu est donc le suivant :

$$\Pr(\text{work}_i = 1 \mid X_i) = \Phi(\beta_0 + \beta_1 \,\text{nag}_i + \beta_2 \,\text{nag}_i^2 + \beta_3 \,\text{couple}_i + \beta_4 \,\text{child}_i + \beta_5 \,\text{tu99}_i + \beta_6 \,\text{ndiplo}_i)$$

Interprétons les résultats de ce Probit :

- L'âge influence significativement la décision de participation au marché du travail. L'effet est non linéaire : la probabilité de participer augmente avec l'âge, mais à un rythme décroissant, ce qui est cohérent avec un effet de cycle de vie.

- Les variables de situation familiale jouent également un rôle important. Vivre en couple et avoir au moins un enfant réduisent significativement la probabilité de participation. On peut parler notamment des contraintes familiales qui joue un rôle sur le travail des femmes.

- Tous les niveaux de diplôme sont associés à une probabilité plus élevée de participer au marché du travail par rapport à la catégorie de référence. L'effet est beaucoup plus élevé quand le niveau de diplôme est lui aussi plus élevé.

- En ce qui concerne la variable géographique, 2 modalités sont significatives, tandis que le reste ne l'est pas. Cela reste normal quand il existe énormément de modalités dans une variable.

Pour comparer avec le Probit, nous avons fait une régression logistique, estimée avec la même spécification. Les signes et la significativité des coefficients sont très proches de ceux obtenus avec le Probit, ce qui confirme la robustesse des résultats.

Question 3 :

Nous allons pour cette question estimer un modèle linéaire afin d'expliquer le salaire. Cette analyse va être en 2 parties. Nous considérons d'abord l'ensemble des femmes de l'échantillon, puis uniquement les femmes qui travaillent.

Dans un premier temps, le salaire est estimé sur l'ensemble des femmes. Dans la base de données, le salaire est égal à zéro pour les femmes qui ne travaillent pas. Les résultats obtenus montrent que l'âge et le niveau de diplôme ont un effet important sur le salaire. Ce modèle mélange deux phénomènes différents : la décision de travailler et le niveau du salaire. Les femmes qui ne travaillent pas ont un salaire nul, ce qui influence fortement les résultats. L'OLS n'est pas adapté. Les zéros observés dans la base ne correspondent pas à de véritables salaires, mais à l'absence d'observation. L'utilisation de l'OLS conduit donc à des prédictions incohérentes, notamment des salaires négatifs, et à un biais de sélection lié au fait que l'échantillon des femmes employées n'est pas aléatoire.

On le voit notamment notre dernier modèle qui nous donne ces résultats :

Min	1Q	Median	3Q	Max
-21980	-5680	-341	5231	187754

L'OLS donne des résultats négatifs ce qui est totalement incohérents car les salaires ne peuvent pas être négatifs donc des résultats biaisés et incohérents.

Dans un second temps, nous estimons le modèle uniquement sur les femmes employées. Cette approche permet d'analyser le salaire uniquement lorsqu'il est observé. Les résultats montrent que le salaire augmente avec l'âge. Plus le diplôme est élevé, plus le salaire est important. Le type de zone géographique a également un effet sur le salaire, même si cet effet varie selon les zones.

Les variables liées à la situation familiale, comme le fait de vivre en couple ou d'avoir des enfants, ne sont pas utilisés ici pour expliquer le salaire. Ces variables sont surtout importantes pour expliquer la décision de travailler, mais beaucoup moins pour expliquer le niveau du salaire une fois que la femme est employée.

Les variables qui expliquent la participation au marché du travail ne sont donc pas exactement les mêmes que celles qui expliquent le salaire (diminution des variables dans le modèle). Cette différence montre qu'il est nécessaire de traiter séparément la décision de travailler et la détermination du salaire, ce qui justifie l'utilisation d'un modèle de sélection dans la suite de l'analyse.

En ce qui concerne les valeurs, nous avons toujours des résultats négatifs même quand la variable work = 1. Ce qui confirme la présence de valeurs négatives complétement incohérentes en OLS sur ce type de données.

Question 4 :

Dans cette question, nous estimons un modèle de type Tobit 2 par maximum de vraisemblance. Dans notre base de données, le salaire n'est observé que pour les femmes qui travaillent, ce qui signifie que l'échantillon des femmes employées n'est pas aléatoire. Utiliser un modèle linéaire reviendrait à ignorer ce problème de sélection et conduirait à des estimations biaisées. Le modèle Tobit 2 permet de corriger ce biais en estimant simultanément deux équations. La première est l'équation de sélection, qui modélise la décision de travailler :

$$work_i^* = Z_i\gamma + u_i, work_i = 1 \text{ si } work_i^* > 0,\ 0 \text{ sinon.}$$

La seconde est l'équation de salaire, définie par :

$$wage_i^* = X_i\beta + \varepsilon_i,$$

où le salaire n'est observé que si la femme travaille.

Les termes d'erreur $u_i$et $\varepsilon_i$sont sous hypothèse, corrélés. Le choix des variables retenues dans le modèle Tobit 2 se base directement sur les résultats obtenus dans les questions précédentes. Les estimations du modèle Probit pour la participation et du modèle linéaire pour le salaire ont permis d'identifier des variables efficaces/pertinentes pour expliquer chacun des deux mécanismes. Nous reprenons donc ces mêmes variables dans le modèle de sélection pour conserver une cohérence entre les différentes étapes de l'analyse. Les variables expliquant la participation sont celles qui ont montré un effet significatif dans le Probit, et les variables expliquant le salaire correspondent à celles qui se sont révélées importantes dans les estimations du salaire conditionnellement à l'emploi.

Question 5 :

Les résultats du Tobit 2 confirment et complètent ceux des questions précédentes. Dans la question 2, le Probit montrait déjà que l'âge (avec un effet non linéaire), le fait de vivre en couple et la présence d'enfants influencent fortement la probabilité de travailler : l'âge augmente la participation mais à un rythme décroissant, tandis que vivre en couple et avoir des enfants réduisent la participation. Dans le Tobit 2, on retrouve exactement la même logique dans l'équation de sélection : les signes et la significativité des coefficients sont très proches du Probit estimé seul, ce qui rassure sur la robustesse de nos résultats.

Dans la question 3, l'OLS sur toutes les femmes posait un problème important, le zéro ne correspondait pas à un vrai salaire et l'OLS mélange donc la décision de travailler et le niveau du salaire, ce qui peut conduire à des prédictions incohérentes, notamment des salaires négatifs. L'OLS estimé seulement sur les femmes employées améliore déjà l'interprétation, mais il ignore encore le fait que les femmes employées ne sont pas choisies au hasard, et on retrouve toujours ce problème de valeurs négatives.

Le Tobit 2 corrige ce point en estimant en même temps la participation et le salaire, et on va trouver une corrélation entre les erreurs des 2 équations qui jouent sur ces deux décisions. Ici, le paramètre ρ est négatif et significatif ($\rho \approx -0.15$, p-value très faible), ce qui montre qu'il existe bien un biais de sélection : Des caractéristiques non observées influencent à la fois la probabilité d'être employée et le niveau du salaire. On utilisera donc un Tobit 2 plutôt qu'une estimation séparée Probit + OLS par exemple.

Concernant le salaire : l'âge a toujours un effet positif mais décroissant et le diplôme a un effet fortement positif. Enfin, sur l'identification des paramètres, avec le Tobit, on peut identifier séparément l'équation de participation et l'équation de salaire en exploitant le fait que le salaire n'est observé que pour une partie de l'échantillon et grâce aux hypothèses de normalité jointe des erreurs. Couple et child sont utilisés pour expliquer la participation, mais ne sont pas inclus dans l'équation de salaire, car ils sont plutôt utiles pour la décision de travailler plutôt qu'au niveau de salaire.

R Code

```r
#Pichon François
#Pot Julien
library(readxl)
library(Hmisc)

database <- read_excel("C:/MASTER 2/Microeconometrie/database.xls")

summary(database)
describe(database)

database$mmatri    <- as.factor(database$mmatri)
database$mdiploc   <- as.factor(database$mdiploc)
database$mne       <- as.factor(database$mne)
database$mtyad     <- as.factor(database$mtyad)
database$tu99      <- as.factor(database$tu99)
database$ncohab    <- as.factor(database$ncohab)
database$ncs8      <- as.factor(database$ncs8)
database$ndiplo    <- as.factor(database$ndiplo)
database$nmatri    <- as.factor(database$nmatri)
database$nnatior   <- as.factor(database$nnatior)
database$noccup    <- as.factor(database$noccup)
database$nsexe     <- as.factor(database$nsexe)
database$married   <- as.factor(database$married)
database$work      <- as.factor(database$work)
database$part_time <- as.factor(database$part_time)

table(database$wage)


# 1) Indicatrice "en couple"
database$couple <- ifelse(database$ncohab == "1", 1,
                          ifelse(database$ncohab == "2", 0, NA))

# 2) Enfants : au moins un enfant
database$child <- ifelse(as.numeric(as.character(database$mne)) > 0, 1,
                         ifelse(as.numeric(as.character(database$mne)) == 0, 0, N
A))

# 3) Revenus non salariaux positifs
database$nrtns_pos <- ifelse(database$nrtns > 0, 1,
                             ifelse(database$nrtns == 0, 0, NA))

# 4) Salaire observé
database$wage_obs <- ifelse(database$work == 1, database$wage, NA)



# UNIVARIÉE

# qex
boxplot(database$qex, col = c("yellow"), main = "Boxplot", ylab = "Quantiles")
hist(database$qex, col = c("orange"), main = "Histogramme pour la variable qex", yl
```

```r
ab = "", xlab = "")

  # nag
  par(mfrow = c(1,2))
  boxplot(database$nag, col = c("yellow"), main = "Boxplot nag", ylab = "")
  hist(database$nag, col = c("orange"), main = "Histogramme nag", ylab = "", xlab =
"")

  par(mfrow = c(1,1))
  # nrtns
  boxplot(database$nrtns, col = c("yellow"), main = "Boxplot", ylab = "Quantiles")
  hist(database$nrtns, col = c("orange"), main = "Histogramme pour la variable nrtn
s", ylab = "", xlab = "")

  # wage
  boxplot(database$wage, col = c("yellow"), main = "Boxplot wage", ylab = "Quantile
s")
  hist(database$wage, col = c("orange"), main = "Histogramme pour la variable wage",
ylab = "", xlab = "")

  # mrtotm
  boxplot(database$mrtotm, col = c("yellow"), main = "Boxplot", ylab = "Quantiles")
  hist(database$mrtotm, col = c("orange"), main = "Histogramme pour la variable mrtot
m", ylab = "", xlab = "")

  #Qualitative

  barplot(table(database$mmatri), main="", xlab="", col="orange")
  barplot(table(database$mdiploc, useNA="ifany"), main="", xlab="", col="orange")
  barplot(table(database$mne), main="", xlab="", col="orange")
  barplot(table(database$mtyad), main="", xlab="", col="orange")
  barplot(table(database$tu99), main="Barplot Zone Geographique", xlab="", col="orang
e")
  barplot(table(database$ncohab), main="", xlab="", col="orange")
  barplot(table(database$ncs8), main="", xlab="", col="orange")
  barplot(table(database$ndiplo), main="Barplot diplome", xlab="", col="orange")
  barplot(table(database$nmatri), main="", xlab="", col="orange")
  barplot(table(database$nnatior), main="", xlab="", col="orange")
  barplot(table(database$noccup), main="", xlab="", col="orange")
  barplot(table(database$nsexe), main="", xlab="", col="orange")
  barplot(table(database$married), main="", xlab="", col="orange")
  barplot(table(database$work), main="", xlab="", col="orange")
  barplot(table(database$part_time, useNA="ifany"), main="", xlab="", col="orange")
  barplot(table(database$couple), main = "Barplot couple", xlab = "", col = "orange")

  prop.table(table(database$work))

  # BIVARIÉE

  table(database$work, database$couple)
  prop.table(table(database$work, database$couple), margin = 1)
  chisq.test(table(database$work, database$couple))

  table(database$work, database$child)
  prop.table(table(database$work, database$child), margin = 1)
```

```r
chisq.test(table(database$work, database$child))

table(database$work, database$nrtns_pos)
prop.table(table(database$work, database$nrtns_pos), margin = 1)
chisq.test(table(database$work, database$nrtns_pos))

table(database$work, database$mmatri)
prop.table(table(database$work, database$mmatri), margin = 1)
chisq.test(table(database$work, database$mmatri))


# Boxplots
boxplot(database$qex ~ database$work, main="qex selon work")
boxplot(database$mrtotm ~ database$work, main="mrtotm selon work")
boxplot(database$nag ~ database$work, main="nag selon work")
boxplot(database$nrtns ~ database$work, main="nrtns selon work")

# BIVARIÉE


database_emp <- subset(database, work == 1)

# Boxplot
boxplot(wage ~ ndiplo, data = database_emp, main = "Salaire selon diplôme")
boxplot(wage ~ ncs8, data = database_emp, main = "Salaire selon catégorie socio-pro")
boxplot(wage ~ married, data = database_emp, main = "Salaire selon statut marital")
boxplot(wage ~ couple, data = database_emp, main = "Salaire selon couple")
boxplot(wage ~ child, data = database_emp, main = "Salaire selon enfants")

# Corrélations
cor.test(database_emp$wage, database_emp$nag)
cor.test(database_emp$wage, database_emp$mrtotm)
cor.test(database_emp$wage, database_emp$nrtns)


# PROBIT

vide <- glm(work ~ 1, data = database, family = binomial(link = "probit"))
summary(vide)
probit1 <- glm(work ~ nag, data = database, family = binomial(link = "probit"))
summary(probit1)
database$nag2 <- database$nag^2
database_emp$nag2 <- database_emp$nag^2
probit2 <- glm(work ~ nag + nag2, data = database, family = binomial(link = "probit"))
summary(probit2)
probit3 <- glm(work ~ nag + nag2 + couple, data = database, family = binomial(link = "probit"))
summary(probit3)
probit4 <- glm(work ~ nag + nag2 + couple + child, data = database, family = binomial(link = "probit"))
summary(probit4)
AIC(vide, probit1, probit2, probit3, probit4)
probit5 <- glm(work ~ nag + nag2 + couple + child + tu99, data = database, family =
```

```
binomial(link = "probit"))
summary(probit5)
probit6 <- glm(work ~ nag + nag2 + couple + child + tu99 + ndiplo, data = database,
family = binomial(link = "probit"))
summary(probit6)
AIC(probit5, probit6)
nobs(probit5); nobs(probit6)

probit7 <- glm(work ~ nag + nag2 + couple + child + tu99 + nnatior, data = databas
e, family = binomial(link = "probit"))
summary(probit7)
AIC(probit5, probit7)
nobs(probit5); nobs(probit7)

probit8 <- glm(work ~ nag + nag2 + couple + child + tu99  + nnatior + ndiplo, data
= database, family = binomial(link = "probit"))
summary(probit8)
AIC(probit5, probit8)
nobs(probit5); nobs(probit8)

AIC(vide, probit1, probit2, probit3, probit4, probit5, probit6, probit7, probit8)
library(lmtest)
lrtest(probit6, probit8)

#Essayons avec probit 6
logit_final <- glm(work ~ nag + nag2 + couple + child + tu99 + ndiplo,
                   data = database,
                   family = binomial(link="logit"))
summary(logit_final)


#3
ols <- lm(wage ~ nag + nag2, data = database)
summary(ols)
ols_diplo <- lm(wage ~ nag + nag2 + ndiplo, data = database)
summary(ols_diplo)
ols_tu99 <- lm(wage ~ nag + nag2 + tu99, data = database)
summary(ols_tu99)
ols_2 <- lm(wage ~ nag + nag2 + tu99 + ndiplo, data = database)
summary(ols_2)


ols_emp_1 <- lm(wage ~ nag + nag2, data = database_emp)
summary(ols_emp_1)
ols_emp_2 <- lm(wage ~ nag + nag2 + ndiplo, data = database_emp)
summary(ols_emp_2)
ols_emp_3 <- lm(wage ~ nag + nag2 + tu99, data = database_emp)
summary(ols_emp_3)
ols_emp_4 <- lm(wage ~ nag + nag2 + ndiplo + tu99, data = database_emp)
summary(ols_emp_4)


#4
install.packages("sampleSelection")
library(sampleSelection)
```

```r


database$wage_k <- database$wage/1000


tobit2_ml <- selection(
  selection = work ~ nag + nag2 + couple + child + tu99 + ndiplo,
  outcome   = wage_k ~ nag + nag2 + ndiplo + tu99,
  data = database,
  method = "ml"
)

summary(tobit2_ml)

```