Université de Lille

DM – Modèles de durée (Telco churn)

Kaplan–Meier, Nelson–Aalen, hazard discret et censure à droite

François Pichon – Maxime Gourguechon – Julien Pot

15 janvier 2026

Table des matières

1 Introduction **1**

1.1 Apports de la littérature et lien avec notre approche 1

2 Données et construction des variables de durée **1**

2.1 Définition de la durée et de la censure 2

3 Analyse descriptive : distributions, courbes de survie **2**

3.1 Qualité des données et limites 3

4 Estimation non paramétrique (Kaplan–Meier / Nelson–Aalen) **3**

4.1 Cadre : durée, événement et censure 3

4.2 Kaplan–Meier : probabilité de rester abonné 3

4.3 Nelson–Aalen : lecture du risque de churn 4

5 Discussion des covariables **4**

5.1 Prix et facturation (`MonthlyCharges`, `TotalCharges`) 4

5.2 Type de contrat (`Contract`) 4

5.3 Qualité perçue et services 5

5.4 Paiement et frictions (`PaymentMethod`, `PaperlessBilling`) 5

5.5 Profil socio-démographique (`SeniorCitizen`, `Partner`, `Dependents`) 5

6 Conclusion **5**

Annexes **I**

Figures et Tables I

Références V

Code R V

Usage de l'IA XI

1 Introduction

Le churn, désignant plus communément la perte d'abonnés à la suite d'une mauvaise expérience, d'un passage à une autre offre, est un indicateur important de la satisfaction client ou encore de l'efficacité d'une stratégie produit. Dans notre cas, nous pouvons allier à ce thème l'analyse de durée qui va permettre d'étudier le temps écoulé avant la survenue d'un évènement et la manière dont le churn va évoluer au fil du temps.

Ces analyses de durée reposent sur les travaux de Cox(1972) qui va introduire les modèles de risques et proposer le concept de fonction de hasard. Cela permettra notamment de mieux comprendre comment le risque d'un évènement va changer au cours du temps sans réellement faire d'hypothèses.

1.1 Apports de la littérature et lien avec notre approche

Le modèle de Cox a été conçu pour intégrer des covariables explicatives. Même si nous resterons dans une approche plus théorique et prospective, cet article reste une référence pour analyser des comportements de sortie et formaliser la notion de risque (hazard) qui évolue au fil du temps.

Plus récemment, on retrouve davantage de travaux appliqués au churn. Celık et Osmanglu (2019) montrent que les modèles de survie restent pertinents pour analyser cette perte de clients, même si les approches de machine learning se démocratisent : l'intérêt des méthodes de survie est d'intégrer explicitement la dimension temporelle, c'est-à-dire non seulement "qui part", mais aussi "quand".

Havrylovych et Kuznietsova mettent également en avant l'intérêt des fonctions de survie et de hasard pour comprendre des comportements hétérogènes au sein d'une population, notamment dans le secteur des télécommunications où la dynamique de résiliation varie fortement selon l'ancienneté.

Ces trois références rappellent surtout une idée simple : en analyse de survie, l'enjeu n'est pas seulement de savoir qui part, mais quand le départ devient le plus probable, et comment ce risque évolue avec l'ancienneté. C'est particulièrement pertinent en télécoms, où beaucoup de clients restent abonnés longtemps : si l'on ignore la censure, on jette justement l'information portée par tous ces clients encore actifs, et on déforme la lecture de la stabilité de la relation.

Dans ce devoir, on ne peut pas estimer de modèles multivariés (pas de Cox, pas de Weibull, etc.). On s'appuie donc sur une approche non paramétrique (Kaplan–Meier et Nelson–Aalen), qui décrit la survie et le risque sans imposer de forme particulière et en intégrant correctement la censure à droite. L'objectif est de mettre en évidence la dynamique globale du churn (phase sensible au démarrage, stabilisation ensuite), puis d'ouvrir sur une discussion argumentée des covariables qui pourraient expliquer ces écarts de comportement.

L'objectif ici est donc de comprendre et d'analyser l'évolution du risque au cours du temps. Notre question de recherche sera : Comment les fonctions de survie et de hasard permettent-elles d'identifier des comportements différents dans le temps, indépendamment des caractéristiques individuelles ?

2 Données et construction des variables de durée

La base Telco contient $N = 7043$ clients suivis sur une ancienneté maximale de 72 mois. La variable de durée est `tenure`, qui mesure l'ancienneté du client (en mois) depuis son entrée chez l'opérateur jusqu'à la fin de son observation. Elle prend des valeurs entières entre 0 et 72, sans valeurs manquantes, avec une moyenne d'environ 32,4 mois.

La résiliation est donnée par `Churn`. Pour l'analyse, on la recode en une indicatrice binaire (par exemple `ChurnBinary`) : 1 si `Churn=Yes` (événement observé), 0 sinon (client encore actif au dernier

mois observé). On utilise aussi `TotalCharges` (montant total facturé depuis l'entrée), qui contient 11 valeurs manquantes : elles sont remplacées par la moyenne afin de conserver l'échantillon complet (le nombre de cas concernés reste très faible).

En première lecture descriptive, les boxplots (Figures 1 et 2 en annexe) montrent que les churners ont une ancienneté plus faible. Ils ont aussi des `TotalCharges` plus faibles, ce qui est cohérent car cette variable est cumulative : un départ précoce implique mécaniquement un cumul facturé plus bas. Quelques valeurs extrêmes existent chez les churners, compatibles avec des départs plus tardifs ou des offres plus coûteuses.

2.1 Définition de la durée et de la censure

Formellement, la durée d'intérêt est :

$$T_i = \texttt{tenure}_i \in \{0, 1, \ldots, 72\}.$$

L'événement est la résiliation. Chaque client est résumé par (t_i, δ_i), où $t_i = \texttt{tenure}_i$ et

$$\delta_i = \begin{cases} 1 & \text{si le client résilie pendant la période observée (\texttt{Churn=Yes}),} \\ 0 & \text{si le client est encore abonné à la fin du suivi.} \end{cases}$$

Les clients encore actifs sont donc censurés à droite : on sait qu'ils n'ont pas résilié jusqu'à t_i, sans information au-delà. Les durées étant mensuelles, on observe des ex-aequo (ties), ce qui est normal et compatible avec Kaplan–Meier et Nelson–Aalen, qui s'appuient précisément sur des instants d'événements discrets.

3 Analyse descriptive : distributions, courbes de survie

Les clients encore actifs à la fin de la période d'observation vont être considérés comme censurés à droite. Le taux de censure est donc la proportion de clients qui n'ont pas résilié leur abonnement durant la période de tenure. Son taux s'élève à environ 73.5%, une majorité de clients sont toujours abonnés au moment de la fin d'observation. Ces abonnements télécoms sont souvent utilisés sur du très long terme, les changements d'opérateurs sont très peu fréquents donc la censure à droite est attendu dans ce contexte.

On peut donc se pencher sur la fonction de survie, on décidera de l'analyser sous forme de table. Chaque valeur correspond à une durée en mois. Quand une durée est suivie du symbole +, cela signifie que notre client est encore actif à cette durée et que l'observation est censurée à droite. S'il n'y a pas de symbole, c'est une résiliation. On retrouve donc la plupart des résiliations sur les faibles durées, vers les premiers mois d'abonnement. Plus la durée augmente, plus il y a d'observations censurées. Donc peu de clients résilient leur contrat avec une ancienneté élevé.

La distribution des durées d'abonnement (Figure 3 en annexe), montrent aussi des événements sur des durées plus faibles et les abonnés encore actifs voient leur pic sur les périodes longues. Plus la durée augmente, plus la proportion d'événements diminuent, on a une domination des observations censurées. La distribution et la fonction de survie sont très similaires dans leur interprétation.

Enfin, pour compléter la lecture descriptive, on examine la distribution des temps de censure (Figure 4 en annexe). Elle indique à quels horizons se situent les clients encore actifs lorsque l'observation s'arrête. Dans notre cas, la censure se concentre surtout sur des durées élevées, ce qui est cohérent avec l'idée que beaucoup de clients restent abonnés longtemps : les observations

censurées portent donc une information importante sur la stabilité de la relation client et doivent être intégrées au calcul des fonctions de survie et de risque.

3.1 Qualité des données et limites

Deux limites principales sont à garder en tête. D'une part, la durée est mesurée au mois : on ne connaît pas la date exacte de résiliation à l'intérieur d'un mois, ce qui crée des durées identiques et des courbes en « paliers ». D'autre part, la censure est très élevée (plus de 70%) : c'est logique dans un contexte télécom, mais cela rend les estimations en fin d'horizon (proche de 72 mois) plus fragiles, car il reste peu de clients réellement encore à risque à ces durées.

Par ailleurs, certaines variables sont mécaniquement liées au temps : `TotalCharges` est un cumul et dépend fortement de `tenure`. Elle est donc utile descriptivement, mais son interprétation comme facteur explicatif direct du churn doit rester prudente. Enfin, le jeu de données ne contient pas d'information sur les motifs réels de résiliation (insatisfaction, déménagement, concurrence, etc.) ni sur l'évolution de l'offre ou des prix dans le temps, ce qui limite l'interprétation causale : on décrit une dynamique de churn, sans pouvoir attribuer formellement la cause des départs.

4 Estimation non paramétrique (Kaplan–Meier / Nelson–Aalen)

Cette section décrit la dynamique du churn dans le temps, sans utiliser de covariables. L'idée est simplement de répondre à la question : à quel moment les clients ont-ils le plus de chances de quitter l'opérateur ? Les approches non paramétriques sont adaptées ici, car elles décrivent la survie et le risque sans imposer une forme particulière, tout en gérant correctement la censure à droite.

4.1 Cadre : durée, événement et censure

On note T la durée (en mois) avant résiliation. L'événement correspond à `Churn=Yes`. Les clients encore abonnés à la fin de l'observation sont censurés à droite : on sait qu'ils n'ont pas résilié jusqu'à leur dernier mois observé, mais on ne sait pas ce qu'il se passe ensuite.

On observe donc, pour chaque client i, une paire (t_i, δ_i), où t_i est la durée observée (tenure) et $\delta_i = 1$ si la résiliation est observée, $\delta_i = 0$ si l'observation est censurée. Ce point est crucial : avec beaucoup de censures, ignorer ces clients ou les traiter comme des churners biaiserait l'analyse.

Dans l'échantillon, on compte $N = 7043$ clients, dont 1869 résiliations (26,54%) et 5174 censures (73,46%). Le détail est rappelé en annexe (Tableau 1).

4.2 Kaplan–Meier : probabilité de rester abonné

La fonction de survie mesure la probabilité de rester abonné au-delà de t mois :

$$S(t) = \mathbb{P}(T > t).$$

L'estimateur de Kaplan–Meier s'écrit :

$$\widehat{S}(t) = \prod_{t_{(j)} \le t} \left(1 - \frac{d_j}{n_j}\right),$$

où d_j est le nombre de résiliations au temps $t_{(j)}$ et n_j le nombre de clients encore à risque juste avant.

Concrètement, la courbe globale (Figure 5 en annexe) baisse fortement au début puis s'aplatit : le

churn est surtout un phénomène de démarrage. Les repères (Tableau 2 en annexe) confirment cette lecture : $\widehat{S}(12) \approx 0{,}843$, $\widehat{S}(24) \approx 0{,}789$ et $\widehat{S}(72) \approx 0{,}593$. Comme la survie reste au-dessus de 0,5 à 72 mois, la médiane de survie n'est pas atteinte sur l'horizon observé. Enfin, la diminution des effectifs à risque (Figure 6 en annexe) implique que la fin de courbe est plus incertaine, car il reste moins de clients suivis.

4.3 Nelson–Aalen : lecture du risque de churn

Kaplan–Meier donne une vision "combien restent". Nelson–Aalen permet une lecture plus orientée "pression de churn", via le hazard cumulé :

$$H(t) = \int_0^t h(u)\,du, \qquad \widehat{H}(t) = \sum_{t_{(j)} \le t} \frac{d_j}{n_j}.$$

La courbe de Nelson–Aalen (Figure 7 en annexe) augmente vite au début puis plus régulièrement, ce qui confirme que le risque est surtout concentré sur les premiers mois. À 72 mois, on obtient $\widehat{H}(72) \approx 0{,}523$ (Tableau 2 en annexe).

Comme les durées sont mensuelles, on peut aussi regarder un hazard discret :

$$\widehat{h}(t) = \frac{d(t)}{n(t)}.$$

Les repères (Tableau 3 en annexe) sont très parlants : le risque est maximal dès le mois 1 ($\widehat{h}(1) \approx 0{,}054$), puis il chute rapidement. Autrement dit, une partie des clients "teste" l'offre et part tôt ; ceux qui restent ensuite deviennent nettement plus stables.

Au final, Kaplan–Meier et Nelson–Aalen racontent la même histoire avec deux angles complémentaires : le churn se joue surtout dans les premiers mois, puis le risque diminue fortement. En pratique, c'est donc là que les actions de rétention ont le plus d'impact (onboarding, support, réduction des frictions).

5 Discussion des covariables

L'idée est simplement d'identifier, à partir de la dynamique observée (churn surtout au début puis stabilisation), quelles variables du fichier semblent les plus plausibles pour expliquer pourquoi certains clients partent plus vite que d'autres. On ne cherche pas à prouver un effet, mais à proposer des mécanismes cohérents avec un abonnement télécom, qui pourraient être testés ensuite.

5.1 Prix et facturation (`MonthlyCharges`, `TotalCharges`)

Les boxplots (Figures 1 et 2 en annexe) montrent que les churners ont des durées plus courtes et des `TotalCharges` plus faibles. C'est largement mécanique : comme `TotalCharges` est un cumul, il baisse dès que l'abonnement s'arrête tôt. Pour raisonner sur le « coût » de façon plus utile, `MonthlyCharges` est plus parlant. Un prix mensuel élevé peut pousser certains clients à partir s'ils jugent l'offre trop chère, mais il peut aussi refléter une offre plus riche et donc mieux perçue. Au final, tout dépend du rapport entre prix payé et valeur perçue.

5.2 Type de contrat (`Contract`)

Le type de contrat est naturellement lié au churn. Un engagement d'un an ou deux ans crée de l'inertie : partir est moins simple (coûts de sortie, démarches, engagement), ce qui peut réduire

le risque de résiliation, surtout au début. À l'inverse, un contrat mensuel rend le départ facile : si l'expérience déçoit, la résiliation peut arriver très vite. On peut donc voir `Contract` comme un levier de « verrouillage » plus ou moins fort.

5.3 Qualité perçue et services

Dans les télécoms, beaucoup de départs viennent de l'expérience réelle : qualité du service, incidents, installation, support. Des variables comme `InternetService`, `TechSupport`, `OnlineSecurity` ou `OnlineBackup` peuvent jouer via des mécanismes simples : un service stable et bien accompagné réduit les irritants et donc l'envie de partir ; à l'inverse, des problèmes techniques non résolus peuvent déclencher une résiliation rapide, ce qui colle bien avec le churn concentré au démarrage. En particulier, `TechSupport` peut faire la différence entre « un souci ponctuel » et « un départ ».

5.4 Paiement et frictions (`PaymentMethod`, `PaperlessBilling`)

La façon de payer capture souvent des frictions. Le paiement automatique et la facturation dématérialisée peuvent limiter les ruptures liées à l'administratif (oubli, retard, complexité). Certains moyens plus « manuels » peuvent au contraire ajouter de la friction et s'associer à plus de volatilité. Ces variables peuvent aussi refléter des profils différents (habitudes, aisance numérique, contraintes budgétaires), ce qui peut se traduire par des comportements de churn différents.

5.5 Profil socio-démographique (`SeniorCitizen`, `Partner`, `Dependents`)

Enfin, le contexte de vie peut jouer sur la stabilité. Des clients avec `Partner` ou `Dependents` peuvent avoir un usage plus régulier et donc une relation plus stable à l'abonnement. `SeniorCitizen` peut renvoyer à des comportements variés : parfois plus d'inertie (moins de changements), parfois plus de sensibilité au prix ou à la simplicité des démarches. Ces variables aident surtout à rappeler que tous les clients n'ont pas la même probabilité de partir tôt.

Au final, l'ensemble de ces covariables est cohérent avec ce que montrent les courbes : si le churn se joue surtout au début, alors les facteurs qui comptent le plus sont ceux qui affectent l'entrée dans l'offre (prix perçu, flexibilité du contrat, qualité du support, frictions de paiement).

6 Conclusion

Environ 73,46% des clients sont encore abonnés à la fin de l'observation : il faut donc tenir compte de la censure pour analyser correctement le churn. Les courbes de Kaplan–Meier et de Nelson–Aalen montrent un message simple : les départs se concentrent surtout au début de l'abonnement. La survie baisse fortement dans les premiers mois, puis elle devient beaucoup plus stable. Le risque mensuel est maximal dès le mois 1 et diminue rapidement ensuite. À long terme, plus d'un client sur deux est encore présent à 72 mois, ce qui confirme une fidélisation forte après la phase initiale. En pratique, la rétention se joue donc principalement au démarrage : installation sans difficulté, accompagnement clair et support réactif dès les premiers mois.

Annexes

Figures et Tables

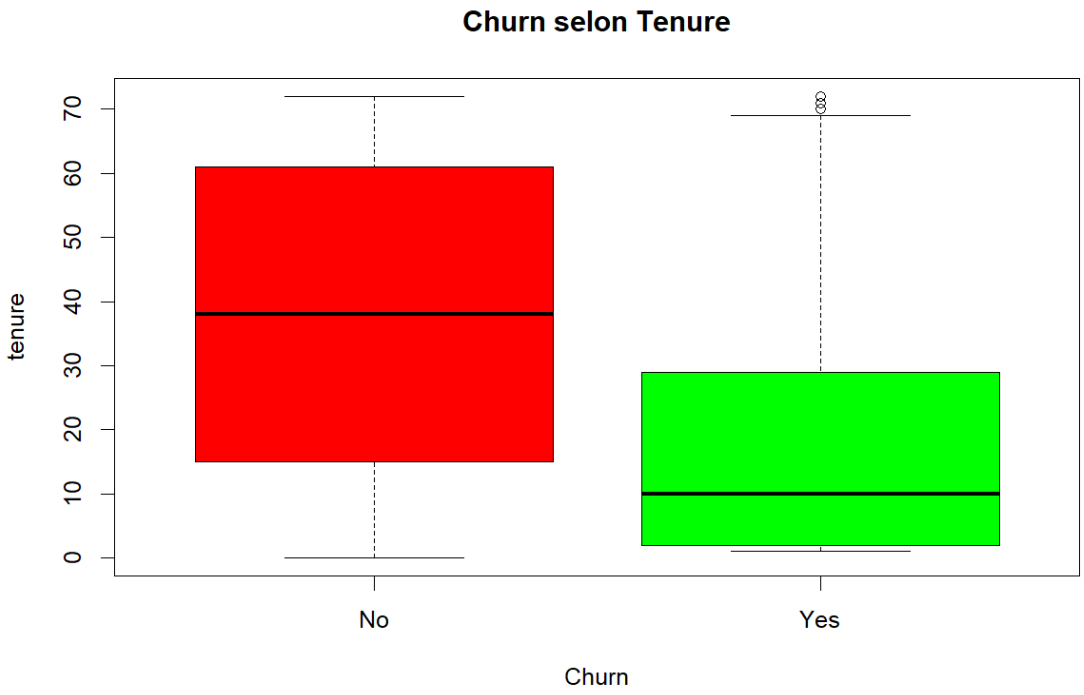


FIGURE 1 : Churn selon Tenure.

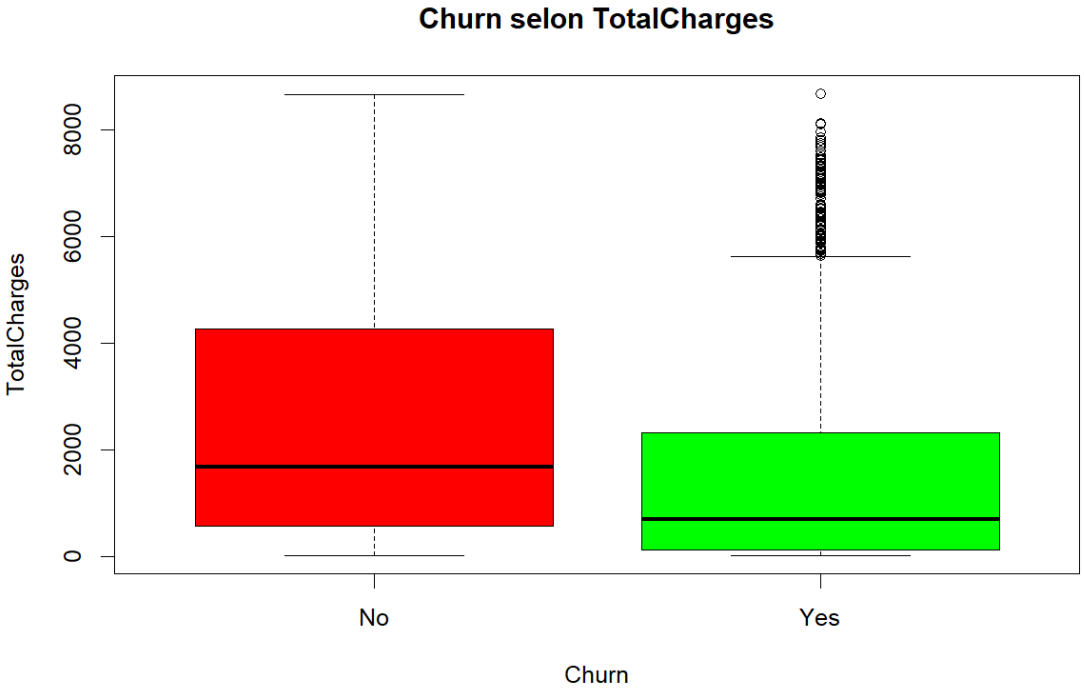


FIGURE 2 : Churn selon TotalCharges.

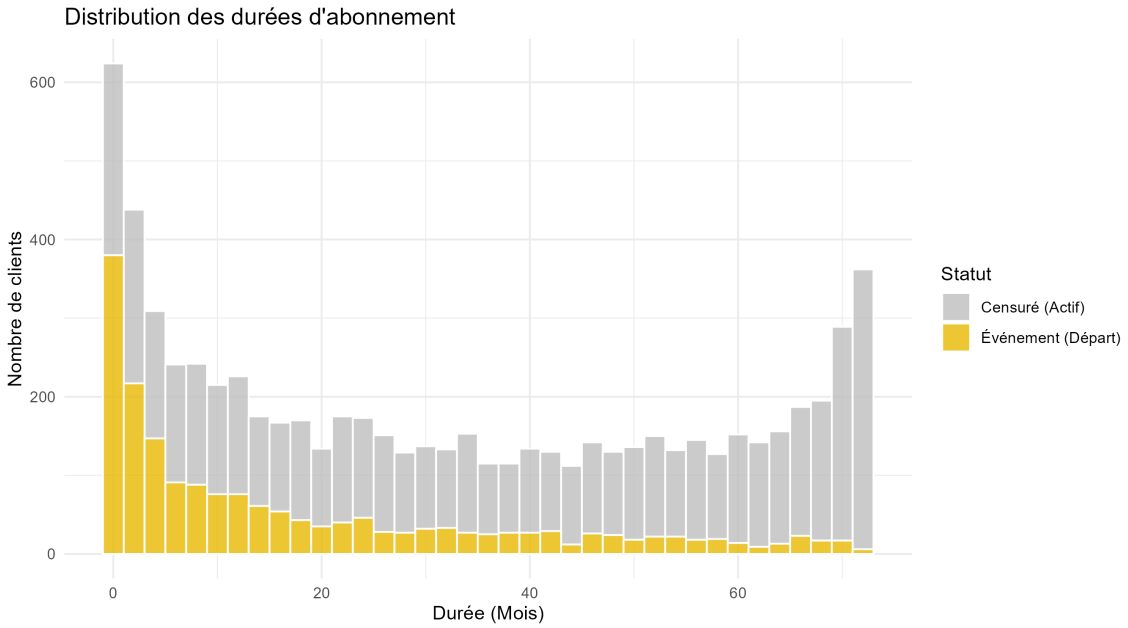


FIGURE 3 : Distribution des durées d'abonnement (événements vs censures).

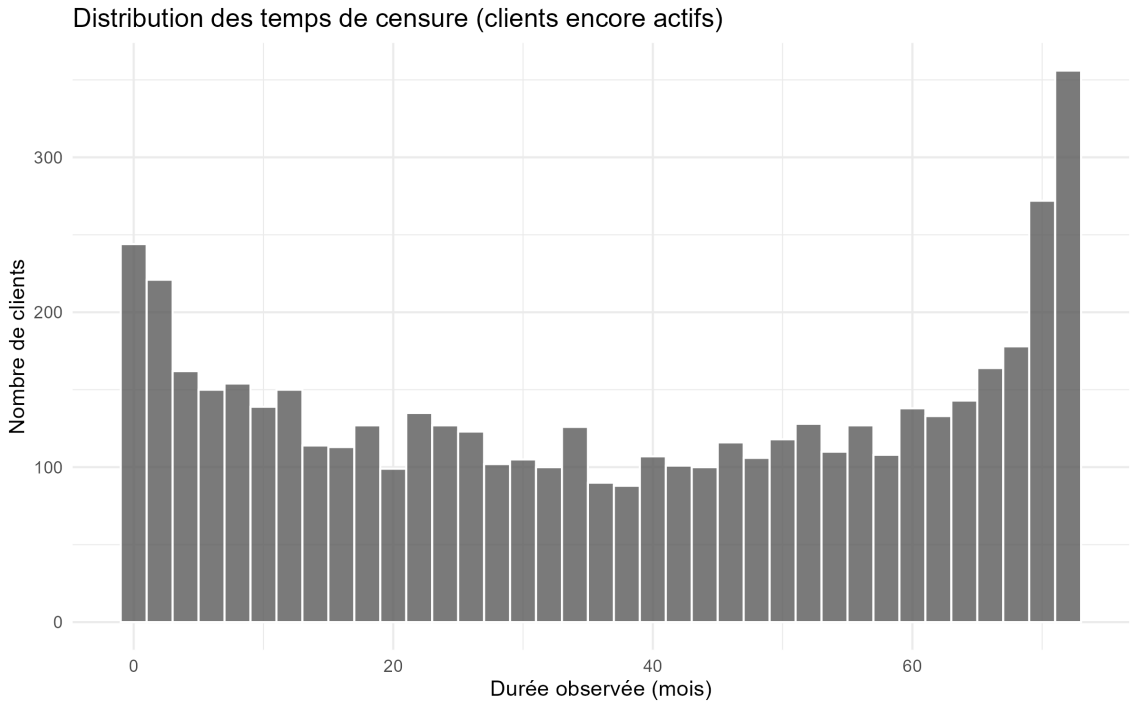


FIGURE 4 : Distribution des temps de censure (clients encore actifs).

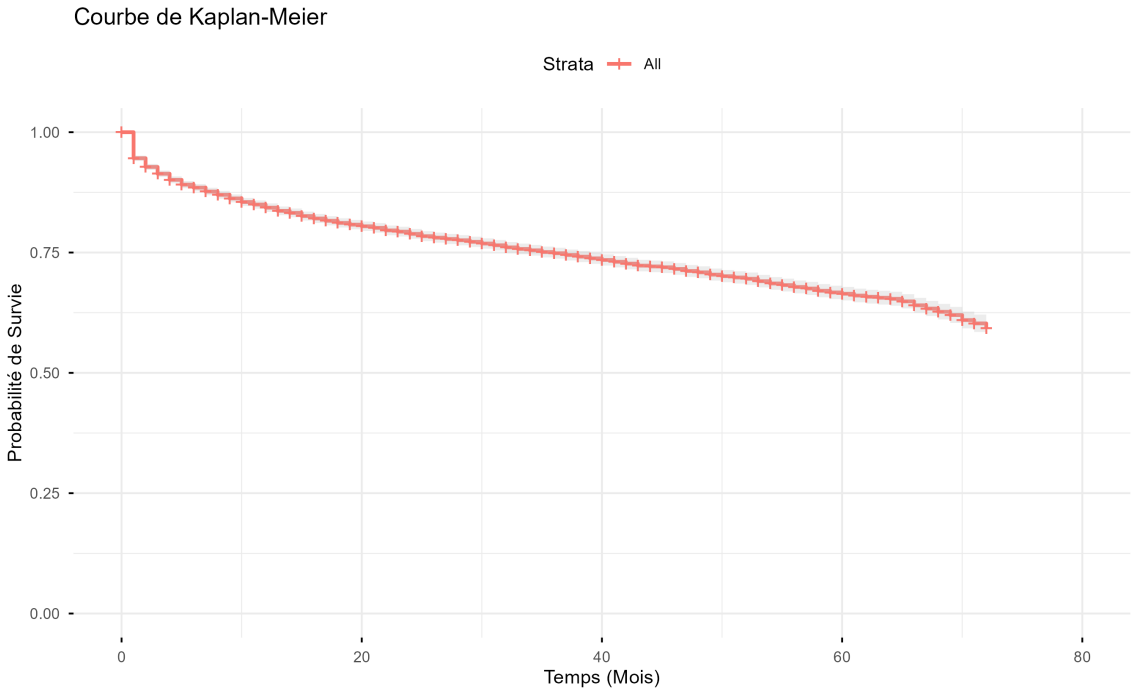


FIGURE 5 : Courbe de Kaplan–Meier (global) : survie avec IC et marques de censure.

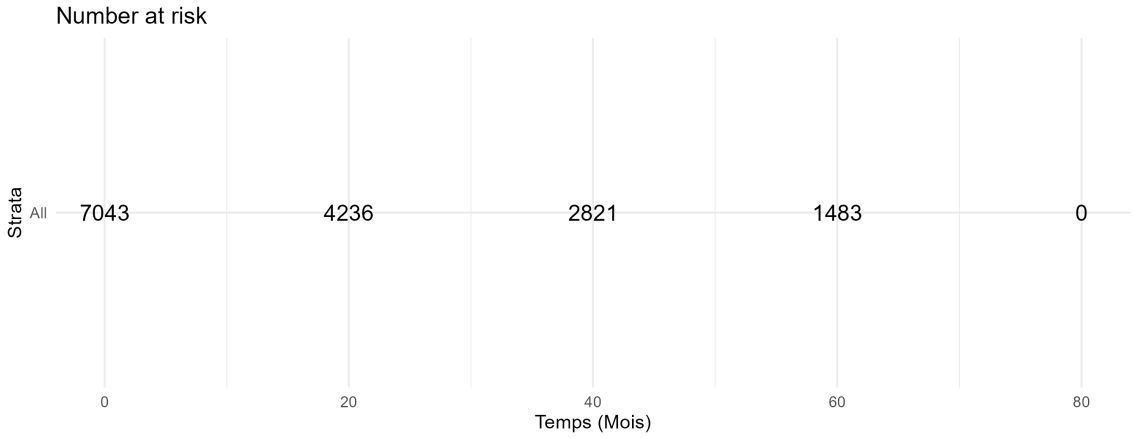


FIGURE 6 : Effectifs à risque au cours du temps (Kaplan–Meier).

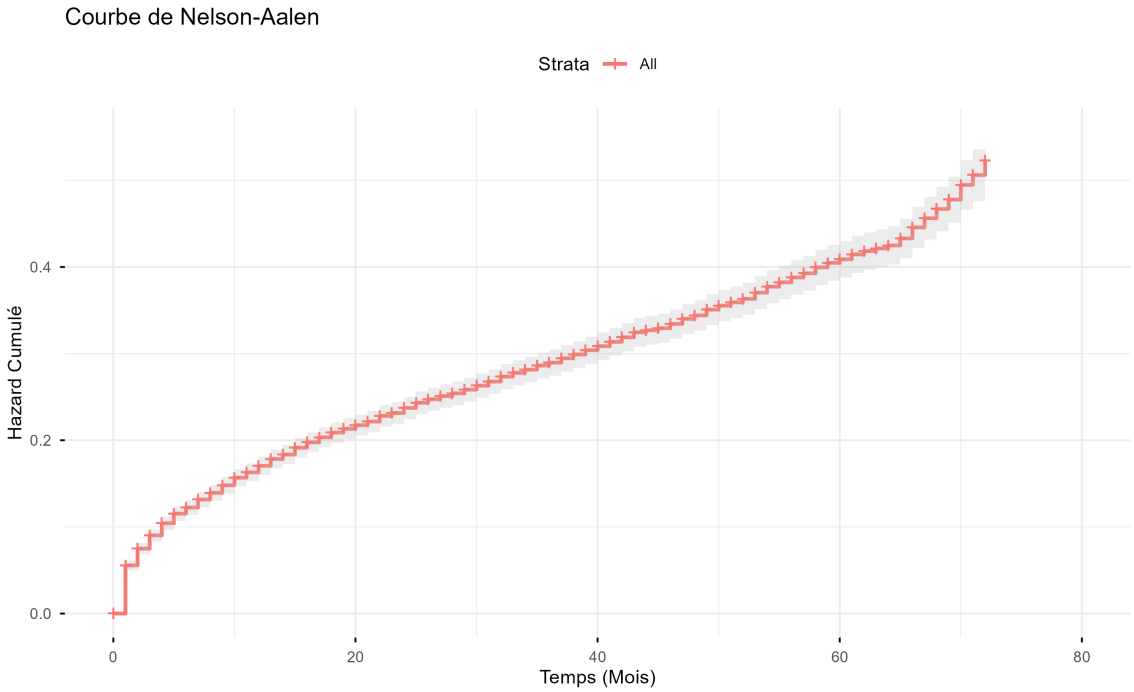


FIGURE 7 : Courbe de Nelson–Aalen (global) : hazard cumulé.

TABLE 1 : Résumé de la censure et des événements.

	N	Événements	Censures	Taux de censure
Telco	7043	1869	5174	73,46%

TABLE 2 : Repères Kaplan–Meier et Nelson–Aalen à horizons clés.

t (mois)	n_{risk}	$\widehat{S}(t)$	IC inf.	IC sup.	$\widehat{H}(t)$
1	7032	0,945 961	0,940 692	0,951 261	0,055 550
3	6181	0,913 725	0,907 128	0,920 369	0,090 219
6	5672	0,884 826	0,877 262	0,892 456	0,122 354
12	4974	0,843 200	0,834 441	0,852 050	0,170 537
24	3927	0,788 736	0,778 593	0,799 012	0,237 301
36	3051	0,748 545	0,737 372	0,759 889	0,289 594
48	2303	0,708 840	0,696 559	0,721 337	0,344 085
60	1483	0,664 404	0,650 584	0,678 517	0,408 808
72	362	0,592 790	0,573 665	0,612 553	0,522 775

TABLE 3 : Hazard discret mensuel $\widehat{h}(t) = d(t)/n(t)$ (quelques repères).

t (mois)	$n(t)$	$d(t)$	$\widehat{h}(t)$	$\widehat{S}(t)$
1	7032	380	0,054 039	0,945 961
2	6419	123	0,019 162	0,927 835
3	6181	94	0,015 208	0,913 725
6	5672	40	0,007 052	0,884 826
12	4974	38	0,007 640	0,843 200

Références

Références

[1] Cox, D. R. (1972). *Regression models and life-tables.* Journal of the Royal Statistical Society : Series B (Methodological), 34(2), 187–220.

[2] Celık, O., & Osmanglu, U. O. (2019). *Comparing techniques used in customer churn analysis.* Journal of Multidisciplinary Developments, 4(1), 30–38.

[3] Havrylovych, M., & Kuznietsova, N. *Survival analysis methods for churn prevention in telecommunications industry.*

Code R (préparation des données, graphiques et exports)

```r
library(survival)
library(survminer)
library(dplyr)
library(ggplot2)
library(Hmisc)

data <- read.csv("D:/2025-2026/Modele de duree et de comptage/Modele de duree/Telco-Customer-Churn.csv")

# =========================
# EXPORT PATHS (mme dossier que le CSV)
# =========================
csv_path <- "D:/2025-2026/Modele de duree et de comptage/Modele de duree/Telco-Customer-Churn.csv"
base_dir <- dirname(csv_path)

fig_dir <- file.path(base_dir, "figures")
tab_dir <- file.path(base_dir, "tables")

dir.create(fig_dir, showWarnings = FALSE, recursive = TRUE)
dir.create(tab_dir, showWarnings = FALSE, recursive = TRUE)

str(data)
describe(data)

# --- Correction TotalCharges (souvent import en texte + valeurs vides " ") ---
# On convertit proprement en numrique pour que is.na() marche vraiment
data$TotalCharges <- trimws(as.character(data$TotalCharges))
data$TotalCharges[data$TotalCharges == ""] <- NA
data$TotalCharges <- suppressWarnings(as.numeric(data$TotalCharges))

table(is.na(data$TotalCharges))
data$TotalCharges[is.na(data$TotalCharges)] <- mean(data$TotalCharges, na.rm = TRUE)
table(is.na(data$TotalCharges))

prop.table(table(data$Churn))

# =========================
# GRAPHIQUE 1 : Barplot churn (base R) -> export via png()
# =========================
png(filename = file.path(fig_dir, "01_barplot_churn.png"), width = 1200, height = 800, res = 150)
barplot(table(data$Churn), col = c('red', 'green'),
        main = 'Proportion Churn', ylab = 'Effectifs', xlab = 'Churn')
```

```r
dev.off()

# ========================
# BOXPLOTS (base R) -> export via png()
# ========================
png(filename = file.path(fig_dir, "02_boxplot_tenure_churn.png"), width = 1200, height = 800, res = 150)
boxplot(tenure ~ Churn, data = data, main = "Churn selon Tenure", col = c("red", "green"))
dev.off()

png(filename = file.path(fig_dir, "03_boxplot_monthlycharges_churn.png"), width = 1200, height = 800, res = 150)
boxplot(MonthlyCharges ~ Churn, data = data, main = "Churn selon MonthlyCharges", col = c("red", "green"))
dev.off()

png(filename = file.path(fig_dir, "04_boxplot_totalcharges_churn.png"), width = 1200, height = 800, res = 150)
boxplot(TotalCharges ~ Churn, data = data, main = "Churn selon TotalCharges", col = c("red", "green"))
dev.off()

data$ChurnBinary <- ifelse(data$Churn == "Yes", 1, 0)

S <- Surv(time = data$tenure, event = data$ChurnBinary)

head(S)

taux_censure <- 1 - mean(data$ChurnBinary)
taux_censure * 100

# ========================
# GRAPHIQUE 2 : Histogramme (ggplot) -> ggsave
# ========================
p_hist <- ggplot(data, aes(x = tenure, fill = factor(ChurnBinary))) +
  geom_histogram(binwidth = 2, color = "white", alpha = 0.8, position = "stack") +
  scale_fill_manual(
    values = c("gray", "#E7B800"),
    breaks = c(0, 1),
    labels = c("Censur (Actif)", "vnement (Dpart)")
  ) +
  labs(title = "Distribution des dures d'abonnement",
       x = "Dure (Mois)",
       y = "Nombre de clients",
       fill = "Statut") +
  theme_minimal()

print(p_hist)

ggsave(
  filename = file.path(fig_dir, "05_histogramme_durees.png"),
  plot = p_hist, width = 9, height = 5, dpi = 300
)

# ----------------------------
# Graphique : distribution des temps de censure
# ----------------------------
censure_df <- data %>% filter(ChurnBinary == 0)
```

```r

p_censure <- ggplot(censure_df, aes(x = tenure)) +
  geom_histogram(binwidth = 2, color = "white", alpha = 0.8) +
  labs(
    title = "Distribution des temps de censure (clients encore actifs)",
    x = "Dure observe (mois)",
    y = "Nombre de clients"
  ) +
  theme_minimal()

ggsave(
  filename = file.path(fig_dir, "05b_distribution_censure.png"),
  plot = p_censure,
  width = 8, height = 5, dpi = 300
)
print(p_censure)

# --- Kaplan-Meier  la main (discret, par mois) ---
km_hand <- data %>%
  group_by(time = tenure) %>%
  summarise(
    d_i = sum(ChurnBinary == 1),
    c_i = sum(ChurnBinary == 0),
    .groups = "drop"
  ) %>%
  arrange(time)

total_subjects <- nrow(data)

km_hand <- km_hand %>%
  mutate(
    cum_dropped = lag(cumsum(d_i + c_i), default = 0),
    n_i = total_subjects - cum_dropped,
    h_i = d_i / n_i,
    S_i = cumprod(1 - h_i)
  )

print(head(km_hand, 10))

# =========================
# EXPORT TABLES
# =========================
write.csv(km_hand, file.path(tab_dir, "table_km_hand.csv"), row.names = FALSE)

# --- Kaplan-Meier global ---
km_global <- survfit(S ~ 1, data = data)

g_km <- ggsurvplot(
  km_global,
  data = data,
  conf.int   = TRUE,
  risk.table = TRUE,
  censor     = TRUE,
  ggtheme    = theme_minimal(),
  xlab       = "Temps (Mois)",
  ylab       = "Probabilit de Survie",
  title      = "Courbe de Kaplan-Meier"
)
```

```r

print(g_km)
print(km_global)

ggsave(file.path(fig_dir, "06_kaplan_meier.png"), g_km$plot, width = 9, height = 5.5, dpi = 300)
ggsave(file.path(fig_dir, "06b_kaplan_meier_risktable.png"), g_km$table + theme_minimal(),
       width = 9, height = 3.5, dpi = 300)

km_global_df <- data.frame(
  time = km_global$time,
  n.risk = km_global$n.risk,
  n.event = km_global$n.event,
  n.censor = km_global$n.censor,
  surv = km_global$surv,
  std.err = km_global$std.err,
  lower = km_global$lower,
  upper = km_global$upper
)
write.csv(km_global_df, file.path(tab_dir, "table_km_global.csv"), row.names = FALSE)

# --- Nelson-Aalen (hazard cumul) ---
na_fit <- survfit(S ~ 1, data = data, type = "fh")

g_na <- ggsurvplot(
  na_fit,
  data = data,
  fun        = "cumhaz",
  conf.int   = TRUE,
  ggtheme    = theme_minimal(),
  xlab       = "Temps (Mois)",
  ylab       = "Hazard Cumul",
  title      = "Courbe de Nelson-Aalen"
)

print(g_na)

ggsave(file.path(fig_dir, "07_nelson_aalen_cumhaz.png"), g_na$plot, width = 9, height = 5.5,
       dpi = 300)

na_df <- data.frame(
  time = na_fit$time,
  n.risk = na_fit$n.risk,
  n.event = na_fit$n.event,
  n.censor = na_fit$n.censor,
  cumhaz = na_fit$cumhaz,
  std.err = na_fit$std.err,
  lower = na_fit$lower,
  upper = na_fit$upper
)
write.csv(na_df, file.path(tab_dir, "table_nelson_aalen.csv"), row.names = FALSE)

# --- Survie selon Contract + test log-rank ---
km_contract <- survfit(S ~ Contract, data = data)

g_contract <- ggsurvplot(
  km_contract,
  data = data,
  conf.int   = TRUE,
```

```r
  pval       = TRUE,
  risk.table = TRUE,
  ggtheme    = theme_minimal(),
  xlab       = "Temps (Mois)",
  title      = "Impact du Type de Contrat sur la Rtention"
)

print(g_contract)
print(km_contract)

diff_contract <- survdiff(S ~ Contract, data = data)
print(diff_contract)

ggsave(file.path(fig_dir, "08_km_contract.png"), g_contract$plot, width = 9, height = 5.5, dpi = 300)
ggsave(file.path(fig_dir, "08b_km_contract_risktable.png"), g_contract$table + theme_minimal(), width = 9, height = 3.5, dpi = 300)

km_contract_df <- data.frame(
  time = km_contract$time,
  surv = km_contract$surv,
  strata = rep(names(km_contract$strata), km_contract$strata)
)
write.csv(km_contract_df, file.path(tab_dir, "table_km_contract_surv.csv"), row.names = FALSE)

sink(file.path(tab_dir, "logrank_contract.txt"))
print(diff_contract)
sink()

# --- Survie selon InternetService + test log-rank ---
km_internet <- survfit(S ~ InternetService, data = data)

g_internet <- ggsurvplot(
  km_internet,
  data = data,
  conf.int   = TRUE,
  risk.table = TRUE,
  ggtheme    = theme_minimal(),
  title      = "Survie selon le Service Internet"
)

print(g_internet)
print(km_internet)

diff_internet <- survdiff(S ~ InternetService, data = data)
diff_internet

ggsave(file.path(fig_dir, "09_km_internet.png"), g_internet$plot, width = 9, height = 5.5, dpi = 300)
ggsave(file.path(fig_dir, "09b_km_internet_risktable.png"), g_internet$table + theme_minimal(), width = 9, height = 3.5, dpi = 300)

km_internet_df <- data.frame(
  time = km_internet$time,
  surv = km_internet$surv,
  strata = rep(names(km_internet$strata), km_internet$strata)
)
write.csv(km_internet_df, file.path(tab_dir, "table_km_internet_surv.csv"), row.names = FALSE)
```

```r

sink(file.path(tab_dir, "logrank_internetservice.txt"))
print(diff_internet)
sink()

# --- Survie selon PaymentMethod + test log-rank ---
km_payment <- survfit(S ~ PaymentMethod, data = data)

g_payment <- ggsurvplot(
  km_payment,
  data = data,
  conf.int   = TRUE,
  risk.table = TRUE,
  ggtheme    = theme_minimal(),
  title      = "Survie selon la Mthode de Paiement"
)

print(g_payment)
print(km_payment)

diff_payment <- survdiff(S ~ PaymentMethod, data = data)
diff_payment

ggsave(file.path(fig_dir, "10_km_paymentmethod.png"), g_payment$plot, width = 9, height = 5.5,
    dpi = 300)
ggsave(file.path(fig_dir, "10b_km_paymentmethod_risktable.png"), g_payment$table +
    theme_minimal(), width = 9, height = 3.5, dpi = 300)

km_payment_df <- data.frame(
  time = km_payment$time,
  surv = km_payment$surv,
  strata = rep(names(km_payment$strata), km_payment$strata)
)
write.csv(km_payment_df, file.path(tab_dir, "table_km_paymentmethod_surv.csv"), row.names =
    FALSE)

sink(file.path(tab_dir, "logrank_paymentmethod.txt"))
print(diff_payment)
sink()

# =========================
# BONUS : export taux censure + stats simples en CSV
# =========================
resume_simple <- data.frame(
  N = nrow(data),
  events = sum(data$ChurnBinary == 1),
  censures = sum(data$ChurnBinary == 0),
  taux_censure = (1 - mean(data$ChurnBinary))
)
write.csv(resume_simple, file.path(tab_dir, "resume_censure.csv"), row.names = FALSE)
```

Usage de l'IA

Table 4 : Transparence sur l'utilisation de l'IA dans le projet (modèles de durée)

Activité / livrable	Outils / ressources	Réalisé par	Intervention de l'IA (ChatGPT)
Recherche bibliographique / références	Google Scholar	Groupe	Aucun
Sélection et validation des sources	Google Scholar + lecture des articles	Groupe	Aucun
Rédaction du rapport (contenu : introduction, méthodologie, résultats, interprétation, conclusion)	Rédaction par le groupe	Groupe	Aucun
Code d'analyse (R : préparation des données, descriptifs, Kaplan-Meier, Cox, tests, graphiques)	R / RStudio	Groupe	Aucun
Vérification / ajustements du code	R / RStudio	Groupe	Aucun
Mise en forme du rapport en LaTeX (structure, packages, renvois `\ref`, figures en annexe, corrections de compilation)	LaTeX (Overleaf/-TeX) + ChatGPT	Groupe (avec assistance)	Assistance technique (mise en forme LaTeX uniquement)