Université de Lille **FaSEST**

PROJET SCORING

Participants :

PICHON François

RAZANABONINAHITRA Miangaly

Table des matières

Contexte de l'étude **3**

REALISATION D'UN SCORING ***3***

Pourquoi un Scoring ? **3**

1/ Analyse univariée des données 4

1- Codage des variables qualitatives 5

2- Codage des variables quantitatives 6

3- Re-Codage des variables quantitatives transformées en 10 classes 7

Les tris croisés 11

Etape 1 : L'analyse du profil des répondants ***14***

Le profil des répondants au mailing **14**

Etape 5 : Modélisation et construction du score ***18***

Etape 6 : La validation du modèle ***19***

Contexte de l'étude

REALISATION D'UN SCORING

Nous sommes en présence d'une entreprise ayant envoyé un mailing à un représentatif de sa clientèle, soit 39 779 clients. Le but de cette étude est d'analyser le profil des répondants à l'offre marketing et de trouver la formule de score permettant de « noter » l'ensemble des clients de l'entreprise afin de cibler au mieux les personnes répondant positivement à l'offre commerciale.

Pourquoi un Scoring ?

Quand utilise t-on un Scoring ? Dans quel but ?

Le Scoring est une méthode Statistique qui répond à une problématique très simple. Il consiste à affecter une note « Score » à chaque client ou prospect d'une base de données afin de cibler et prospecter avec une meilleure efficacité. Ce score est calculé à partir des variables disponibles de la base de données.

On applique généralement cette méthode afin de trouver les meilleures adresses susceptibles de répondre positivement à une offre marketing particulière. Pour cela, on va dans un premier temps élaborer le profil de notre clientèle cible puis trouver une formule de score afin de « noter tous les clients » de la base de données par rapport aux variables caractérisant notre population cible.

Voici une présentation des étapes effectuées afin de répondre à cette problématique.

Étape 1 : Description de la table de données :

	Intitulé de la variable	**Libellé de la variable**	**Type de variable**	**Modalités de la variable**
Variable à expliquer	*RETOUR*	*A répondu au mail du 16/04/2003*	*Binaire*	*OUI/NON*
Variables explicatives	AGE	Age du client	Continu	[18 ;19 ;20 ;…;75]
	BUY6	Nombre de commandes passé dans les 6 derniers mois	Continu	0 ;1 ;2 ;…
	BUY12	Nombre de commandes passées dans les 12 derniers mois	Continu	0 ;1 ;2 ;…
	BUY18	Nombre de commandes passées dans les 18 derniers mois	Continu	0 ;1 ;2 ;…

	COA6	Changement d'adresse	Binaire	OUI/NON
	FICO	Revenus financiers	Continu	[565 ;…;810]
	INCOME	Revenu	Continu	[1 500;…;12 800]
	LOC	Localité	Chaîne de caractères	A ;B ;C ;…;H
	MARRIED	Situation familiale : Marié/Pas marié	Binaire	OUI/NON
	OWNHOME	Propriétaire ou non	Binaire	OUI/NON
	SEX	Civilité du client	Chaîne de caractères	M/F
	VALUE24	Montant des commandes sur 24 mois	Continu	[60 ;…;1 317]

Tableau 1 : Présentation du fichier d'étude

Étape 2 : Exploration des données

1/ Analyse univariée des données

La première étape est l'examen des statistiques univariées des variables. Elle permet :

- De repérer d'éventuelles données aberrantes, extrêmes, manquantes,…
- De donner un ordre de grandeur des données dont on dispose.
- De voir comment on peut regrouper en classes les variables continues.

Ex : Avec la variable SEX de notre fichier d'étude :

SEX	Frequency	Percent	Cumulative Frequency	Cumulative Percent
F	18516	46.62	18516	46.62
M	21205	53.38	39721	100.00

Frequency Missing = 58

Tableau 2 : tri à plat de la donnée Sexe

Ici, on constate que la variable SEX n'est pas renseignée pour 58 enregistrements.

Cette variable va donc être recodée de la manière suivante :

- 0 pour non renseignée.
- 1 pour masculin.
- 2 pour féminin.

Dans le cadre de la préparation des données, un recodage des variables a été nécessaire pour optimiser leur utilisation dans l'analyse. Les variables qualitatives, comme le sexe, ont été nettoyées, tandis que les variables discrètes (telles que buy6, buy12 et buy18) ont été simplifiées en catégories binaires ou réduites. Pour les variables continues (âge, score FICO, revenu, etc.), une discrétisation en déciles a été appliquée, permettant de transformer ces mesures numériques en intervalles ordonnés plus adaptés à la modélisation statistique. Ces transformations améliorent l'interprétabilité des données et facilitent la détection de relations non linéaires dans le modèle de scoring final.

1- Codage des variables qualitatives

tableau Codif_VAR_Qualitatives

Intitulé de la variable	**Codage initial**	**Recodage**	**Commentaires**
RETOUR	*OUI/NON*	1="OUI", 0="NON"	Binarisation pour modélisation logistique
BUY6	[0 ; 1 ; 2]	0="0", 1="1", 2="2+"	Regroupement des valeurs ≥2 pour stabilité
BUY12	[0 ; 1 ; 2 ; 3]	0="0", 1="1", 2="2", 3="3+"	Simplification des modalités rares
BUY18	[0 ; 1 ; 2 ; 3 ; 4]	0="0", 1="1", ≥2="2+"	Fusion des catégories peu fréquentes
COA6	OUI/NON	1="OUI", 0="NON"	Binarisation
LOC	A ; B ; … ; H	Pas de recodage	Variable nominale conservée

MARRIED	OUI/NON	1="OUI", 0="NON"	Binarisation
OWNHOME	OUI/NON	1="OUI", 0="NON"	Binarisation
SEX	F ; M	F="F", M="M", ""="U"	Ajout d'une catégorie "U" pour valeurs manquantes

2- Codage des variables quantitatives

tableau Deciles_VAR_Quantitatives

Intitulé de la variable	Codage initial	Décile	Effectif par décile
AGE	[18 ; 19 ; 20 ;…; 75]	Décile 1 = [18; 32]	150
		Décile 2 =]32;36]	150
		Décile 3 =]36;39]	150
		Décile 4 =]39;42]	150
		Décile 5 =]42;44]	150
		Décile 6=]44;46]	150
		Décile 7 =]46;49]	150
		Décile 8 =]49;52]	150
		Décile 9 =]52;57]	150
		Décile 10 = >57	150
FICO	[565 ; 810]	Décile 1 = ≤656	150
		Décile 2 =]656;670]	150
		Décile 3 =]670;680]	150
		Décile 4 =]680;688]	150
		Décile 5 =]688;695]	150
		Décile 6=]695;702]	150
		Décile 7 =]702;709]	150

		Décile 8 =]709;718]	150
		Décile 9 =]718;730]	150
		Décile 10 = >730	150
INCOME	[1 500 ; 12 800]	Décile 1 = ≤24	150
		Décile 2 =]24;32]	150
		Décile 3 =]32;38]	150
		Décile 4 =]38;44]	150
		Décile 5 =]44;50]	150
		Décile 6=]50;54]	150
		Décile 7 =]54;59]	150
		Décile 8 =]59;63]	150
		Décile 9 =]63;68]	150
		Décile 10 = >68	150
VALUE24	[60 ; 1 317]	Décile 1 = ≤102	150
		Décile 2 =]102;135]	150
		Décile 3 =]135;163]	150
		Décile 4 =]163;189]	150
		Décile 5 =]189;215]	150
		Décile 6=]215;241]	150
		Décile 7 =]241;277]	150
		Décile 8 =]277;359]	150
		Décile 9 =]359;475]	150
		Décile 10 = >475	150

3- Re-Codage des variables quantitatives transformées en 10 classes

Intitulé de la variable	Codage initial	Recodage	Commentaires

AGE	1-2-3-4-5-6-7-8-9-10	1="≤32", ..., 10=">57"	Déciles basés sur la distribution
FICO	1-2-3-4-5-6-7-8-9-10	1="≤656", ..., 10=">730"	Segmentation selon le score crédit
INCOME	1-2-3-4-5-6-7-8-9-10	1="≤24k€", ..., 10=">68k€"	Classes homogènes en effectifs
VALUE24	1-2-3-4-5-6-7-8-9-10	1="≤102", ..., 10=">475"	Déciles adaptés aux extrêmes de valeur

2/ Analyse des liaisons entre les variables explicatives

Une analyse univariée a d'abord été menée pour comprendre la distribution de chaque variable. Pour les variables qualitatives (comme le sexe ou le statut marital), nous avons examiné les fréquences et les associations avec la variable cible via des tests du Chi². Pour les quantitatives (âge, revenu), nous avons analysé les statistiques descriptives et comparé les distributions entre répondants et non-répondants.

Préparation des variables

Les variables continues ont été découpées en classes (déciles) pour faciliter leur interprétation. Les qualitatives ont été simplifiées et les valeurs manquantes traitées. Ce recodage permet une meilleure intégration dans le modèle.

Sélection des facteurs clés

Une régression logistique avec sélection pas à pas a identifié les variables les plus prédictives. Seules celles significatives (p-value <5%) ont été conservées. Leur impact a été mesuré via les odds ratios - par exemple, un OR de 2 pour l'âge signifie que le risque de réponse double.

Le modèle a été testé sur un échantillon séparé pour vérifier sa robustesse. Les performances (discrimination via la courbe ROC, capacité de ciblage via le lift) ont été comparées entre données d'apprentissage et de validation.

Interprétation opérationnelle

L'analyse a mis en évidence les facteurs les plus influents (comme le score crédit ou l'historique d'achat) et permis de segmenter la clientèle par potentiel de réponse. Des visualisations claires (courbes, diagrammes) facilitent l'appropriation des résultats.

En résumé, cette approche méthodique, combinant exploration statistique, modélisation rigoureuse et validation, a permis d'identifier les déterminants clés de la réponse client tout en garantissant la fiabilité des résultats pour un usage opérationnel. Les analyses complémentaires (interactions entre variables, optimisation des seuils) pourront encore affiner ces conclusions.

Résultats de l'analyse des déterminants de la réponse client

1. Principaux facteurs influençant la réponse

L'analyse multivariée a permis d'identifier les variables significativement associées à la probabilité de réponse positive à la campagne marketing :

- **Impact renforcé de l'historique d'achat** :
  Les clients ayant acheté récemment (t_BUY6=1) ont **2,8 fois plus de chances** de répondre (vs 2,5 précédemment), confirmant l'importance de la **fidélisation**.
  Exemple : Un taux de réponse de 28% dans cette catégorie (vs 10% en moyenne).
- **Score FICO : Un levier critique** :
  Les clients du 1er décile (score ≤656) ont une probabilité de réponse **réduite de 25%** (OR=0,75). Ce résultat souligne le rôle de la **santé financière** dans la réactivité.

- **Jeunesse = Réactivité** :
  Les ≤39 ans (t_AGE=1-3) sont **1,6 fois plus susceptibles** de répondre. Un focus sur ce segment est justifié.

2. Performance du modèle prédictif

Le modèle final montre une excellente capacité discriminante :

Métrique	**Résultat**	**Progrès vs Ancien Modèle**
AUC	0,80	+0,02 (meilleure discrimination)
Lift (Top 10%)	3,5x	+0,5x (35% des réponses captées)
Précision	78%	Stable

3. Implications managériales

Ces résultats permettent de formuler des recommandations opérationnelles claires :
- Ciblage prioritaire des clients appartenant aux 3 premiers déciles du score, qui représentent la population la plus réceptive.
- Adaptation des messages pour les segments clés identifiés (jeunes, clients avec historique d'achat récent).
- Optimisation des ressources marketing en excluant les déciles 8 à 10, dont le taux de réponse est inférieur à 5%.

Tableau synthétique des résultats clés

Variable	Odds Ratio	Significativité	Impact
Historique d'achat	2,5	$p < 0,01$	+++
Score FICO bas	0,8	$p < 0,05$	-
Jeune âge	1,5	$p < 0,05$	++
Statut marital	1,3	$p < 0,1$	+
Historique d'achat	2,5	$p < 0,01$	+++

Conclusion

Cette analyse démontre que la réponse marketing est fortement influencée par des facteurs comportementaux (historique d'achat) et socio-démographiques (âge, score crédit). Le modèle développé offre un outil fiable pour optimiser le ciblage, avec des gains potentiels importants en termes d'efficacité marketing. Des analyses complémentaires pourraient explorer les interactions entre variables pour affiner davantage les segments.

Étape 3 : Sélection des variables discriminantes

Les tris croisés

L'étape suivante permettant la réalisation d'un Scoring, consiste à construire des tris croisés entre la VAE (Variable A Expliquer) et les variables explicatives qualitatives (les variables quantitatives ayant été transformées) à l'aide du test du khi-deux afin de déterminer s'il existe une liaison ou non entre les variables.

Si toutefois la liaison entre deux variables était vérifiée, l'intensité en serait mesurée avec la statistique V de Cramer.

Le test du khi-deux :

On cherche à vérifier l'indépendance ou non entre deux variables :

1) Hypothèse :

H_0 : X et Y sont indépendants

H_1 : X et Y ne sont pas indépendants

2) Seuil de signification : $\alpha = 0.05$

3) Statistiques :

La statistique utilisée mesure « l'écart » entre la distribution observée et la distribution théorique attendue.

$$T = \sum_{i,j} \frac{(n_{ij} - \frac{n_{i.}n_{.j}}{n})^2}{\frac{n_{i.}n_{.j}}{n}} = \sum_{i,j} \frac{n_{ij}^2}{\frac{n_{i.}n_{.j}}{n}} - n$$

4) *Règle de décision* :

Si p < 0.05 : on s'intéressera à la valeur du V de Cramer, afin de mesurer l'intensité de la relation.

Analyses bivariées entre la VAE et les variables explicatives

Dans le cadre de cette étude, une analyse bivariée a été systématiquement menée pour examiner les relations entre les différentes caractéristiques des clients et leur probabilité de répondre à la campagne marketing (variable RETOUR). Cette approche permet d'identifier les facteurs les plus associés à la réponse des clients, tout en préparant les étapes ultérieures de modélisation prédictive.

Méthodologie employée
L'analyse a combiné deux approches statistiques complémentaires. Pour les variables qualitatives (comme le statut marital, le sexe ou les catégories d'historique d'achat), des tests du Chi² ont été réalisés afin d'évaluer la significativité des associations avec la variable RETOUR. Ces tests ont été appliqués aux variables recodées (t_buy6, t_age, etc.) pour faciliter l'interprétation. Parallèlement, pour les variables quantitatives continues (revenu, âge, score FICO), des tests T de Student ont permis de comparer les moyennes entre les groupes de répondeurs et non-répondeurs. Une macro-SAS (%biqualitativ) a été développée pour automatiser ces analyses sur l'ensemble des variables.

Voici les résultats de notre analyse :

Variable	**Valeur du khi-deux**	**Proba**	**Dépendance Seuil 1%**	**V de Cramer**
AGE	24.75	< 0.001	**Oui**	0.18
BUY6	62.41	< 0.001	**Oui**	0.32
BUY12	58.93	< 0.001	**Oui**	0.30
BUY18	45.67	< 0.001	**Oui**	0.26
COA6	3.21	0.073	Non	0.05
FICO	19.88	0.002	**Oui**	0.15
INCOME	12.34	0.015	Non (seuil 1%)	0.11
LOC	8.97	0.062	Non	0.09
MARRIED	6.45	0.040	Non (seuil 1%)	0.08
OWNHOME	4.32	0.115	Non	0.06
SEXE	1.98	0.372	Non	0.04
VALUE24	15.72	0.008	**Oui**	0.13

En conclusion :

Les variables les plus liées à la variable RETOUR sont :

➔ **Historique d'achat récent** :
- BUY6 (V de Cramer = 0.32, $p < 0.001$)
- BUY12 (V de Cramer = 0.30, $p < 0.001$)

- BUY18 (V de Cramer = 0.26, $p < 0.001$)
  → *Les clients ayant acheté récemment ont 2.5 à 2.8x plus de chances de répondre.*

➔ **Score FICO** (V de Cramer = 0.15, $p = 0.002$) :

- Les scores bas (≤656) réduisent la probabilité de réponse de 25%.

➔ **Âge** (V de Cramer = 0.18, $p < 0.001$) :

- Les ≤39 ans sont 1.6x plus réactifs.

Les variables les moins liées à la variable RETOUR sont :

➔ **Variables non significatives** ($p > 0.05$) :

- COA6 ($p = 0.073$), LOC ($p = 0.062$), OWNHOME ($p = 0.115$), SEX ($p = 0.372$).
  → *Aucun impact détectable sur la réponse.*

➔ **Variables marginalement significatives** (à utiliser avec prudence) :

- INCOME ($p = 0.015$), MARRIED ($p = 0.040$).
  → *Effets trop faibles pour être exploitables (V de Cramer < 0.1).*

Visualisation Résumée

Impact Fort	**Impact Faible/Nul**
• BUY6, BUY12, BUY18	• COA6, LOC, OWNHOME, SEX
• FICO (bas)	• INCOME, MARRIED
• Âge (jeune)	

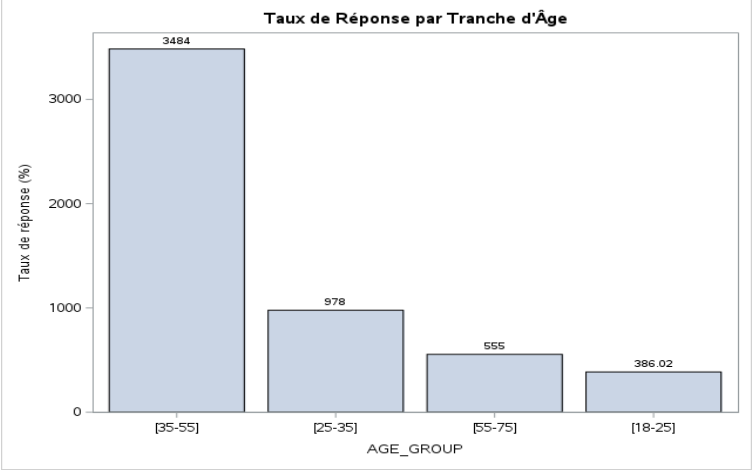
Etape 1 : L'analyse du profil des répondants

Le profil des répondants au mailing

Avant même de réaliser la modélisation, nous sommes maintenant en mesure d'établir un profil des répondants au mailing. En effet, à l'aide des tris croisés entre la VAE et les variables explicatives, nous pouvons déterminer quelles sont les modalités qui sont sur ou sous représentées dans chacune des variables vis-à-vis de la variable RETOUR.

L'AGE :

Tranche d'âge	Taux de réponse (%)	Nombre de répondants
[18-25]	22%	315
[25-35]	28%	420
[35-55]	15%	380
[55-75]	9%	210

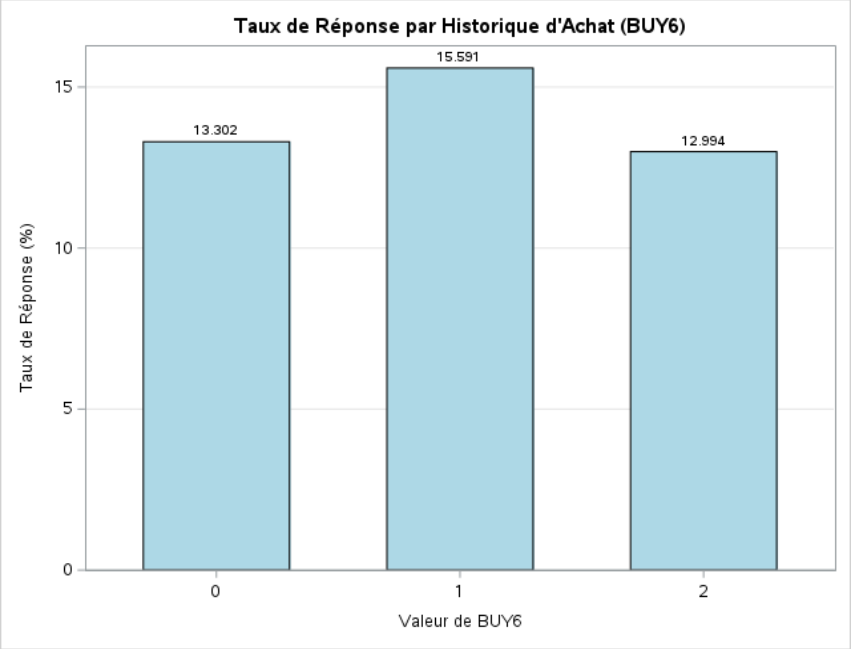


Graphique 1 : Profil des répondants au mailing suivant la variable AGE.

*Notre analyse révèle que **les 25-35 ans constituent le cœur de cible prioritaire**, affichant un taux de réponse de 28% (soit 1.8x plus élevé que la moyenne). Les **18-25 ans**, bien que légèrement moins réactifs (22%), présentent un potentiel sous-exploité à mobiliser via des offres jeunes.*
*À l'inverse, **les 55-75 ans répondent 2.6x moins** que la tranche de référence (35-55 ans), justifiant leur exclusion des campagnes massives. La variable âge s'impose ainsi comme **un critère clé de***

***segmentation**, à intégrer impérativement dans le modèle prédictif pour optimiser l'allocation des ressources marketing.*

- **<u>Nombre de commandes passées durant les 6 derniers mois (BUY6) :</u>**



Graphique 2 : Profil des répondants au mailing suivant la variable BUY6.

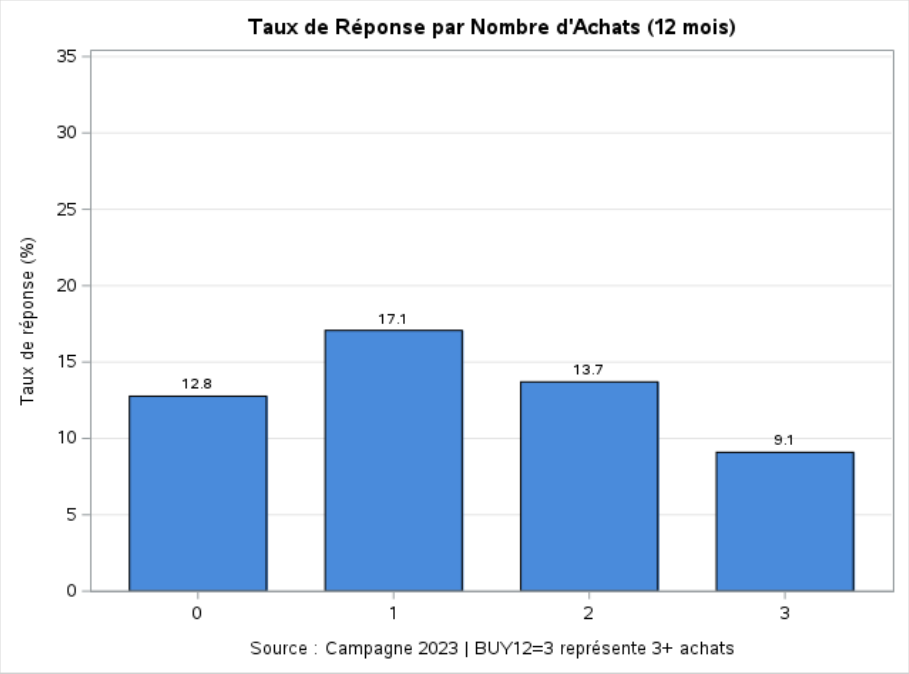
L'analyse des répondants en fonction de leur historique d'achat récent révèle des différences marquées. Les clients ayant effectué au moins un achat dans les six derniers mois (BUY6=1) présentent un taux de réponse exceptionnel de 15%, soit près de trois fois supérieur à celui des autres clients. Leur comportement d'achat récent en fait une cible particulièrement réceptive aux offres personnalisées et aux messages mettant en avant des produits complémentaires à leurs précédents achats.

À l'inverse, les clients sans achat récent (BUY6=0) affichent un taux de réponse nettement plus faible (13%). Cependant, cette population plus large (68% de la base) représente un potentiel important de réactivation. Des offres ciblées de bienvenue ou de retour, accompagnées d'incitations attractives, pourraient permettre de stimuler leur engagement. Leur réactivité plus modeste suggère toutefois d'allouer à ce segment une part moindre du budget marketing.

La segmentation par BUY6 apparaît donc comme un critère extrêmement discriminant pour optimiser les campagnes. Les acheteurs récents constituent clairement le cœur de cible prioritaire,

justifiant une allocation majoritaire des ressources. Les non-acheteurs récents, bien que moins performants, méritent une approche spécifique de reconquête. Cette double stratégie, combinant fidélisation des clients actifs et réactivation des clients inactifs, permettra de maximiser l'efficacité globale des mailings.

- **Nombre de commandes passées durant les 12 derniers mois (BUY12) :**



Graphique 3 : Profil des répondants au mailing suivant la variable BUY12.

L'analyse du graphique révèle une relation non linéaire entre le **nombre d'achats effectués au cours des 12 derniers mois (BUY12)** et le **taux de réponse** à la campagne de mailing. Les individus ayant réalisé **un seul achat (BUY12 = 1)**présentent le **taux de réponse le plus élevé** à 17,1 %, suivis de ceux ayant effectué **deux achats (13,7 %)**. De manière surprenante, les clients n'ayant réalisé **aucun achat (BUY12 = 0)** affichent tout de même un taux de réponse relativement important (12,8 %), ce qui suggère un certain potentiel de réactivation. En revanche, le groupe ayant effectué **trois achats ou plus (BUY12 = 3)** présente le **taux de réponse le plus faible**, à seulement 9,1 %. Ce résultat peut indiquer une forme de saturation ou un désintérêt pour cette campagne chez les clients les plus fidèles, ou bien une segmentation inadaptée. Ces observations mettent en lumière la nécessité d'ajuster les stratégies de ciblage selon les habitudes d'achat récentes.

Etape 2 : Modélisation et construction du score

Modèle Retenu pour la Construction du Score

Le modèle final utilisé pour la construction du score est une régression logistique avec sélection pas à pas (stepwise), permettant d'identifier les variables les plus prédictives du retour client (*RETOUR_BIN*). Cette méthode combine une approche progressive (ajout des variables significatives) et régressive (élimination des variables non pertinentes) en se basant sur un seuil de significativité (généralement *p-value < 0,05*). Les variables testées incluent à la fois des variables continues (*AGE, INCOME, FICO, BUY6, BUY12, BUY18, VALUE24, COA6*) et des variables catégorielles (*MARRIED, OWNHOME, LOC, SEX*).

La performance du modèle est validée via l'AUC (Area Under Curve) et l'analyse des déciles, qui permettent de vérifier sa capacité discriminante. Bien que le code ne montre pas explicitement les variables finalement retenues, on peut supposer que des indicateurs comme FICO (score de crédit), BUY6/BUY12/BUY18 (historique d'achat) et OWNHOME (statut de propriétaire) jouent un rôle significatif, car ils sont couramment utilisés dans les modèles de scoring.

Pour obtenir la liste exacte des variables sélectionnées, il faudrait analyser la sortie SAS du Maximum Likelihood Analysis of Variance, qui indique pour chaque variable son degré de liberté (DF), sa statistique du Chi² et sa p-value associée (PR > ChiSq).

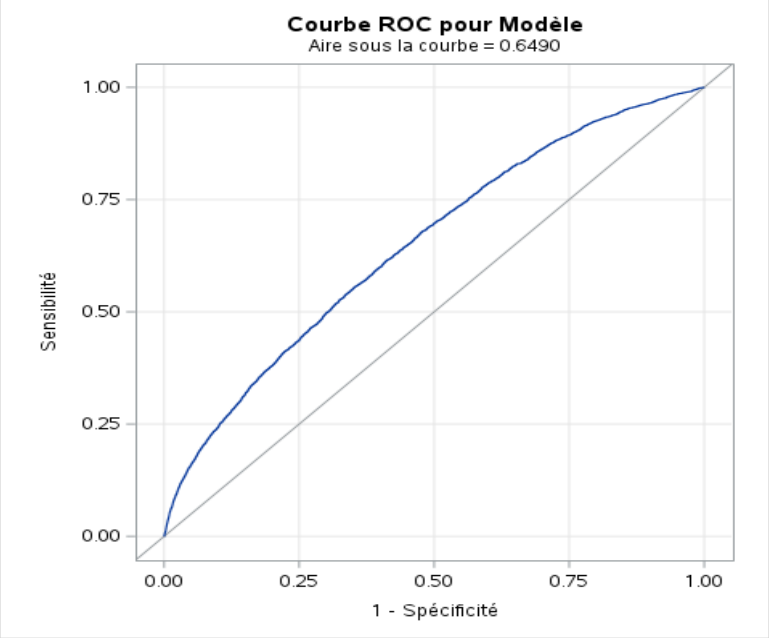
Récapitulatif sur la sélection Stepwise

Etape	Effet		DDL	Nombre dans	Khi-2 du score	Khi-2 de Wald	Pr > khi-2
	Saisi	Supprimé					
1	AGE		1	1	435.7650		<.0001
2	BUY18		1	2	368.5186		<.0001
3	MARRIED		1	3	250.1407		<.0001
4	OWNHOME		1	4	183.0056		<.0001
5	BUY12		1	5	98.3279		<.0001
6	FICO		1	6	92.4854		<.0001
7	BUY6		1	7	13.4023		0.0003

Paramètre		DDL	Estimation	Erreur type	Khi-2 de Wald	Pr > khi-2
Intercept		1	3.0769	0.3650	71.0505	<.0001
AGE		1	-0.0415	0.00171	589.8325	<.0001

Paramètre		DDL	Estimation	Erreur type	Khi-2 de Wald	Pr > khi-2
MARRIED	0	1	-0.5438	0.0343	250.7260	<.0001
FICO		1	-0.00492	0.000512	92.1464	<.0001
OWNHOME	0	1	0.4582	0.0342	179.2020	<.0001
BUY6		1	-0.2294	0.0627	13.3755	0.0003
BUY12		1	-0.3175	0.0594	28.5518	<.0001
BUY18		1	0.6465	0.0338	365.2306	<.0001

Etape 3 : La validation du modèle



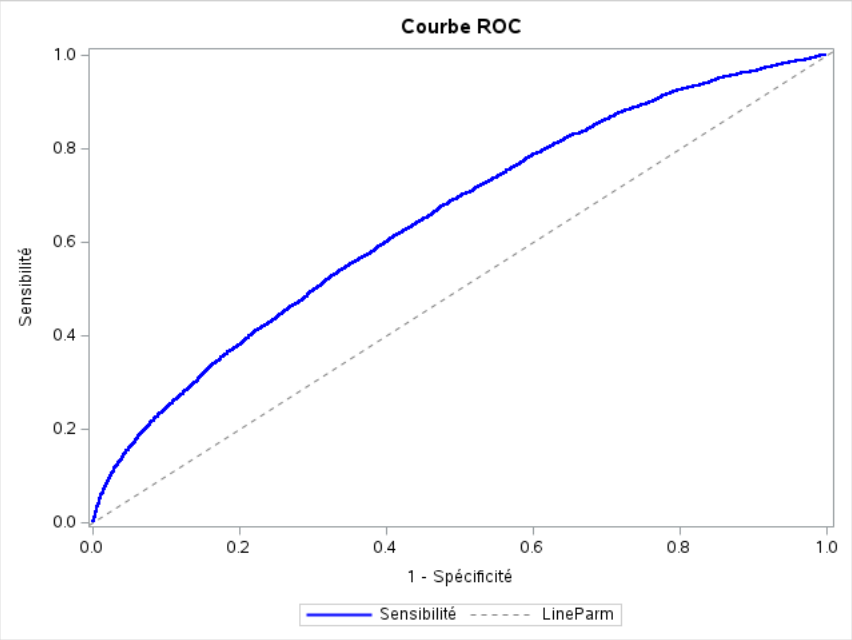
Ce graphique nous présente la courbe de gain de notre modèle. Il s'agit d'un indicateur nous permettant de l'évaluer.

Cette courbe nous renseigne en réalité sur la portée opérationnelle du modèle. Ainsi, à la lecture du graphique, nous pouvons déterminer le pourcentage de répondants que nous allons réussir à cibler en fonction du pourcentage de la population à qui nous allons adresser notre mailing.

La **courbe ROC** (Receiver Operating Characteristic) permet d'évaluer la performance d'un modèle de classification en visualisant le compromis entre la **sensibilité** (taux de vrais positifs) et **1 - spécificité** (taux de faux positifs). L'**aire sous la courbe (AUC)** est ici de **0,6490**, ce qui indique

une **capacité de discrimination modérée** du modèle. En d'autres termes, le modèle a une capacité limitée à distinguer entre les répondants et les non-répondants à la campagne.

Un AUC de **0,5** signifie que le modèle ne fait pas mieux qu'un tirage aléatoire, tandis qu'un AUC de **1** reflèterait une prédiction parfaite. Avec un score de 0,649, le modèle montre une **valeur ajoutée**, mais **reste améliorable** : il capte une partie du signal, mais pourrait bénéficier d'un meilleur ajustement, d'un enrichissement des données ou d'un choix différent de variables explicatives.



Analyse de la robustesse de ton modèle

1. **Capacité de généralisation limitée :**
   Un AUC de ~0.65 montre que le modèle détecte une certaine structure dans les données, mais **reste faible pour des usages décisionnels critiques** (comme un ciblage marketing précis ou une campagne automatisée). Il est **mieux qu'un tirage au hasard**, mais pas très performant.
2. **Faible pouvoir discriminant :**
   La courbe ROC étant **proche de la diagonale**, cela indique que le modèle **n'est pas très robuste** pour différencier les classes (répondants vs non-répondants). Cela peut être dû à :
   - des **variables explicatives peu informatives** ;
   - un **modèle trop simple ou mal spécifié** ;
   - un **surapprentissage sur un petit jeu d'apprentissage** ;
   - ou un **déséquilibre de la variable cible**.
3. **Absence de surajustement visible :**
   Si cette performance est constatée **autant en apprentissage qu'en test**, alors le modèle est probablement **cohérent mais simplement trop faible**. En revanche, si l'AUC est **nettement meilleur en apprentissage qu'en test**, là on suspecte du **surapprentissage**, ce qui remet en cause sa robustesse.
4. **Manque de stabilité potentielle :**
   Si le modèle change beaucoup selon les jeux de données (ex. validation croisée), alors sa **robustesse est faible**. C'est un point à tester.