Université de Lille

Etude spatiale du prix de l'immobilier a Arras (2022-2025)

Projet 2 - Prix d'un bien immobilier en fonction de ses caracteristiques et de son voisinage

François PICHON Julien POT

1. Construction de la base de donnees

Le territoire étudié est la commune d'Arras (code INSEE 62041) et la période d'observation couvre les transactions du 01/01/2022 au 31/12/2025. Afin de limiter l'hétérogénéité liée aux différences structurelles entre types de biens, l'analyse est restreinte aux appartements, identifiés dans DVF par la variable `type_local`.

Les données proviennent, d'une part, de la base DVF, qui fournit les informations de transaction (valeur foncière, surface réelle bâtie, nombre de pièces principales, coordonnées longitude/latitude), et d'autre part, des sections cadastrales du Cadastre Etalab utilisées pour définir l'environnement spatial (quartiers). Les sections sont initialement disponibles au format GeoJSON compressé (`.json.gz`) puis converties en Shapefile (`.shp`) pour le rendu.

Enfin, un nettoyage est appliqué pour garantir la qualité des observations : seules les ventes sont conservées (`nature_mutation = Vente`), les valeurs manquantes sur le prix, la surface ou les coordonnées sont supprimées, les logements de très petite taille sont exclus (`surface_reelle_bati` > 9 m^2), les transactions à valeur foncière non positive sont retirées, et les prix au mètre carré sont bornés entre 500 et 20 000 /m^2 afin d'écarter les valeurs aberrantes.

Etape	Valeur
Observations finales (apres filtres)	1549
Observations rattachees a une section	1549 (100%)
Variable dependante	$y = \log(prix/m2)$

Statistiques descriptives (sur l'echantillon final) :

Sources: DVF (Demande de Valeurs Foncières) et Cadastre Etalab (sections 02/01/2026 cadastrales).

Indicateur	Valeur
N	1549
Prix moyen (EUR/m2)	4333.77
Prix median (EUR/m2)	2765.957
Ecart-type (EUR/m2)	3838.515
Surface moyenne (m2)	49.51904
Pieces moyennes	2.139445

Commentaire. Le prix moyen (4334 EUR/m2) est nettement superieur a la mediane (2766 EUR/m2), ce qui signale une distribution asymetrique avec quelques transactions tres cheres. Pour limiter l'influence de cette asymetrie, la modelisation utilise $y = \log(prix/m2)$.

2. Presentation du sujet et des donnees

Problematique. Expliquer le log(prix/m2) des appartements a Arras a partir des caracteristiques du bien (surface, pieces) et evaluer la presence d'effets spatiaux : les prix (ou les residus) sont-ils correles entre biens voisins ?

Carte 1 : transactions DVF geolocalisees (couleur = log(prix/m2)).

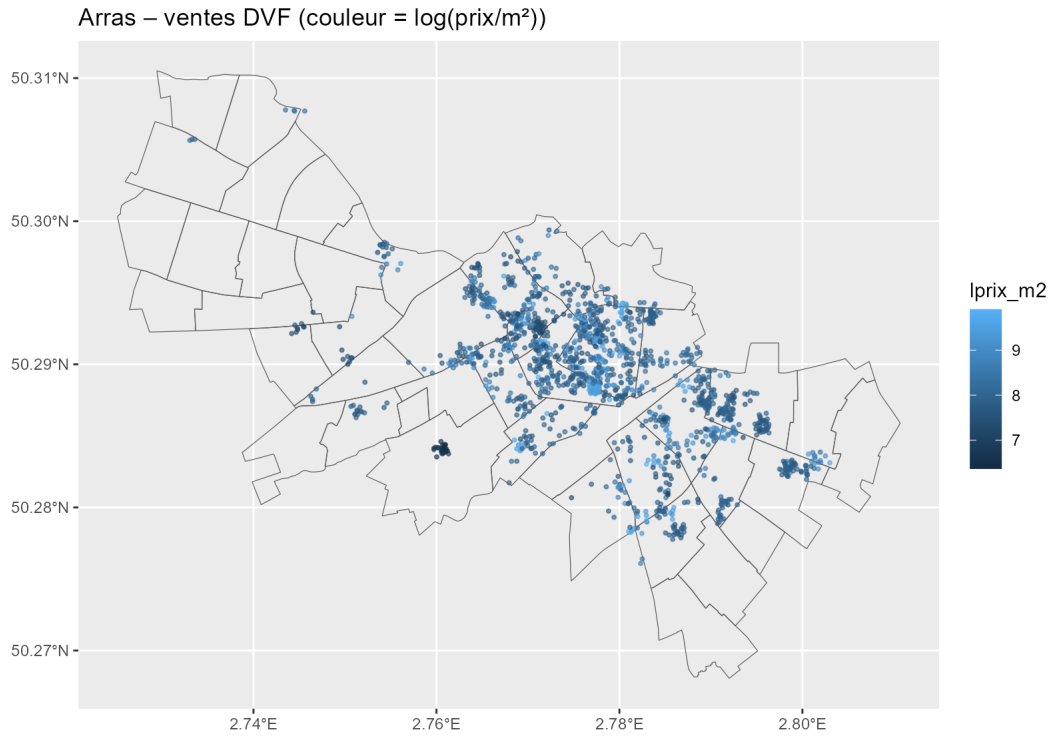


FIGURE 1 – Ventes a Arras (2022-2025), couleur = log(prix/m2).

La carte met en evidence une concentration des transactions dans la zone centrale, ainsi que des gradients de prix. Des points de couleur claire (prix/m2 eleves) apparaissent

Sources: DVF (Demande de Valeurs Foncières) et Cadastre Etalab (sections 02/01/2026 cadastrales).

autour du centre-ville, alors que des valeurs plus faibles se retrouvent davantage en peripherie. Cette premiere lecture suggere une structure spatiale des prix.

2.1 Heterogeneite spatiale par section cadastrale

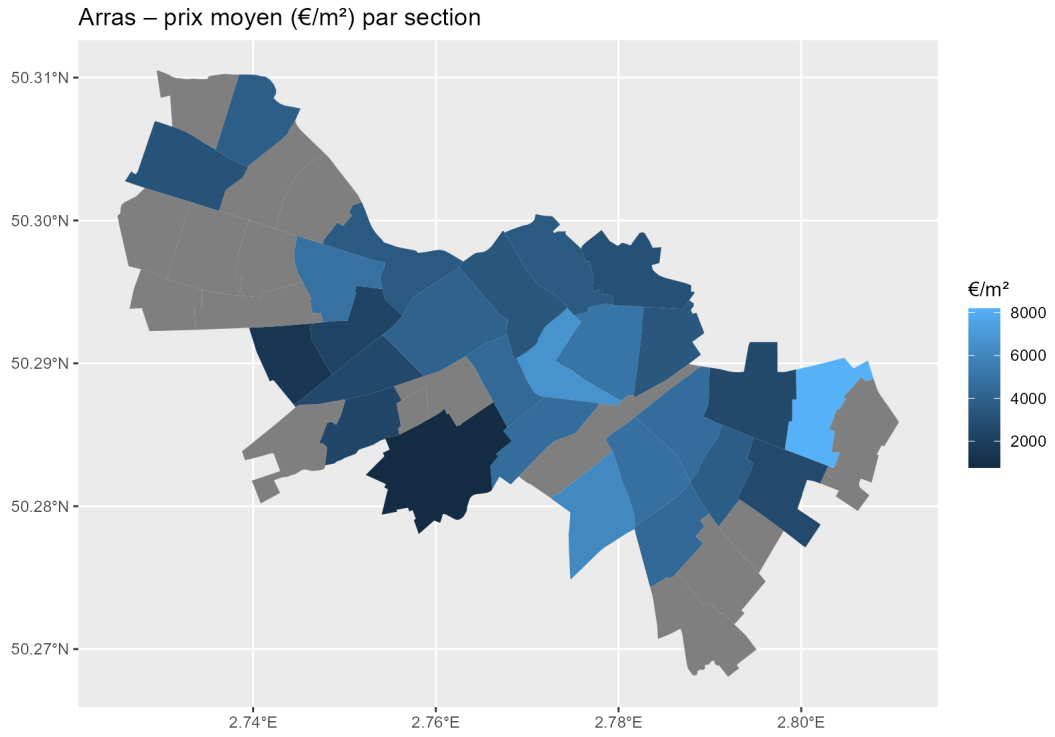


FIGURE 2 – Prix moyen (EUR/m2) par section cadastrale. Les zones en gris correspondent a des sections sans transaction retenue.

Cette representation agrege les transactions par section cadastrale (quartier). On observe des differences marquees entre sections : certaines sections atteignent des niveaux eleves (jusqu'a environ 8000 EUR/m2 sur la legende), tandis que d'autres sections restent sensiblement plus basses. Cette heterogeneite justifie l'introduction d'un terme spatial dans la modelisation (effets de quartier).

Remarque. Une partie des sections est en gris car aucune transaction ne satisfait simultanement les filtres (type_local, borne prix/m2, coordonnees valides) sur la periode.

3. Modelisation econometrique spatiale

On commence par un modele lineaire classique (OLS), puis on teste la dependance spatiale des residus. Ensuite, on estime des modeles spatiaux (SAR, SEM, SDEM) sous deux matrices de poids W (kNN et sections).

Sources: DVF (Demande de Valeurs Foncières) et Cadastre Etalab (sections 02/01/2026 cadastrales).

3.1 Modele OLS (reference)

Variable	Estimate	Std. Error	t value	p-value
Constante	10.14039	0.15981	63.452	$< 2 \cdot 10^{-16}$
log(surface batie)	-0.57590	0.05664	-10.167	$< 2 \cdot 10^{-16}$
Nb pieces principales	0.05743	0.03082	1.863	0.0626

TABLE 1 – OLS : variable dependante $y = \log(prix/m2)$.

Qualite d'ajustement : $R^2 = 0.1586$ (R^2 ajuste $= 0.1575$), erreur standard residuelle $= 0.6287$.

3.2 Tests de dependance spatiale sur les residus OLS

Test	W kNN (k=8)	W sections
Moran I (residus)	$I = 0.560$ ($p < 2.2 \cdot 10^{-16}$)	$I = 0.450$ ($p < 2.2 \cdot 10^{-16}$)
Rao score Lag	1810.6 ($p < 2 \cdot 10^{-16}$)	1776.2 ($p < 2 \cdot 10^{-16}$)
Rao score Error	2370.3 ($p < 2 \cdot 10^{-16}$)	2640.4 ($p < 2 \cdot 10^{-16}$)
Robuste Lag	0.089 ($p = 0.7653$)	1.887 ($p = 0.1696$)
Robuste Error	559.77 ($p < 2.2 \cdot 10^{-16}$)	866.15 ($p < 2.2 \cdot 10^{-16}$)

TABLE 2 – Moran et tests Rao score (LM) sur residus OLS.

Les tests de Moran montrent une autocorrelation spatiale tres forte des residus OLS. Les tests robustes indiquent surtout une dependance de type erreur spatiale (robuste Error significatif, robuste Lag non significatif), ce qui oriente vers des modeles SEM/SDEM.

3.3 Comparaison des modeles (AIC)

Modele	AIC (W kNN)	AIC (W sections)
OLS	2963.230	2963.230
SAR	2132.204	2335.423
SEM	2046.700	2257.451
SDEM	2049.126	2258.525

TABLE 3 – Comparaison AIC.

Tous les modeles spatiaux ameliorent nettement l'ajustement par rapport a l'OLS. Le SEM obtient l'AIC minimal sous les deux W. Le SDEM est tres proche sous W sections (difference ≈ 1.1) et permet d'evaluer directement des effets indirects des caracteristiques des voisins. Dans la suite, on presente le SDEM (W sections) comme modele d'interpretation.

Sources: DVF (Demande de Valeurs Foncières) et Cadastre Etalab (sections 02/01/2026 cadastrales).

3.4 Modele retenu et interpretation (SDEM - W sections)

Le SDEM (Spatial Durbin Error Model) combine : (i) un terme de regressions sur les variables du bien X, (ii) des variables explicatives spatialement retardees WX, (iii) une autocorrelation spatiale dans l'erreur.

Forme du modele. $y = X\beta + WX\theta + u$, avec $u = \lambda Wu + \varepsilon$. Ici $y = \log(prix/m2)$, $X = (1, \log(surface), pieces)$.

Variable	Estimate	Std. Error	z value	p-value
Constante	11.494410	0.705014	16.304	$< 2.2 \cdot 10^{-16}$
log(surface batie)	-0.646678	0.051018	-12.675	$< 2.2 \cdot 10^{-16}$
Nb pieces principales	0.091304	0.025695	3.553	0.0003804
W*log(surface batie)	-0.431864	0.252438	-1.711	0.0871
W*Nb pieces principales	0.212595	0.149539	1.422	0.1551

TABLE 4 – SDEM (sections) : coefficients.

Parametre spatial (erreur) : $\lambda = 0.77421$ (ecart-type 0.020872, $z = 37.093$, $p < 2.22 \cdot 10^{-16}$). Test LR = 705.15 ($p < 2.22 \cdot 10^{-16}$). AIC = 2258.5.

Interpretation. Le coefficient sur log(surface) est negatif et tres significatif : a pieces donnees, les logements plus grands ont un prix au metre carre plus faible (effet de taille). Le nombre de pieces est positif et significatif (p = 0.00038), suggerant un effet de qualite ou de typologie a surface comparable. Les termes WX ne sont pas fortement significatifs ; W*log(surface) est seulement marginalement different de zero (p = 0.087). En revanche, λ est eleve et tres significatif : les chocs non observes (qualite du quartier, accessibilite, amenites, bruit, etc.) sont spatialement correles. L'effet spatial s'exprime principalement via l'erreur plutot que par une interaction directe des prix.

Conclusion

Les donnees DVF a Arras montrent une dependance spatiale forte. Une specification avec erreur spatiale (SEM/SDEM) est la plus adaptee selon les tests robustes et l'AIC. La cartographie par sections met en evidence des effets de quartier importants, coherents avec un λ eleve. Pour ameliorer l'explication economique, on pourrait enrichir X (anciennete, etage, proximite services) ou estimer separement maisons et appartements.

Sources: DVF (Demande de Valeurs Foncières) et Cadastre Etalab (sections 02/01/2026 cadastrales).