Université de Lille

Rapport d'étude de cas - Scoring

Modélisation, validation et recommandations

Auteur : François PICHON & Julien POT

24 octobre 2025

Ce document présente le cadre méthodologique, les résultats et les recommandations opérationnelles pour un scoring de probabilité d'au moins un accident responsable.

Table des matières

1 Introduction et objectifs **2**
1.1 Contexte stratégique . . . 2
1.2 Problématique et finalités . . . 2
1.3 Contributions . . . 2
1.4 Démarche & gouvernance des données . . . 2

2 Base de données et qualité **3**
2.1 Périmètre . . . 3
2.2 Typologie et domaines de variation . . . 3
2.3 Qualité des données : principes de correction . . . 3
2.4 Déséquilibre et séparation . . . 4
2.5 Synthèse des variables clés . . . 4

3 Descriptif **5**
3.1 Fréquence et métriques . . . 5
3.2 Effets protecteurs (stables) . . . 5
3.3 Effets aggravants (significatifs) . . . 5
3.4 Pourquoi une lecture multivariée ? . . . 5

4 Modélisation (logit) **6**
4.1 Pourquoi le logit ? . . . 7
4.2 Spécification et encodage . . . 7
4.3 Signes attendus et cohérence métier . . . 8
4.4 Hypothèses . . . 8

5 Résultats, règle de décision, validation **8**
5.1 Score métier . . . 8
5.2 Seuil de Youden (décision binaire) . . . 9
5.3 Validation hors échantillon . . . 9

6 Discussion : coûts, biais, extensions **10**
6.1 Seuil statistique vs seuil économique . . . 10

7 Conclusion & recommandations **11**
7.1 Bilan chiffré . . . 11
7.2 Enseignements majeurs . . . 12
7.3 Recommandations opérationnelles . . . 12
7.4 Mot de clôture . . . 12

Annexe A — Script R complet **12**

1 Introduction et objectifs

1.1 Contexte stratégique

La rentabilité en assurance automobile repose sur la capacité à mesurer et piloter le risque individuel tout en maintenant l'équité tarifaire et une expérience client satisfaisante. Le risque porté par chaque sociétaire s'explique par un faisceau de facteurs observables : des attributs conducteur (âge, genre, situation professionnelle, historique de sinistralité via bonus-malus et ancienneté de contrat), des caractéristiques véhicule (type, catégorie/groupe de puissance, valeur), des éléments de géographie (région, densité de population) et un ancrage dans le temps (millésime). Sur 71 196 contrats observés en 2009–2010, notre objectif est de convertir ces informations en un score probabiliste estimant la probabilité d'au moins un accident responsable sur une année civile. Ce score doit être interprétable par les métiers (lecture des effets directionnels et de leur intensité) et robuste hors échantillon (stabilité des performances sur données non vues).

1.2 Problématique et finalités

La problématique est double. D'une part, analytique : identifier les déterminants du risque et mesurer l'effet propre de chaque facteur « toutes choses égales par ailleurs », en neutralisant les corrélations structurelles (p. ex. jeunesse et puissance du véhicule). D'autre part, opérationnelle : fournir un outil d'aide à la décision qui permette de segmenter le portefeuille, d'ajuster la tarification, de cibler des actions de prévention et d'anticiper la sinistralité. La transparence des mécanismes (hypothèses, variables, métriques) est un prérequis pour l'acceptation par les métiers et la conformité réglementaire.

1.3 Contributions

Le rapport apporte quatre livrables complémentaires :

1. un descriptif rigoureux mettant en évidence des tendances stables et intelligibles ;
2. une régression logistique calibrée et validée sur échantillon indépendant ;
3. une règle de segmentation fondée sur un seuil de Youden optimisé, afin d'équilibrer sensibilité et spécificité ;
4. une discussion critique des limites et extensions : prise en compte des coûts d'erreurs (FN vs FP), gestion des biais potentiels, intégration d'effets région/temps, et exploration d'alternatives de modèle (non linéaires, pénalisés) lorsque pertinent.

1.4 Démarche & gouvernance des données

La démarche suit un pipeline clair : collecter → nettoyer → modéliser → valider → interpréter. La fiabilité repose sur trois piliers : qualité des données (cohérence, recodages, typages), séparation apprentissage/test pour mesurer la généralisation, et métriques adaptées au déséquilibre de la cible (courbes ROC et AUC, plutôt que la *accuracy* seule). La sortie visée est un scoring immédiatement exploitable par les équipes, conçu pour être

itératif : intégration ultérieure d'éléments économiques pour fixer un seuil optimal en coût, enrichissement par télématique, et recalibrages périodiques si les distributions ou les performances évoluent.

2 Base de données et qualité

2.1 Périmètre

Le jeu de données regroupe 71 196 contrats automobiles observés sur 2009–2010. Les informations sont structurées en quatre axes : conducteur (*Age*, *Gender*, *Occupation*, *Bonus*, *Poldur* pour l'ancienneté de contrat), véhicule (*Type*, *Category*, *Group1*, *Value*), géographie (*Region*, *Density*) et temps (*Year*). La cible $Surv1 \in \{0, 1\}$ vaut 1 lorsqu'au moins un accident responsable survient sur l'année civile, 0 sinon. Ce périmètre couvre les principaux déterminants « observables » du risque assurantiel.

2.2 Typologie et domaines de variation

Les variables quantitatives (*Age*, *Bonus*, *Poldur*, *Value*, *Density*) présentent des plages plausibles après corrections ciblées d'anomalies. Les variables qualitatives sont définies sur des modalités explicites : *Gender* (H/F), *Category* (Petit/Moyen/Large), *Occupation* (5 modalités), *Region* (L/U), *Group1* (1–20), *Year* (2009/2010), *Adind* (0/1), *Type* (catégorie de véhicule). Cet éventail est suffisant pour une première modélisation explicable et opérationnelle. On note toutefois l'absence de télématique, qui limite la finesse comportementale (pas d'information sur le style de conduite, l'intensité ou les horaires d'usage).

2.3 Qualité des données : principes de correction

Nous privilégions la logique « corriger > supprimer » afin de limiter les biais de sélection et préserver l'information. Concrètement : *Gender* est recodé de F/Female et M/Male vers Femme/Homme ; *Surv1* est normalisée de Yes/No vers 1/0 (pré-requis pour la régression logistique) ;

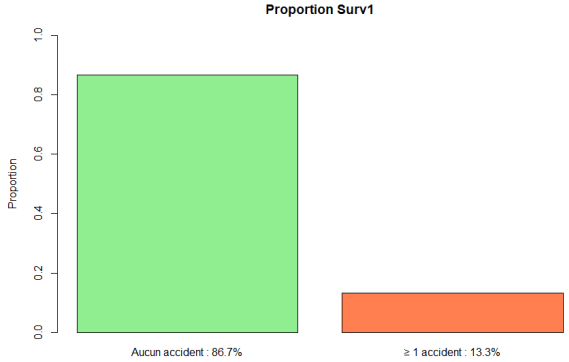
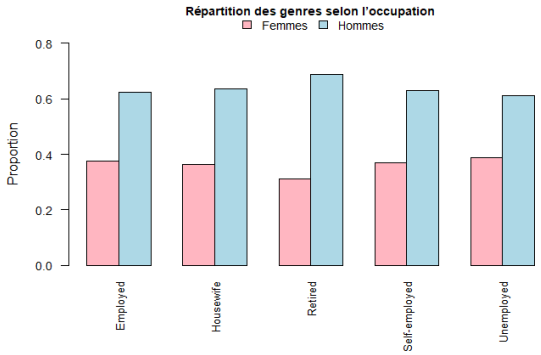
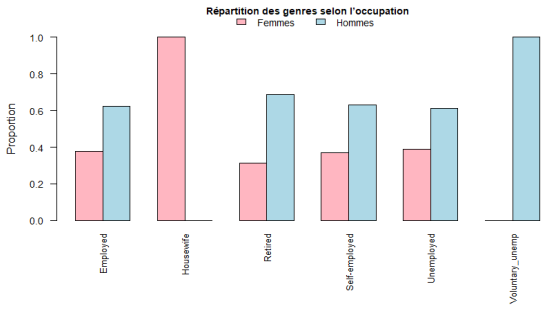


Figure 1 – proportion Surv1

Age fait l'objet de corrections ponctuelles des saisies aberrantes après vérification croisée (valeurs manifestement décalées) ; *Housewife* est recodé au vu des hommes dans cette catégorie qui sont deux fois plus nombreux, deux options s'offrent à nous : (1) reclasser ces hommes en « Unemployed », ou (2) créer une sous-catégorie « Voluntary unemployed » (chômage par choix) pour distinguer les situations, nous privilégions la deuxième option.



(a) Répartition des genres selon l'occupation



(b) Répartition des genres selon l'occupation (après transformation)

Figure 2 – Comparaison avant et après transformation.

Enfin, un typage cohérent (numérique vs. facteur) est appliqué à l'ensemble des champs pour sécuriser l'estimation, l'encodage des catégorielles et la reproductibilité des résultats.

2.4 Déséquilibre et séparation

La prévalence d'au moins un accident responsable est d'environ 13 %, rendant la classe positive minoritaire. Nous constituons une séparation aléatoire stratifiée 70/30 (apprentissage/test) afin d'évaluer loyalement la généralisation. Les métriques de référence privilégient la ROC/AUC — plus adaptées qu'une simple *accuracy* dans un contexte déséquilibré — et la décision binaire repose sur un seuil optimisé (calculé sur l'échantillon d'apprentissage puis appliqué tel quel au test).

2.5 Synthèse des variables clés

Table 1 – Variables clés (synthèse)

Axe	Variables / commentaire
Conducteur	*Age*, *Gender*, *Occupation*, *Bonus*, *Poldur* — effets comportementaux et historiques
Véhicule	*Type*, *Category*, *Group1*, *Value* — puissance/usage, redondances possibles
Géographie	*Region*, *Density* — exposition urbaine
Temps	*Year* — effet millésime (2009–2010)
Cible	*Surv1* (0/1) — ≥ 1 sinistre responsable sur l'année

Cette base, après recodages et contrôles de cohérence, fournit un socle propre et documenté pour une modélisation explicable, tout en signalant clairement les zones de recouvrement potentiel entre variables et la contrainte liée à l'absence de données comportementales fines.

3 Descriptif

3.1 Fréquence et métriques

La fréquence d'au moins un accident responsable est d'environ 13 %, ce qui place la classe positive en minorité. Dans ce contexte déséquilibré, l'accuracy devient peu informative : un classifieur qui prédirait « 0 » pour tout le monde obtiendrait déjà une accuracy élevée. Nous privilégions donc les courbes ROC et leur AUC, ainsi que la lecture des taux de vrais positifs (TPR) et faux positifs (FPR) le long des différents seuils de décision, afin d'évaluer la capacité discriminante toutes choses égales par ailleurs, c'est-à-dire indépendamment de la prévalence du risque dans l'échantillon.

3.2 Effets protecteurs (stables)

On observe une décroissance nette du risque avec l'âge, toutes choses égales par ailleurs : l'expérience de conduite, l'anticipation et des comportements plus prudents réduisent l'exposition effective. L'ancienneté de contrat (Poldur) est également associée à un risque plus faible ; elle combine un effet comportemental (assurés stables) et un effet de sélection (les profils risqués résilient davantage). Enfin, un bonus élevé — qui synthétise l'historique de sinistralité — constitue un indicateur robuste de prudence passée et s'aligne sur une probabilité plus faible d'accident responsable, toutes choses égales par ailleurs.

3.3 Effets aggravants (significatifs)

À l'inverse, le genre masculin présente une sinistralité plus élevée, cohérente avec une plus forte exposition (kilométrage, types de trajets), des vitesses moyennes plus importantes et une propension au risque différente, toutes choses égales par ailleurs. Les véhicules plus puissants, récents ou de valeur s'accompagnent d'une exposition accrue (performances, vitesses de croisière, usages spécifiques). La densité urbaine fait mécaniquement monter le risque, via le trafic, la complexité de circulation et la multiplication des interactions. Sur le plan socio-économique, les chômeurs et personnes au foyer apparaissent légèrement plus exposés, possiblement en lien avec des schémas d'usage distincts du véhicule, toutes choses égales par ailleurs.

3.4 Pourquoi une lecture multivariée ?

Ces constats descriptifs peuvent être entremêlés par des corrélations structurelles : les jeunes sont plus susceptibles de conduire des véhicules puissants, le milieu urbain se confond avec certains usages professionnels, et le bonus reflète à la fois l'expérience et la prudence.

Une lecture multivariée via la régression logistique s'impose afin d'isoler l'effet propre de chaque facteur, toutes choses égales par ailleurs. Cette approche permet de neutraliser les corrélations croisées entre variables et de quantifier directement l'impact marginal moyen de chaque caractéristique sur la probabilité d'accident. Les effets marginaux moyens offrent une mesure interprétable en points de probabilité, plus intuitive que les coefficients bruts ou les odds ratios pour une lecture économique et opérationnelle.

Les effets marginaux moyens confirment ces tendances : les profils de type F et E, les hommes et les inactifs (chômeurs, femmes au foyer) présentent une probabilité plus élevée d'accident, d'environ +2 à +4 points, tandis que les retraités et certaines régions apparaissent plus protecteurs, réduisant le risque de 2 à 3 points.

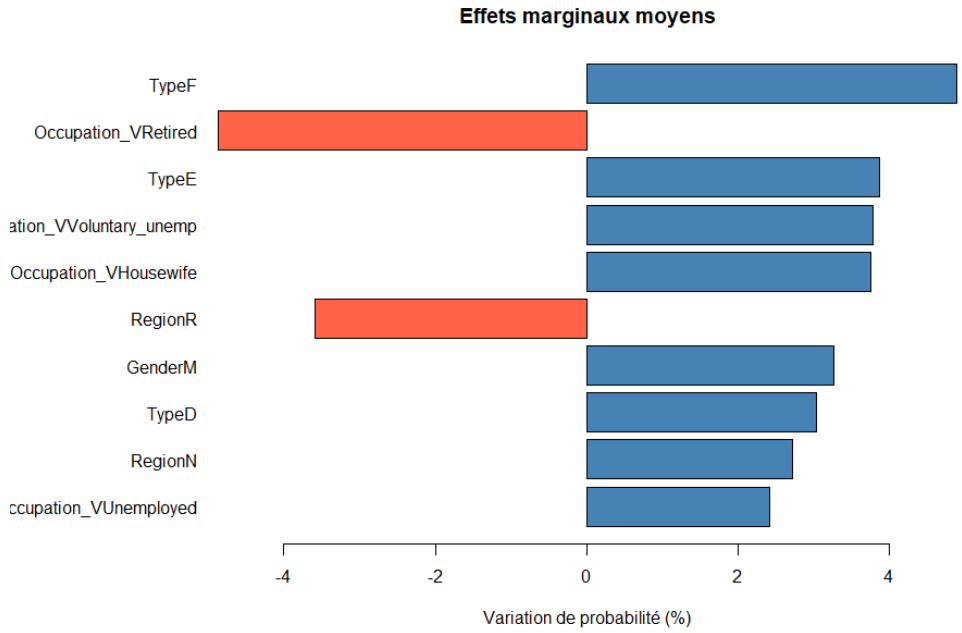


Figure 3 – Les effets marginaux

Globalement, le modèle souligne une segmentation nette du risque selon le profil socio-professionnel, le type d'assuré et la localisation.

4 Modélisation (logit)

Pour chaque assuré i, on modélise la probabilité d'avoir au moins un accident responsable :

$$P_i = \Pr(Y_i = 1 \mid X_i)$$

au moyen d'une **régression logistique binaire** :

$$\operatorname{logit}(P_i) = \ln\left(\frac{P_i}{1-P_i}\right) = \beta_0 + \sum_{k=1}^{K} \beta_k X_{ik}. \tag{4.1}$$

De façon équivalente :

$$P_i = \frac{1}{1 + \exp\left(-\beta_0 - \sum_{k=1}^{K} \beta_k X_{ik}\right)}. \tag{4.2}$$

Les coefficients β_k ne s'interprètent pas directement sur l'échelle des probabilités, mais à travers leurs **effets marginaux**, c'est-à-dire la variation de la probabilité P_i associée à une variation unitaire de X_{ik}, toutes choses égales par ailleurs :

$$\frac{\partial P_i}{\partial X_{ik}} \approx P_i(1 - P_i)\,\beta_k. \tag{4.3}$$

Cet effet marginal est *maximal lorsque* $P_i \approx 0{,}5$ et décroît vers 0 lorsque P_i est proche de 0 ou de 1. Les **effets marginaux moyens (AME)** sont obtenus en moyennant ces dérivées sur l'ensemble des individus :

$$\mathrm{AME}_k = \frac{1}{N} \sum_{i=1}^{N} \frac{\partial P_i}{\partial X_{ik}} = \frac{1}{N} \sum_{i=1}^{N} P_i(1 - P_i)\,\beta_k. \tag{4.4}$$

Ils traduisent l'impact moyen de chaque facteur sur la probabilité d'accident, exprimé en *points de probabilité*. Cette mesure est directement interprétable et plus intuitive que les coefficients bruts sur l'échelle des log-odds, tout en conservant une lecture *ceteris paribus*.

4.1 Pourquoi le logit ?

Le recours au modèle logit s'explique par plusieurs raisons pratiques et méthodologiques :

- la variable cible est binaire (survenue ou non d'un sinistre responsable) ;
- le jeu de variables explicatives combine des variables quantitatives (âge, densité, bonus, etc.) et qualitatives (genre, type de véhicule, région, etc.) ;
- les équipes métiers ont besoin d'une lecture claire et directe des effets en probabilité.

La régression logistique répond à ces exigences :

- elle fournit des effets marginaux directement interprétables (variation moyenne de probabilité pour chaque facteur) ;
- elle repose sur une estimation **robuste par maximum de vraisemblance** ;
- elle offre une traçabilité et un déploiement simples (modèle GLM standard).

Par rapport à des modèles plus flexibles (arbres,

4.2 Spécification et encodage

La spécification de travail retient les variables suivantes : *Age*, *Bonus*, *Poldur* (ancienneté), *Gender*, *Type* (véhicule), *Occupation*, *Region*, *Density* et *Adind*. Les variables catégorielles sont encodées en indicateurs (*one-hot*) avec une modalité de référence clairement fixée pour chaque champ, ce qui permet d'interpréter chaque coefficient β_k comme un écart à la référence. Pour limiter les recouvrements d'information, *Value* et *Category* sont écartées (redondances fonctionnelles avec *Type*/*Group1*). Enfin, *Region* et *Density* étant fortement

corrélées, on évite leur inclusion simultanée dans la spécification de base et l'on contrôle la colinéarité via les VIF (seuil usuel : $5-10$).

4.3 Signes attendus et cohérence métier

Nous anticipons des effets protecteurs pour *Age*, *Bonus* et *Poldur* (conduite plus prudente, effet de sélection et stabilité), et des effets aggravants pour *Gender* = *Homme*, la densité urbaine et certains types de véhicules plus puissants. Ces attentes orientent la lecture des coefficients estimés et servent de contrôle de cohérence entre les résultats statistiques et la réalité opérationnelle.

4.4 Hypothèses

Le modèle logit suppose (i) une relation linéaire sur l'échelle des *log-odds*, (ii) l'indépendance conditionnelle des observations compte tenu des covariables X (i.i.d. conditionnelle), et (iii) l'absence de séparation (quasi-)parfaite (aucune modalité ne prédit à elle seule la cible). En pratique, nous :

1. vérifions la stabilité des signes et des ordres de grandeur par ré-estimation ;
2. surveillons les VIF et réajustons si besoin ;
3. contrôlons l'influence des points extrêmes (diagnostics d'influence / *leverage*) ;
4. comparons avec des spécifications voisines (ajouts/retraits de blocs de variables) afin de s'assurer que les conclusions ne dépendent pas d'un encodage trop spécifique.

Cette discipline de spécification garantit un modèle lisible, parcimonieux et exploitable par les métiers, et prépare l'évaluation hors échantillon ainsi que la définition d'une règle de décision au seuil.

Ces vérifications préliminaires valident la cohérence des données et orientent la spécification du modèle logit, finalement restreint à 12 variables significatives après exclusion de Value et Category pour absence d'apport explicatif.

Nous obtenons :

$$\begin{aligned}\operatorname{logit}(P_i) &= \ln\left(\frac{P_i}{1-P_i}\right) \\ &= \beta_0 + \beta_1\,\mathrm{Bonus}_i + \beta_2\,\mathrm{Age}_i + \beta_3\,\mathrm{Group1}_i + \beta_4\,\mathrm{Occupation_V}_i + \beta_5\,\mathrm{Gender}_i \\ &\quad + \beta_6\,\mathrm{Density}_i + \beta_7\,\mathrm{Type}_i + \beta_8\,\mathrm{Poldur}_i + \beta_9\,\mathrm{Adind}_i + \beta_{10}\,\mathrm{CalYear}_i + \beta_{11}\,\mathrm{Region}_i + \varepsilon_i\end{aligned} \tag{4.1}$$

5 Résultats, règle de décision, validation

5.1 Score métier

— Le modèle attribue à chaque assuré une probabilité P_i d'avoir au moins un accident responsable sur l'année.

- Échelle de lecture : 0 = profil sûr ; 1 = profil très risqué.
- Usages du score :
  - classement des assurés (prioriser les actions sur les déciles/quantiles élevés) ;
  - décision binaire après choix d'un seuil, pour :
    - une tarification différenciée ;
    - la priorisation des actions de prévention ;
    - des dispositifs de fidélisation adaptés au niveau de risque estimé.

5.2 Seuil de Youden (décision binaire)

Le seuil est calé sur l'échantillon d'apprentissage en maximisant l'indice de Youden :

$$J(t) = \text{Sensibilité}(t) + \text{Spécificité}(t) - 1 \;=\; \text{TPR}(t) - \text{FPR}(t). \tag{5.1}$$

Avec ce critère, on obtient AUC = 0,758, seuil = 0,1394, TPR = 0,673, FPR = 0,294 sur apprentissage. En appliquant le même seuil (0,1425) au test, on observe Sensibilité = 0,663, Spécificité = 0,705 (donc FPR = 0,295) et 34,39 % d'assurés classés « à risque ». Cette part « à risque » est cohérente avec la formule $\pi \cdot \text{TPR} + (1-\pi) \cdot \text{FPR}$: avec une prévalence $\pi \approx 0{,}13$, on obtient $0{,}13 \times 0{,}663 + 0{,}87 \times 0{,}295 \approx 0{,}3428$ (34,3 %).

$$\Pr(\text{classé « à risque »}) = \pi \cdot \text{TPR} + (1-\pi) \cdot \text{FPR}. \tag{5.2}$$

5.3 Validation hors échantillon

À ce seuil, on capte $\sim 68\,\%$ des assurés qui auront un sinistre responsable (sensibilité), au prix d'environ 29 % de faux positifs (assurés prudents classés « à risque »). Compte tenu d'une prévalence de 13 %, la valeur prédictive positive (proportion de vrais « à risque » parmi les classés « à risque ») est autour de 25 % :

$$\text{VPP} = \frac{\pi \cdot \text{TPR}}{\pi \cdot \text{TPR} + (1-\pi) \cdot \text{FPR}} \approx \frac{0{,}13 \times 0{,}663}{0{,}3428} \approx 25\,\%.$$

À l'inverse, la valeur prédictive négative est élevée ($93-94\,\%$), ce qui signifie que la majorité des profils classés « sûrs » ne sinistreront pas. En pratique, ce compromis est statistiquement optimal au sens de Youden ; s'il faut tenir compte des coûts (FN vs FP), on ajustera le seuil en conséquence (cf. discussion).

Validation hors échantillon. Les courbes ROC (train & test) restent nettement au-dessus de la diagonale, signe d'une bonne discrimination. L'AUC test = 0,750, très proche de l'apprentissage (0,745), traduit une généralisation satisfaisante et aucun sur-apprentissage manifeste. Le maintien de la sensibilité/spécificité, avec un même seuil fixé sur le train, confirme la stabilité du modèle.

Récapitulatif (chiffres clés).

— *Apprentissage* : AUC 0,758 ; seuil 0,1394 ; TPR 0,684 ; FPR 0,294 ;34,6 % d'assurés classés « à risque ».
— *Test (seuil train)* : AUC 0,754 ; Sensibilité 0,686 ; Spécificité 0,706 (FPR 0,294) ; 34,7 % d'assurés classés « à risque ».

Table 2 – Métriques clés

Échantillon	AUC	Seuil	TPR	FPR
Apprentissage	0,754	0,1394	0,684	0,294
Test (seuil train)	0,758	0,1394	0,686	0,294

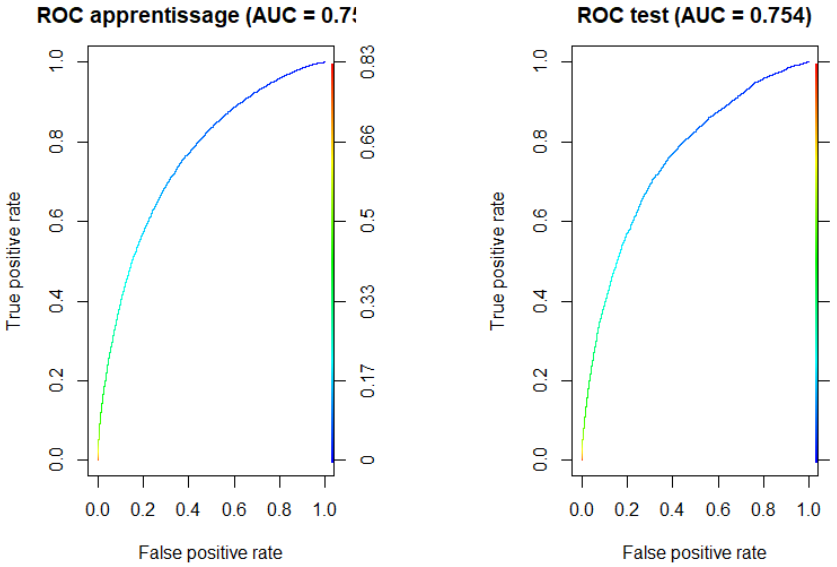


Figure 4 – Les courbes ROC train vs test

En pratique, un tiers du portefeuille est classé "à risque", captant environ deux tiers des sinistres responsables, ce qui garantit une segmentation efficace et exploitable opérationnellement.

6 Discussion : coûts, biais, extensions

6.1 Seuil statistique vs seuil économique

Le seuil de Youden maximise l'indice

$$J(t) = \text{Sensibilité}(t) + \text{Spécificité}(t) - 1,$$

soit, de façon équivalente,

$$J(t) = \text{TPR}(t) - \text{FPR}(t).$$

il ne tient ni compte des coûts opérationnels des erreurs de classement, ni des capacités des équipes à traiter un certain volume de « positifs ». En pratique, un faux négatif (assuré

risqué classé « sûr ») engendre un coût attendu supérieur à celui d'un faux positif (assuré prudent classé « à risque »). On formalise l'objectif comme la minimisation du coût espéré au seuil t :

$$C(t) = C_{FP}(1-\pi)\,\mathrm{FPR}(t) + C_{FN}\,\pi\,[1-\mathrm{TPR}(t)]. \tag{6.1}$$

Écriture équivalente demandée :

$$C(t) = CFP\,(1-\pi)\,\mathrm{FPR}(t) + CFN\,\pi\,[1-\mathrm{TPR}(t)]. \tag{6.2}$$

où π est la prévalence, C_{FN} le coût d'un FN (sinistre non anticipé, marges dégradées), et C_{FP} celui d'un FP (coût commercial, actions de prévention inutiles, friction client). Quand les probabilités sont calibrées et qu'on raisonne au niveau individuel, le seuil économique s'écrit

$$t^\star = \frac{C_{FP}}{C_{FP}+C_{FN}} = \frac{1}{1+\rho}, \qquad \rho = \frac{C_{FN}}{C_{FP}}. \tag{6.3}$$

Autrement dit, plus le coût d'un FN est élevé relativement au FP, plus le seuil optimal doit être bas (on préfère détecter plus large). **Recommandation :** estimer C_{FP} et C_{FN} avec l'actuariat (marge technique, coût des actions, churn, image), vérifier la calibration du modèle, puis ajuster t pour maximiser le bénéfice net. En présence de contraintes de capacité, choisir t tel que la part d'assurés « à risque » reste compatible avec les ressources, tout en conservant un gain marginal positif (analyse coût–volume).

Schéma de coûts : une Prédiction 1 sur Classe 0 ⇒ FP : coût C_{FP} ; une Prédiction 0 sur Classe 1 ⇒ FN : coût C_{FN}. Les cas corrects (Préd.1/Classe1, Préd.0/Classe0) ne génèrent pas de pénalité.

Table 3 – Matrice de coûts (schéma)

	Classe 0	**Classe 1**
Préd. 0	Gain 0	FN : coût C_{FN}
Préd. 1	FP : coût C_{FP}	Gain 1

7 Conclusion & recommandations

7.1 Bilan chiffré

Sur 71 196 assurés (2009–2010), la régression logistique produit un scoring interprétable et stable. En apprentissage : AUC 0,758, seuil 0,1394, TPR = 0,684, FPR = 0,294. En test (même seuil) : sensibilité 0,686, spécificité 0,706, soit 34,7 % d'assurés classés « à risque ». La proximité des AUC train/test et la conservation des métriques au seuil confirment une bonne généralisation.

7.2 Enseignements majeurs

La prévalence d'au moins un sinistre responsable est $\approx 13\,\%$. Les facteurs aggravants sont cohérents métier : hommes jeunes, urbain dense, véhicules puissants/récents. Les facteurs protecteurs sont attendus : âge, ancienneté de contrat (*Poldur*), bonus élevé, stabilité contractuelle. L'ensemble valide la pertinence d'un score simple, lisible et aligné avec les déterminants opérationnels du risque.

7.3 Recommandations opérationnelles

D'un point de vue décisionnel, il convient :

1. de remplacer le seuil de Youden par un seuil économique, en pondérant FN/FP selon les coûts actuariaux et la capacité de traitement ;
2. d'enrichir progressivement le modèle avec des signaux télématiques et des effets région/année afin d'absorber l'hétérogénéité spatio-temporelle ;
3. de connecter le score à des actions concrètes (prévention ciblée, tarification fine, rétention) en pilotant la marge technique par décile.

7.4 Mot de clôture

Un scoring bien calibré n'est pas seulement un outil de prédiction : c'est un levier de pilotage pour des décisions équitables et performantes sur le portefeuille, capable d'éclairer la segmentation, d'optimiser l'allocation des efforts commerciaux et de sécuriser la rentabilité dans la durée.

Annexe A — Script R complet

```
#Code R
#Pichon Francois
#Pot Julien
#M2 EA Etude de cas
library(readxl)
data <- read_excel("C:/Users/etudiant/Desktop/2025-2026/Etudes de Cas/Scoring/base2.xlsx",
col_types
= "text")
names(data)
head(data)
tail(data)
colnames(data)[12] <- "Region"
#Recodage
data$CalYear <- factor(data$CalYear)
data$Gender <- factor(data$Gender)
data$Type <- factor(data$Type)
data$Category <- factor(data$Category)
data$Occupation <- factor(data$Occupation)
data$Region <- factor(data$Region)
data$Adind <- factor(data$Adind)
str(data)
data$Age <- as.numeric(data$Age)
data$Bonus <- as.numeric(data$Bonus)
data$Poldur <- as.numeric(data$Poldur)
data$Value <- as.numeric(data$Value)
data$Density <- as.numeric(data$Density)
data$Group1 <- as.numeric(data$Group1)
table(data$Surv1)
data$Surv1 <- factor(data$Surv1)
levels(data$Surv1)[levels(data$Surv1) == ’no’] <- "0"
levels(data$Surv1)[levels(data$Surv1) == ’yes’] <- "1"
table(data$Surv1)
data$Surv1 <- as.numeric(data$Surv1) -1
#Encodage
levels(data$Gender)
table(data$Gender)
levels(data$Gender)[levels(data$Gender) == ’Female’] <- "F"
levels(data$Gender)[levels(data$Gender) == ’Male’] <- "M"
#"Valeur aberrante" Age
hist(x = data$Age, col = "lightblue", main = "Age")
unique(data$Age)
boxplot(data$Age ~ data$Surv1)
data$Age[data$Age == 488] <- 48
data$Age[data$Age == 600] <- 60
data$Age[data$Age == 200] <- 20
data$Age[data$Age == 533] <- 53
data$Age[data$Age == 255] <- 25
data$Age[data$Age == 466] <- 46
data$Age[data$Age == 366] <- 36
data$Age[data$Age == 733] <- 73
sort(unique(data$Age))
summary(data$Age)
```

```
unique(is.na(data))
#tirage al atoire (apprentissage et test)
set.seed(2204)
tirage = sample(nrow(data), nrow(data) * 0.70)
apprentissage <- data[tirage,]
test <- data[-tirage,]
#Description de l' chantillon
summary(apprentissage)
str(apprentissage)
summary(test)
attach(apprentissage)
#b) Liens
#Univari
table(apprentissage$Surv1)
prop <- prop.table(table(apprentissage$Surv1))
round(prop, digits = 3)
par(mfrow = c(1,1))
barplot(
prop,
col = c("lightgreen", "coral"),
main = "Proportion Surv1",
names.arg = c("Aucun accident : 86.7%", "? 1 accident : 13.3%"),
ylab = "Proportion",
ylim = c(0, 1)
)
M0 <- glm(Surv1 ~ 1, family = binomial(link = "logit"), data=apprentissage)
exp(coef(M0)) #La chance d'avoir Surv1 = 1 est 0.152 fois celle d'avoir Surv1 = 0
1/exp(coef(M0))
#Les 'non-accident s" sont 6.6fois plus nombreux que les "accident s"
exp(coef(M0))/(1+exp(coef(M0))) # La proba moyenne d'avoir eu au moins 1 accident est de
13.3%
1/(1+exp(coef(M0)))
prop.table(table(Surv1))
par(mfrow = c(1, 2))
hist(x = apprentissage$Bonus, col = "red", main = "Bonus", xlab = "",
ylab = "")
hist(x = apprentissage$Poldur, col = "violet", main = "Anciennet Contrat", xlab = "",
ylab = "")
hist(x = apprentissage$Value, col = "green2", main = "Valeur V hicule", xlab = "", ylab = "")
hist(x = apprentissage$Density, col = "slategray", main = "Densit ", xlab = "", ylab = "")
hist(x = apprentissage$Age, col = "yellow", main = "Age", xlab = "", ylab = "")
hist(x = apprentissage$Group1, col = "blue", main = "Groupe v hicule", xlab = "", ylab = "")
table(apprentissage$Gender)
prop.table(table(apprentissage$Gender))
table(apprentissage$CalYear)
prop.table(table(apprentissage$CalYear))
table(apprentissage$Type)
prop.table(table(apprentissage$Type))
table(apprentissage$Category)
prop.table(table(apprentissage$Category))
table(apprentissage$Occupation)
prop.table(table(apprentissage$Occupation))
```

```
table(apprentissage$Adind)
prop.table(table(apprentissage$Adind))
table(apprentissage$Region)
prop.table(table(apprentissage$Region))
par(mfrow = c(1,2))
barplot(table(apprentissage$CalYear), main = "Ann e du contrat")
barplot(table(apprentissage$Gender), main = "Genre")
barplot(table(apprentissage$Type), main = "Type du v hicule")
barplot(table(apprentissage$Adind), main = "Garantie tous risques (0/1)")
barplot(table(apprentissage$Category), main = "Cat gorie du v hicule")
barplot(table(apprentissage$Occupation), main = "Profession du conducteur", las = 2, cex.names =
0.6)
par(mfrow = c(1,1))
barplot(table(apprentissage$Region), main = "R gion d habitation")
#Analyse
# Crois s Occupation x Gender
table(apprentissage$Occupation, apprentissage$Gender)
round(prop.table(table(apprentissage$Occupation, apprentissage$Gender), margin = 1), 3)
round(prop.table(table(apprentissage$Occupation, apprentissage$Gender), margin = 2), 3)
tab <- round(prop.table(table(apprentissage$Occupation, apprentissage$Gender), margin = 1), 3)
# Barplot
par(mar = c(8, 4, 4, 2))
barplot(
t(tab),
beside = TRUE,
col = c("lightpink", "lightblue"),
main = "R partition des genres selon l occupation",
ylab = "Proportion",
ylim = c(0, 0.8),
las = 2,
cex.names = 0.8,
cex.axis = 0.9,
cex.main = 0.9
)
# L gende
legend(
"top",
inset = c(0, -0.15),
xpd = TRUE,
legend = c("Femmes", "Hommes"),
fill = c("lightpink", "lightblue"),
border = "black",
bty = "n",
horiz = TRUE,
cex = 0.9
)
idx_vol <- which(apprentissage$Occupation == "Housewife" & apprentissage$Gender == "M")
length(idx_vol)
Occupation_V <- as.character(apprentissage$Occupation)
Occupation_V[apprentissage$Occupation == "Housewife" & apprentissage$Gender == "M"] <-
"Voluntary_unemp"
apprentissage$Occupation_V <- factor(Occupation_V)
```

```
tab_V <- round(prop.table(table(apprentissage$Occupation_V, apprentissage$Gender), margin = 1),
3)
tab_V
par(mar = c(8, 4, 4, 2))
barplot(
t(tab_V),
beside = TRUE,
col = c("lightpink", "lightblue"),
main = "R partition des genres selon l occupation",
ylab = "Proportion",
ylim = c(0, 1),
las = 2,
cex.names = 0.8,
cex.axis = 0.9,
cex.main = 0.9
)
# L gende
legend(
"top",
inset = c(0, -0.15),
xpd = TRUE,
legend = c("Femmes", "Hommes"),
fill = c("lightpink", "lightblue"),
border = "black",
bty = "n",
horiz = TRUE,
cex = 0.9
)
#Age x Occupation
table(apprentissage$Occupation, apprentissage$Age)
round(prop.table(table(apprentissage$Occupation, apprentissage$Age), margin = 2), 3)
#Bonus x Poldur
table(apprentissage$Bonus, apprentissage$Poldur)
round(prop.table(table(apprentissage$Bonus, apprentissage$Poldur), margin = 2), 3)
#Bivari
table(apprentissage$CalYear, apprentissage$Surv1)
round(prop.table(table(apprentissage$CalYear, apprentissage$Surv1), margin = 1),4)
round(prop.table(table(apprentissage$CalYear, apprentissage$Surv1), margin = 2),4)
table(apprentissage$Gender, apprentissage$Surv1)
round(prop.table(table(apprentissage$Gender, apprentissage$Surv1), margin = 1),4)
round(prop.table(table(apprentissage$Gender, apprentissage$Surv1), margin = 2),4)
table(apprentissage$Type, apprentissage$Surv1)
round(prop.table(table(apprentissage$Type, apprentissage$Surv1), margin = 1),4)
round(prop.table(table(apprentissage$Type, apprentissage$Surv1), margin = 2),4)
table(apprentissage$Category, apprentissage$Surv1)
round(prop.table(table(apprentissage$Category, apprentissage$Surv1), margin = 1),4)
round(prop.table(table(apprentissage$Category, apprentissage$Surv1), margin = 2),4)
table(apprentissage$Occupation_V, apprentissage$Surv1)
round(prop.table(table(apprentissage$Occupation_V, apprentissage$Surv1), margin = 1),4)
round(prop.table(table(apprentissage$Occupation_V, apprentissage$Surv1), margin = 2),4)
table(apprentissage$Adind, apprentissage$Surv1)
round(prop.table(table(apprentissage$Adind, apprentissage$Surv1), margin = 1),4)
```

```
round(prop.table(table(apprentissage$Adind, apprentissage$Surv1), margin = 2),4)
table(apprentissage$Region, apprentissage$Surv1)
round(prop.table(table(apprentissage$Region, apprentissage$Surv1), margin = 1),4)
round(prop.table(table(apprentissage$Region, apprentissage$Surv1), margin = 2),4)
chisq.test(table(apprentissage$CalYear, apprentissage$Surv1))
chisq.test(table(apprentissage$Gender, apprentissage$Surv1))
chisq.test(table(apprentissage$Type, apprentissage$Surv1))
chisq.test(table(apprentissage$Category, apprentissage$Surv1))
chisq.test(table(apprentissage$Occupation_V, apprentissage$Surv1))
chisq.test(table(apprentissage$Adind, apprentissage$Surv1))
chisq.test(table(apprentissage$Region, apprentissage$Surv1))
boxplot(Density ~ Surv1)
boxplot(Bonus ~ Surv1)
boxplot(Value ~ Surv1)
boxplot(Poldur ~ Surv1)
boxplot(Age ~ Surv1)
boxplot(Group1 ~ Surv1)
summary(apprentissage)
wilcox.test(Density ~ Surv1, data = apprentissage)
wilcox.test(Bonus ~ Surv1, data = apprentissage)
wilcox.test(Value ~ Surv1, data = apprentissage)
wilcox.test(Poldur ~ Surv1, data = apprentissage)
wilcox.test(Age ~ Surv1, data = apprentissage)
wilcox.test(Group1 ~ Surv1, data = apprentissage)
# Corr lations variables continues
continues <- apprentissage[, sapply(apprentissage, is.numeric)]
cor_matrix <- cor(continues, use = "pairwise.complete.obs")
library(corrplot)
corrplot(cor_matrix, method = "color", tl.cex = 0.8)
cor(continues, method = "spearman")
#2c)
str_constant <- "~ 1"
str_all <-
"~Gender+Type+Category+Occupation+Age+Group1+Bonus+Poldur+Value+Adind+Region+Dens
ity"
#Essai avec un stepwise 1 re m thode
require(MASS)
modele <- glm(Surv1 ~ 1, data = apprentissage, family = binomial)
modele_stepwise <- stepAIC(modele, scope = list(lower = str_constant, upper = str_all), trace = T,
data =
apprentissage, direction = "both")
summary(modele_stepwise)
#R gression logistique (nos choix)
logit <- glm(formula = Surv1 ~ Bonus + Age + Density + Group1 + Occupation_V +
Gender + Region + Type + Poldur + Adind + Value + CalYear,
family = binomial, data = apprentissage )
summary(logit)
table(apprentissage$Value)
library(car)
vif <- vif(logit)
vif
summary(data$Density)
```

```
hist(data$Density)
logit_2 <- glm(formula = Surv1 ~ Bonus + Age + Group1 + Occupation_V +
Gender + Density + Type + Poldur + Adind + CalYear + Region,
family = binomial, data = apprentissage )
summary(logit_2)
vif(logit_2)
par(mfrow = c(1,1))
crPlot(logit_2, "Bonus")
crPlot(logit_2, "Density")
crPlot(logit_2, "Poldur")
crPlot(logit_2, "Age")
crPlot(logit_2, "Group1")
str(apprentissage)
deviance(logit_2) / df.residual(logit_2)
#Interpr tation des coeffs
exp(cbind(OR = coef(logit_2), confint(logit_2)))
#Effets marginaux
library(margins)
effet_marg <- margins(logit_2)
res_ame <- summary(effet_marg)
res_ame
res_ame$AME_points <- res_ame$AME * 100
top_ame <- head(res_ame[order(-abs(res_ame$AME_points)), ], 10)
# 5. Graphique
par(mar = c(5, 10, 3, 1))
barplot(rev(top_ame$AME_points),
names.arg = rev(top_ame$factor),
horiz = TRUE, las = 1,
col = ifelse(rev(top_ame$AME_points) > 0, "steelblue", "tomato"),
main = "Effets marginaux moyens",
xlab = "Variation de probabilit (%)")
#Exemple interpr tation, les hommes ont 3.5points de probas d'accident que les femmes
#Si p<0.05 <- effet significatif
#On peut d gager un profil peut tre
#2d)
chi2 <- logit_2$null.deviance - logit_2$deviance
chi2
ddl <- logit_2$df.null - logit_2$df.residual
ddl
pvalue <- pchisq(chi2,ddl,lower.tail = F)
pvalue #Il existe bien une diff rence significative entre le mod le d viance nulle et notre mod le
apprentissage$Occupation_V <- as.character(apprentissage$Occupation)
apprentissage$Occupation_V[apprentissage$Occupation == "Housewife" & apprentissage$Gender
==
"M"] <- "Voluntary_unemp"
apprentissage$Occupation_V <- factor(apprentissage$Occupation_V)
test$Occupation_V <- as.character(test$Occupation)
test$Occupation_V[test$Occupation == "Housewife" & test$Gender == "M"] <-
"Voluntary_unemp"
test$Occupation_V <- factor(test$Occupation_V)
# ROC / AUC (apprentissage & test)
library(ROCR)
```

```
proba_app <- predict(logit_2, type = "response", newdata = apprentissage)
proba_test <- predict(logit_2, type = "response", newdata = test)
pred <- prediction(proba_app, apprentissage$Surv1)
perf <- performance(pred, "tpr", "fpr")
perf_auc <- performance(pred, "auc")@y.values[[1]]
predtest <- prediction(proba_test, test$Surv1)
perftest <- performance(predtest, "tpr", "fpr")
perftest_auc <- performance(predtest, "auc")@y.values[[1]]
par(mfrow = c(1, 2))
plot(perf, colorize = TRUE, main = paste0("ROC apprentissage (AUC = ", round(perf_auc, 3), ")"))
plot(perftest, colorize = TRUE, main = paste0("ROC test (AUC = ", round(perftest_auc, 3), ")"))
par(mfrow = c(1, 1))
# Seuil optimal (Youden) appris sur apprentissage
perf_sens_spec <- ROCR::performance(pred, "sens", "spec")
sens <- slot(perf_sens_spec, "y.values")[[1]]
spec <- slot(perf_sens_spec, "x.values")[[1]]
cutoffs <- slot(perf_sens_spec, "alpha.values")[[1]]
optimal_index <- which.max(sens + spec) # indice de Youden
optimal_cutoff <- cutoffs[optimal_index]
se_opt <- sens[optimal_index]
sp_opt <- spec[optimal_index]
cat("\n=== Seuil optimal (Youden) appris sur apprentissage ===\n")
cat("Cutoff :", round(optimal_cutoff, 4), "\n")
cat("Sensibilit (Se) :", round(se_opt, 3), "\n")
cat("Sp cificit (Sp) :", round(sp_opt, 3), "\n")
cat("Balanced Accuracy :", round(mean(c(se_opt, sp_opt)), 3), "\n\n")
# Matrices de confusion au seuil Youden
library(caret)
cible_app <- factor(apprentissage$Surv1, levels = c(0,1), labels = c("0","1"))
cible_test <- factor(test$Surv1, levels = c(0,1), labels = c("0","1"))
modalite_app_opt <- factor(ifelse(proba_app > optimal_cutoff, "1", "0"), levels = c("0","1"))
modalite_test_opt <- factor(ifelse(proba_test > optimal_cutoff, "1", "0"), levels = c("0","1"))
cm_app_opt <- confusionMatrix(modalite_app_opt, cible_app, positive = "1")
cm_test_opt <- confusionMatrix(modalite_test_opt, cible_test, positive = "1")
cat("=== Matrice de confusion APPRENTISSAGE (Youden) ===\n")
print(cm_app_opt)
cat("Accuracy :", round(cm_app_opt$overall["Accuracy"], 3),
" | Sens :", round(cm_app_opt$byClass["Sensitivity"], 3),
" | Spec :", round(cm_app_opt$byClass["Specificity"], 3),
" | BalAcc :", round(mean(c(cm_app_opt$byClass["Sensitivity"],
cm_app_opt$byClass["Specificity"])), 3), "\n\n")
cat("=== Matrice de confusion TEST (Youden appris sur apprentissage) ===\n")
print(cm_test_opt)
cat("Accuracy :", round(cm_test_opt$overall["Accuracy"], 3),
" | Sens :", round(cm_test_opt$byClass["Sensitivity"], 3),
" | Spec :", round(cm_test_opt$byClass["Specificity"], 3),
" | BalAcc :", round(mean(c(cm_test_opt$byClass["Sensitivity"],
cm_test_opt$byClass["Specificity"])), 3), "\n")
#Essai avec discr tisation pour montrer que certaines transformations (discr tisation, splines,
passage en
quadratique)
#Ne fait pas descendre l’AIC o ne donne pas une courbe ROC plus pr cise.
```

```
library(dplyr)
auto <- apprentissage # copie de travail
# Discr tisations (exemples ajuste si besoin)
auto <- auto %>%
mutate(
Age_q = cut(Age, breaks=quantile(Age, probs=seq(0,1,0.25), na.rm=TRUE),
include.lowest=TRUE),
Group1_q = cut(Group1, breaks=quantile(Group1, probs=seq(0,1,0.25), na.rm=TRUE),
include.lowest=TRUE),
Bonus_q = cut(Bonus, breaks=quantile(Bonus, probs=seq(0,1,0.25), na.rm=TRUE),
include.lowest=TRUE),
Poldur_q = cut(Poldur, breaks=quantile(Poldur, probs=seq(0,1,0.25), na.rm=TRUE),
include.lowest=TRUE),
Density_q= cut(Density,breaks=quantile(Density,probs=seq(0,1,0.25), na.rm=TRUE),
include.lowest=TRUE)
)
# Mod le logit avec variables qualitatives (r fs = 1er quartile / premi re modalit )
M_score <- glm(Surv1 ~ Gender + Type + Occupation_V + Adind + Region +
Age_q + Group1_q + Bonus_q + Poldur_q + Density_q,
family=binomial, data=auto)
summary(M_score)
AIC(M_score)
AIC(logit_2)
```